中文教学精读 · ARXIV 2402.09236V2

从因果表征到概念学习

模型、逐式推导、完整证明路线、数值例子与批判性阅读

源论文：Learning Interpretable Concepts: Unifying Causal Representation Learning and Foundation Models

作者：Goutham Rajendran、Simon Buchholz、Bryon Aragam、Bernhard Schölkopf、Pradeep Ravikumar

版本：arXiv v2，2024-12-09；原论文CC BY 4.0

本手册是中文教学解析，不是逐句翻译或作者正式勘误。

覆盖正文与附录A–G、编号公式(1)–(78)、关键未编号公式及全部定理/引理/推论。

教学验算不等于形式化证明，也未复现原论文神经网络训练或LLM实验。

先修｜基础概念补课：从看懂符号到读懂第一条公式

这部分专门写给“以前学过，但很久没用”的你。**不要求先恢复整本概率论和线性代数，也不要一开始就啃证明。** 先建立对象、例子和术语之间的联系，再回到原论文。

正文中带虚线下划线的术语可以点击；右上角“查术语”也能按中文、英文或别名搜索。每个词条都有：直觉、定义、手算例子、论文用途和容易混淆的地方。静态版的全部解释在术语词典。

先修0｜先知道自己在学什么，不急着背定义

假设你有一堆物体图片，想研究“颜色”和“大小”。要区分三个问题：

1. **表示问题：** 图片能否用少量有用数值来描述？
2. **识别问题：** 不同模型都能解释这些图片时，怎样知道哪个数真的对应颜色，而不是颜色与大小的混合？
3. **控制问题：** 改动某个内部数值，能否改变颜色或行为，同时少影响其他东西？

这篇论文的严格理论主要研究第二问；LLM编辑是第三问的一种启发式应用。你的因果结构学习背景主要关注“变量之间怎样连边”，而这里先问“变量本身怎样确定”。

学习时只反复问四句话：这个符号是什么？输入和输出是什么？我能算一个例子吗？论文此处为什么需要它？

先修1｜先分清数、向量、矩阵和函数

1. 一个数：标量

温度25、概率0.8、某个概念值3，都是标量。标量只有一个数。

2. 一组有顺序的数：向量

设

$$z = \begin{bmatrix} 3 \\ 4 \end{bmatrix} \in \mathbb{R}^2.$$

这表示z有两个实数分量。你可以暂时把它理解成“颜色强度3、大小4”，但**语义只是我们给这个教学例子的设定，不是看到两个数就自动知道它们的意义。**

$\mathbb{R}^2$中的2数的是坐标数量。列向量竖着写，行向量横着写。$z^\top = (3,4)$中的上标$\top$表示转置，不是乘方。

3. 内积：指定怎样从向量读出一个数

取$a = (1,2)^\top$，则

$$a^\top z = 1 \times 3 + 2 \times 4 = 11.$$

可以把a看成一组读取权重：第一个分量读1份，第二个分量读2份。**a是读取规则，z是被读取的数据，11才是读取结果。**

4. 矩阵：同时执行多条读取规则

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 2 \end{bmatrix}, \qquad Az = \begin{bmatrix} 1 \times 3 + 0 \times 4 \\ 1 \times 3 + 2 \times 4 \end{bmatrix} = \begin{bmatrix} 3 \\ 11 \end{bmatrix}.$$

A的每一行是一条测量。论文用A表示概念测量，不是因果邻接矩阵。

先检查维度：$k \times d$矩阵乘d维列向量，输出k维向量。你可以把它记成“中间维度对得上，外面留下输出维度”。

5. 函数：输入到输出的一条规则

$f(z) = 2z$是规则；$f(3) = 6$是把输入3代进去后的计算。写f^{-1}表示逆函数，而不是通常意义上的$1/f$。

先修2 | “线性”“仿射”“非线性”有什么区别?

线性映射保留输入的加法和缩放：

$$L(\alpha u + \beta v) = \alpha L(u) + \beta L(v).$$

用最简单的例子检查：

- $L(z) = 2z$线性，因为$2(u+v) = 2u + 2v$，而且$L(0) = 0$。
- $F(z) = 2z + 1$不是线性，但属于仿射映射：它多了一个偏移。
- $G(z) = z^2$通常非线性，因为$(u+v)^2 = u^2 + 2uv + v^2$，不等于$u^2 + v^2$。

“概念在潜空间线性”说的是Az的形式；它不要求图像生成器f也线性。

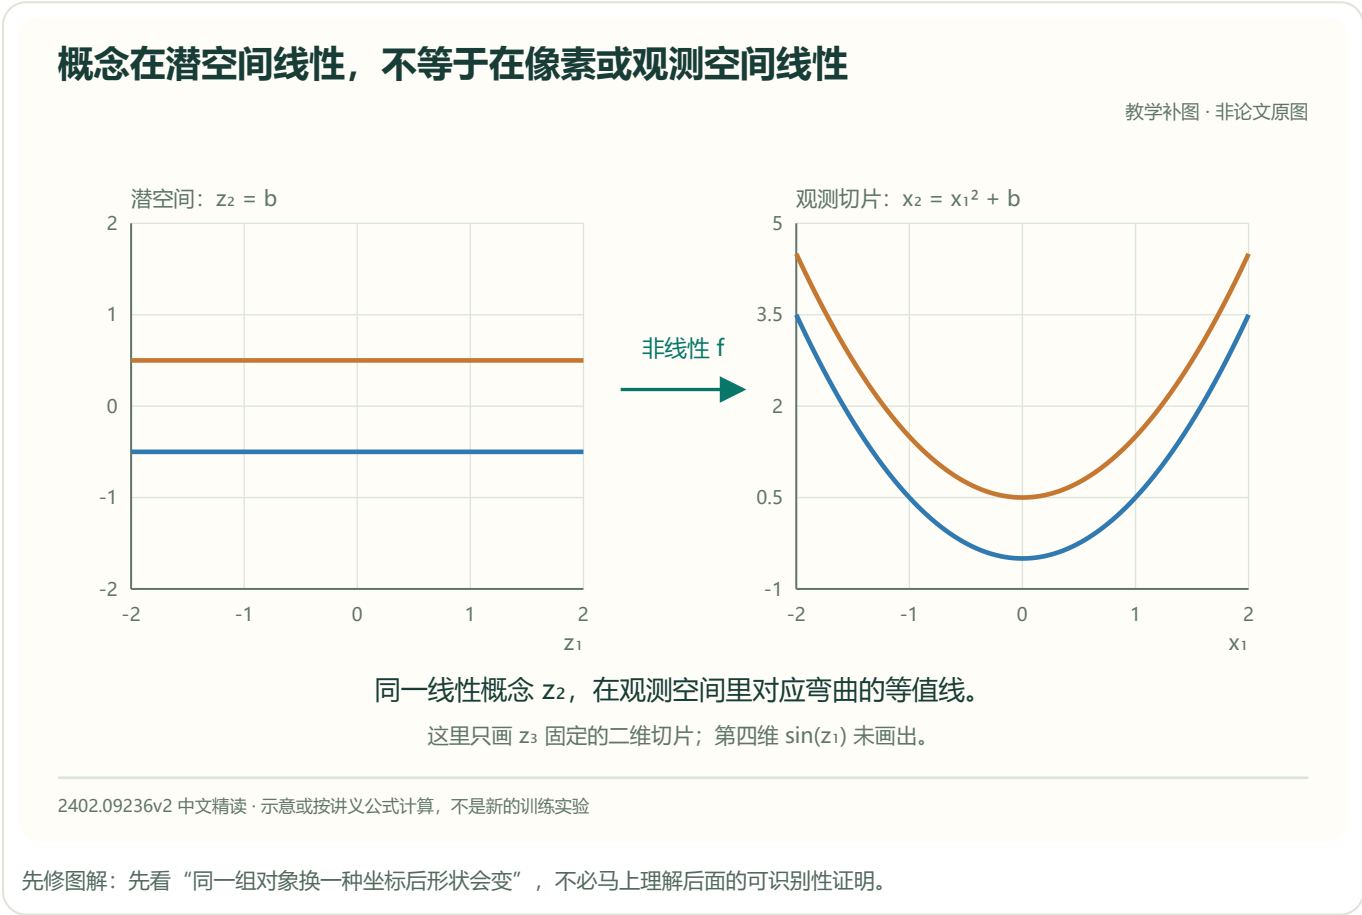
一个可以自己反算的生成模型

$$x = f(z) = (z_1,\ z_2 + z_1^2).$$

给$z = (2, 3)$，得到$x = (2, 7)$。反过来：

$$z_1 = x_1 = 2, \qquad z_2 = x_2 - x_1^2 = 7 - 4 = 3.$$

“读出第二个潜概念”的函数因此是$s_2(x) = x_2 - x_1^2$。它在z里线性，却在x里非线性。



先修图解：先看“同一组对象换一种坐标后形状会变”，不必马上理解后面的可识别性证明。

先修3｜线性独立、正交、统计独立：三个完全不同的问题

线性独立问：向量能否互相拼出来？

$(1, 0)$和$(2, 0)$不独立，因为后者是前者的2倍。$(1, 0)$和$(1, 1)$独立，因为第二个方向带来了无法由第一个产生的竖向变化。

严格定义：$c_1 a_1 + c_2 a_2 = 0$只能在$c_1 = c_2 = 0$时成立，就叫线性独立。

正交问：指定内积下是否垂直?

$(1,0)^\top(0,1)=0$，所以这两个方向正交。$(1,0)$和$(1,1)$内积为1，不正交，但它们依然线性独立。

统计独立问：知道一个随机结果，会不会改变另一个的分布?

两枚独立硬币，知道第一枚的结果不会改变第二枚的正面概率。这说的是随机变量的联合规律，不是在检查固定向量能否相互表示。

论文要求原子向量线性独立，并没有要求它们正交，也没有要求概念数值统计独立。

先修4 | 秩、零空间、左零空间：把定义变成算式

秩：真正独立的信息方向数

$$M=\begin{bmatrix}1&0\\0&1\\1&1\end{bmatrix}.$$

第三行等于前两行之和，所以3行不等于3份独立信息。前两行独立，秩是2。两列独立，因此M满列秩。

零空间：输入变化了，但测量看不见

令$A=(1,0)$。它只读第一坐标，所以

$$A\begin{bmatrix}0\\t\end{bmatrix}=0.$$

所有$(0,t)$都在A的零空间中。若想改变第一概念而保持其他东西少变化，就要知道哪些成分会被A看见，哪些会被忽略。

左零空间：给行加权，把结果抵消

对上述M，取$v=(-1,-1,1)^\top$:

$$v^\top M=-(1,0)-(0,1)+(1,1)=(0,0).$$

它不是神秘的线性代数符号，只是“第三行减去前两行”。论文利用这样的权重抵消二次项。

右零空间检查$Mv = 0$，左零空间检查$v^\top M = 0$。两者向量长度通常不同；先看矩阵尺寸，就不容易写反。

先修5｜仿射空间、维度与余维：为什么论文一直在数平面？

在三维中：

- 不加限制，三个坐标都能变，有3个自由度。
- 要求$z_1 = 1$，还剩z_2, z_3自由，是一个平面，维度2、余维1。
- 再要求$z_2 = 2$，只剩z_3自由，是一条直线，维度1、余维2。

一般地，d维空间中的k条独立线性约束，在有解时留下$d - k$维自由度。

$Az = 0$的解集经过原点，是线性子空间；$Az = b$是它的平移，叫仿射空间。若$Az_0 = b$，所有解就是

$$z = z_0 + v, \qquad v \in \ker A.$$

论文“概念维度k”数的是测量数；满足测量的集合维度则是$d_z - k$。不要把这两个维度看反。

先修6｜概率分布不是一批数据，密度也不是概率

随机变量、样本与分布

还没抽图时，Z表示不确定的潜变量；抽到一张图后，可以得到某个具体值z。反复抽到的$z^{(1)}, \ldots, z^{(N)}$是一批样本。分布描述产生这些样本的概率规律。

一枚公平硬币的总体正面概率是1/2，但10次可能出现7次正面。样本比例0.7不代表总体规律已经变成0.7。

离散概率是点的比例，连续概率通常是区域的面积

连续变量可以落在无穷多个数上。密度$p(z)$告诉你概率在附近有多集中：

$$P(a \le Z \le b) = \int_a^b p(z)\, dz.$$

积分可以先理解为：把区间切成许多小段，将“曲线高度×小段宽度”相加，再让小段越来越细。

例如$Z \sim U[0, 0.2]$，密度在区间内为5。整个区间概率为$5 \times 0.2 = 1$。**密度5没有问题，概率5才有问题。**

对于有连续密度的分布，单点概率通常为0；这不表示该点附近不可能出现样本。

先修7｜期望、方差与高斯：先掌握位置和散布

期望是按出现概率加权的平均位置。若0和2各以一半概率出现，期望为1。方差检查围绕均值的平均平方偏离：

$$\mathrm{Var}(Z) = E[(Z - EZ)^2] = \frac{1}{2}(0-1)^2 + \frac{1}{2}(2-1)^2 = 1.$$

标准差是方差的平方根。期望不必是某次抽样能出现的值：骰子期望3.5，但没有一面写着3.5。

高斯分布$\mathcal{N}(\mu, \sigma^2)$有两个基本参数：中心μ与方差σ²。其密度是

$$p(z) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(z-\mu)^2}{2\sigma^2}\right].$$

先读指数部分：离中心越远，负的平方越大，密度越小；σ越小，远离中心下降得越快。前面的系数负责让整条曲线下面积为1。

本文假设高斯的是筛选噪声，不是任意基准分布。 基准可以相关、复杂、多峰。

先修8｜条件概率、似然与贝叶斯：从筛选物体开始

设有100个物体，50个红色、50个蓝色。一个不完美的筛选器：

- 红色物体有80%概率通过；
- 蓝色物体有20%概率误通过。

在这组整齐的教学数据里，通过者是40个红色、10个蓝色。通过后是红色的概率为

$$P(\text{红} \mid \text{通过}) = \frac{40}{40 + 10} = 0.8.$$

写成“先加权、再归一化”就是

$$\frac{0.5 \times 0.8}{0.5 \times 0.8 + 0.5 \times 0.2} = 0.8.$$

先验0.5表示筛选前的比例；似然0.8表示红色情况下证据有多容易出现；后验0.8表示看到证据后重新计算的比例。分母是所有情况的加权总量。

这就是贝叶斯更新。连续情形把求和换为积分，形式保持：

$$p(z \mid y) = \frac{p(z)p(y \mid z)}{\int p(u)p(y \mid u)\,du}.$$

注意：刚才红蓝数量算得整齐是教学设定；真实随机筛选次数只会在平均意义上接近这些数量。

先修9｜怎样把这篇论文的第一个公式读成人话?

假设z是真正被表示的潜向量，我们想知道某个概念数值$a^\top z$。现实测量有噪声：

$$\tilde{b} = a^\top z + \epsilon.$$

- a：决定读哪个方向；
- $a^\top z$：这一张样本的真实概念数值；
- ε：测量误差；
- $\tilde{b}$：我们看见的含噪测量。

若噪声密度是q，看见测量结果b时，这个潜状态的似然就是$q(b - a^\top z)$。误差越符合噪声规律，该状态越容易解释测量。

于是

$$\boxed{p_C(z) = \frac{p^0(z)q(b - a^\top z)}{N_C}}, \qquad N_C = \int p^0(u)q(b - a^\top u)\,du.$$

逐段翻译：筛选后的分布 = 筛选前分布 × 测量匹配程度 ÷ 所有状态的总权重。

符号∝表示“只差一个不随z变化的正常数”。所以$p_C(z) \propto p^0(z)q(b - a^\top z)$不表示作者忘了归一化，而是暂时省略了分母。

多个测量在给定z时噪声独立，似然才能写成乘积。这正是原文公式(2)的来源。

先修10｜一维高斯筛选，逐行算到最后

设基准是$\mathcal{N}(0,1)$，希望测量接近b=1，噪声也为标准高斯：

$$p^0(z)=\frac{1}{\sqrt{2\pi}}e^{-z^2/2},\qquad q(1-z)=\frac{1}{\sqrt{2\pi}}e^{-(z-1)^2/2}.$$

相乘时前面系数相乘、指数相加：

$$p^0(z)q(1-z)=\frac{1}{2\pi}\exp\left[-\frac{z^2+(z-1)^2}{2}\right].$$

逐步配方：

$$z^2+(z-1)^2=2z^2-2z+1=2(z-1/2)^2+1/2.$$

所以乘积为

$$\frac{e^{-1/4}}{2\pi}\exp[-(z-1/2)^2].$$

归一化后成为

$$\boxed{p_C=\mathcal{N}(1/2,1/2).}$$

因为指数中$(z-1/2)^2$前的系数是1，与高斯形式$1/(2\sigma_C^2)$比较，就得到$\sigma_C^2=1/2$。中心直接读为1/2。

如果想核对分母，利用$\int e^{-t^2}dt=\sqrt{\pi}$（积分范围为整个实数轴），得到

$$N_C=\frac{e^{-1/4}}{2\sqrt{\pi}}\approx 0.21970.$$

▼ 可选：为什么全实数积分e的负平方等于根号π?

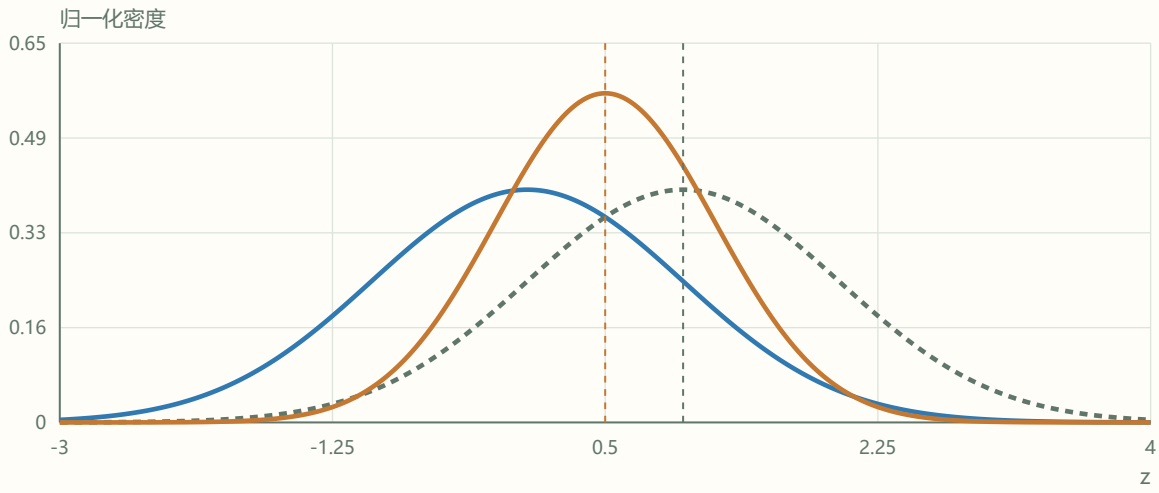
令$I=\int_{-\infty}^{\infty} e^{-x^2}dx>0$。平方后看作二维平面积分，按半径r的圆环相加；薄圆环面积约为$2\pi r\,dr$：

$$I^2=\int_0^{\infty} 2\pi r e^{-r^2}dr=\pi\int_0^{\infty} e^{-u}du=\pi.$$

这里使用换元$u=r^2$、$du=2r\,dr$，故$I=\sqrt{\pi}$。这一步是补充数学背景，不是本文可识别性证明的新结论。

含噪筛选不是直接把均值移到目标上

教学补图 · 非论文原图



蓝：基准 N(0,1)　　虚线：筛选 q(z−1)　　橙：后验 N(0.5,0.5)

目标 b = 1，但后验均值 = 0.5；先验与筛选权重相乘后必须重新归一化。

2402.09236v2 中文精读 · 示意或按讲义公式计算，不是新的训练实验

先修图解：对照橙色曲线再读刚才的配方。筛选目标b=1，不等于筛选后均值1/2。

先修11 | 密度比与对数：为什么复杂的东西可以消失?

把刚才的环境密度除以基准密度：

$$\frac{p_C(z)}{p^0(z)}=\frac{q(1-z)}{N_C}.$$

基准$p^0(z)$消掉了。这不需要先把复杂基准密度的全部形状学出来。

对数只要先记三条规则（所有输入为正）：

$$\log(ab) = \log a + \log b, \quad \log(a/b) = \log a - \log b, \quad \log(e^t) = t.$$

因此高斯的指数在取对数后变成二次式：

$$\log \frac{p_C(z)}{p^0(z)} = -\frac{1}{2}(z-1)^2 + c = -\frac{1}{2}z^2 + z + c',$$

c与c′不随z变化，但不是同一个数。证明中对z求导、找极小位置时可以把这些常数单独处理；写精确密度时不能把它们当成不存在。

观测变换的体积项为什么也会抵消?

先用一维$x = 2z$想象：区间被拉长2倍，为了保留概率面积，密度高度要变成一半：

$$p_X^e(x) = p_Z^e(x/2)/2, \qquad p_X^0(x) = p_Z^0(x/2)/2.$$

同一点作比，两个1/2又抵消。一般情形的Jacobian就是记录这种局部拉伸的工具。这里需要两个环境使用同一个变换，而且比值所在区域分母为正。

先修12 | 导数、梯度、Jacobian和链式法则各管什么?

一元函数：导数记录局部变化速度

从$F(z) = z^2$出发：

$$\frac{F(z+h) - F(z)}{h} = \frac{2zh + h^2}{h} = 2z + h.$$

让h趋于0，导数为2z。这也解释了$\frac{1}{2}z^2 - bz$的导数是$z - b$。

多个输入、一个输出：梯度

$$F(z_1, z_2) = z_1^2 + 2z_2^2, \qquad \nabla F = (2z_1, 4z_2)^\top.$$

每次只改一个输入求偏导，再把这些偏导排起来。梯度下降沿负梯度方向作小步更新，但小步变好不等于全局最优。

多个输入、多个输出：Jacobian

对$f(z_1, z_2) = (z_1, z_2 + z_1^2)$，每个输出都对每个输入求偏导：

$$Df(z) = \begin{bmatrix} 1 & 0 \\ 2z_1 & 1 \end{bmatrix}.$$

第一行描述第一个输出，第二行描述第二个输出。论文对向量环境函数求导，得到的也是这样的矩阵。

函数套函数：链式法则

$y = (2z+1)^2$先经过内层$u = 2z + 1$，再经过外层$y = u^2$：

$$\frac{dy}{dz} = \frac{dy}{du}\frac{du}{dz} = 2u \times 2 = 4(2z+1).$$

向量版本把两个数相乘换成矩阵相乘，顺序由输入输出维度决定。反向传播就是系统地利用这条法则计算网络梯度。

先修13｜最小值是数，argmin是位置或集合

考虑

$$F(z_1, z_2) = (z_1 - 1)^2.$$

它的最小值是0，但达到0的输入有无穷多个：$(1, -3), (1, 0), (1, 10)$都行。因此

$$\operatorname{argmin} F = \{(1, t) : t \in \mathbb{R}\}.$$

论文要看的是这个集合还剩几个自由度。只依赖一个概念的二次函数，常常只固定一个方向，其他方向仍自由。

还要区分：局部极小是在附近最低；全局最小是在整个指定定义域中最低；驻点只是梯度为0。例子$-z^2$在0处梯度为0，却是极大点。

先修14｜可识别性为什么不是“算法跑得出来”？

想象两位研究者给出两套模型，它们能产生完全相同的所有环境分布。若你就算拥有无限数据也无法区分它们，它们之间的差异就不是多训练几轮能解决的。

所以有三层问题：

层次	问题	典型困难
可识别性	总体信息是否足以区分解释?	不同概念混合产生同样分布
统计估计	有限数据能估得多准?	抽样波动、密度比估计误差
优化	选定目标能否高效求解?	局部极值、病态尺度、梯度不稳定

本文允许原子重排、换单位、换零点，例如$\tilde{s} = 2s + 3$；这叫识别到等价类。允许这些变化不代表允许任意把颜色和大小混成一个新概念。

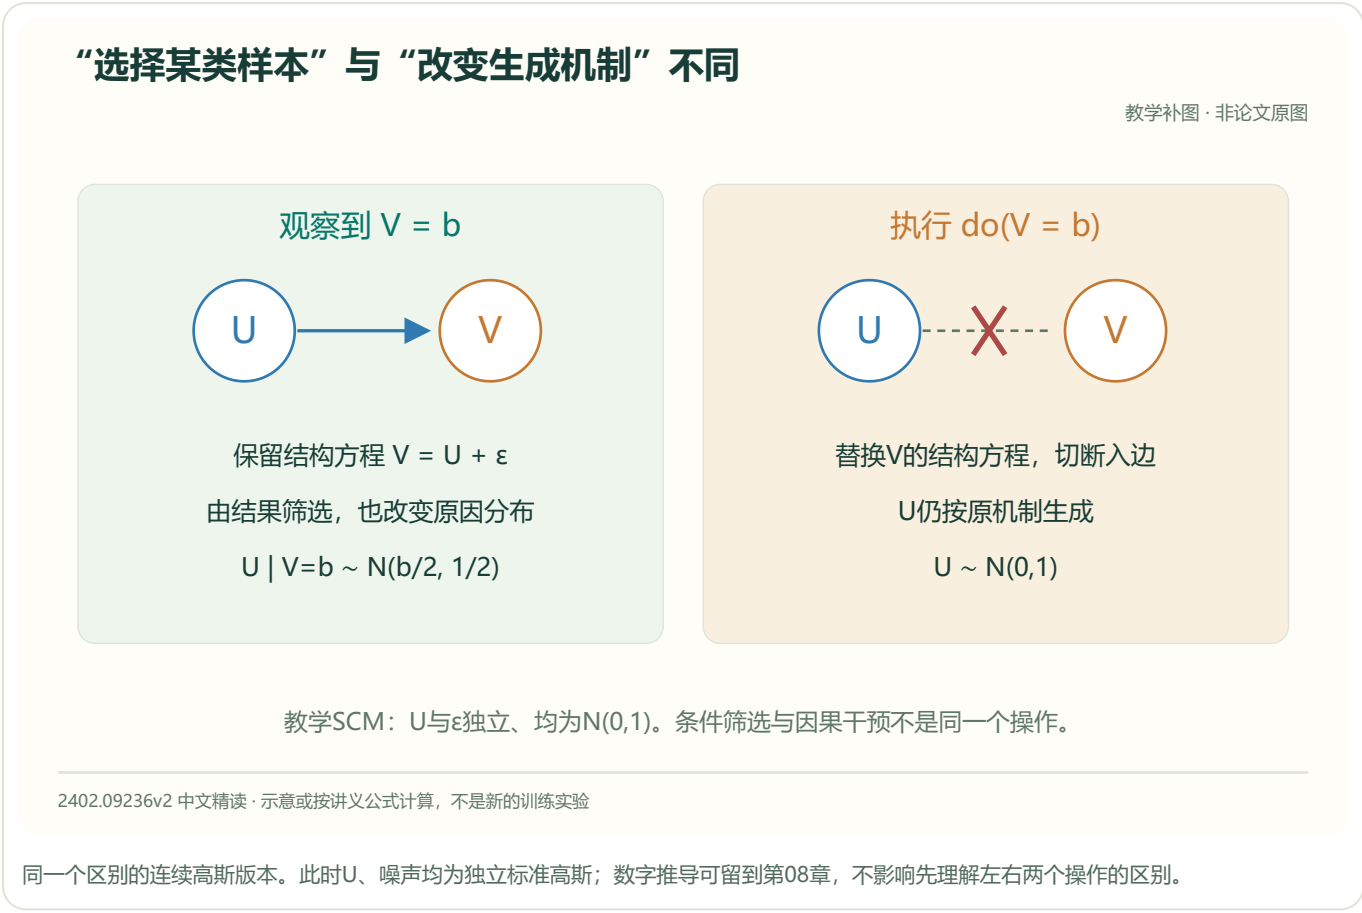
可识别定理不保证优化收敛；优化收敛不保证因果真值；好的分类准确率也不自动证明概念恢复。

先修15｜条件筛选与因果干预，先用“下雨—地湿”理解

设下雨R以一半概率发生，在这个极简教学世界里，地湿W完全由下雨决定：$W = R$。

- 观察到地湿，$P(R = 1 \mid W = 1) = 1$。
- 主动洒水把地面设为湿，即$\mathrm{do}(W = 1)$，不会让天空更容易下雨；雨仍以1/2概率发生。

第一种是用结果筛选世界，第二种是改变一个机制。**条件相关性不等于操作的因果效果。**



同一个区别的连续高斯版本。此时U、噪声均为独立标准高斯；数字推导可留到第08章，不影响先理解左右两个操作的区别。

LLM里的“激活干预”是对模型内部计算施加修改。它可以帮助研究模型行为，但不是自动证明现实世界中“真假、礼貌、帮助性”之间的因果机制。

先修16 | 分类损失怎样与密度比接上?

假设正类来自条件环境、负类来自基准环境，各占一半。固定输入x后，贝叶斯公式给出

$$P(Y=1 \mid x)=\frac{p_X^e(x)}{p_X^e(x)+p_X^0(x)}.$$

设这个概率为p，则

$$\frac{p}{1-p}=\frac{p_X^e(x)}{p_X^0(x)}, \qquad \log\frac{p}{1-p}=\log\frac{p_X^e(x)}{p_X^0(x)}.$$

左边叫logit（对数几率），不是log p。Sigmoid是它的反函数，把任意实数分数r变成概率$1/(1+e^{-r})$。

交叉熵鼓励模型给真实标签高概率。真实标签为1时，损失是$-\log p$：预测0.8约损失0.223，预测0.2约损失1.609。

在总体风险、足够模型容量等条件下，交叉熵最优预测等于真实条件标签概率。这就把分类、对数密度比和概念求值联系起来。有限网络训练是否达到这一理想状态，是另外的问题。

先修17｜公式阅读的简明字典

写法	读法	此处含义
$z \in \mathbb{R}^d$	z属于d维实数空间	z有d个实数坐标
$a^\top z$	a转置乘z	一个加权求和的标量
$Z \sim p$	Z服从分布p	不是Z约等于p
$p(z \mid b)$	给定b时z的条件密度	竖线不是除号
$p \propto w$	p正比于w	差一个与当前自变量无关的正常数
$\sum_i u_i$	对i求和	把各项相加
$\prod_i u_i$	对i求积	把各项相乘
$\int p(z)\,dz$	对z积分	在所有状态上累计密度面积
$E[Z]$	Z的期望	概率加权平均
$z^{\odot 2}$	z逐元素平方	不是矩阵乘方
$\|z\|_2$	z的欧氏范数	各分量平方和再开根号
$\ker A$	A的核或零空间	被A读成0的所有方向
$\mathrm{Diag}(z)$	以z为对角线的矩阵	对角外为0
$D\varphi$	φ的Jacobian	所有输出对所有输入的偏导表
argmin	达到最小值的输入集合	与最小的数值本身不同

上标e通常是环境编号，不是幂；上标0是基准环境；f^{-1}是逆映射；A^{+}是伪逆。读公式时先确认这些约定，可以少掉一半不必要的困惑。

先修18｜现在怎样回到原论文?

先不要按“把所有术语背完再看论文”的顺序。按以下三遍推进：

1. **直觉遍：** 读本章到先修11，能说清“潜变量、概念、筛选、密度比”。
2. **模型遍：** 回到00阅读地图、02模型。遇到词就点击查，只要求逐段翻译出公式在做什么。
3. **证明遍：** 补先修12–16与01预备知识，再读04定理2、05几何证明、06左零空间。

遇到“为什么满秩就可以左乘一个矩阵”时，回到秩与伪逆；遇到“为什么几乎处处能变成处处”时，回到连续与可微。**带着具体卡点补一个概念，比一次背完61个词更有效。**

先修19｜五个自测题：会这些就能开始读模型了

题1：a=(1,2)、z=(3,4)，哪个是方向，哪个是概念数值?

▼ 查看解释

a是读取方向或权重，z是潜表示，内积结果11才是概念数值。若筛选目标b=1，也不代表当前这个样本的概念值变成1。

题2：密度为5，违反概率不能超过1吗?

▼ 查看解释

不违反。宽度0.2的区间上密度为5，面积是1。密度高度与概率面积不同。

题3：筛选希望z接近1，为什么后验均值可能只有0.5?

▼ 查看解释

筛选是似然与先验相乘，不是强制把变量设成1。标准高斯先验更偏好0，单位方差的筛选偏好1，乘积在0.5处取得新的中心。

题4：M有3行，为什么左零空间里还有一个非零向量?

▼ 查看解释

上述M只有2个独立行方向，第三行是前两行之和，所以三行之间有一条非平凡抵消关系。左零空间维度为行数3减秩2，等于1。

题5：训练损失下降，能否据此证明找到了真正的因果变量？

▼ 查看解释

不能。损失下降说明当前优化目标改善了。还要分别检查模型设定、可识别性、有限样本误差，以及学到的特征是否满足相应解释或干预要求。

如果现在仍觉得“我知道词的意思，但读不动证明”，这是正常的下一阶段：先把一个具体例子算通，再逐行把数字换成符号，不必立刻把所有抽象结论一起记住。

00 | 先搭起整篇论文的地图

0.1 一句话概括

这篇论文问：**如果只关心高维数据中的少数概念，能否不恢复整个生成机制，就识别这些概念的数值?**

作者给出的路线是：把概念建模为潜空间中的线性测量；把不同数据集建模为对这些测量值的含噪筛选；利用不同环境相对于基准分布的密度比，消掉未知的基准分布和非线性变换带来的体积项。

随后有两条分支：

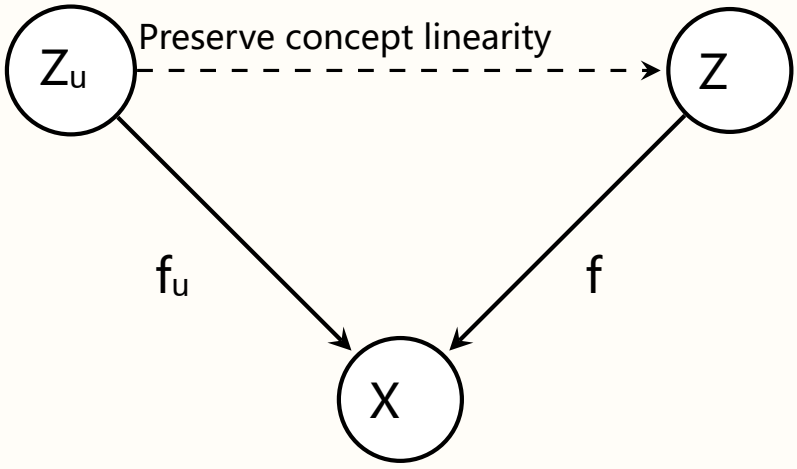
1. **严格理论分支**：环境够多样时，概念求值函数只能相差置换、尺度和偏移。
2. **LLM应用分支**：假设模型激活中已有近似线性概念，用真假答案的激活差做推理时编辑。

第二条分支受到第一条的启发，但不是第一条定理对真实 LLM 的直接推论。

图1(a)：为什么“表征”不必等于真实世界的全部机制?

原论文图1(a)：真实生成过程与学习表征

原论文图 · 离线适配



原图：Rajendran 等，arXiv:2402.09236v2，图1(a)，CC BY 4.0；文字层作离线兼容转换

原文图1(a)。保留作者的矢量结构与箭头；文字层转换为独立SVG文本，避免依赖arXiv网页样式。原作者署名及CC BY 4.0授权见图下方。

图左侧的 $Z_u \xrightarrow{f_u} X$ 表示真实但可能非常复杂的生成过程；右侧 $Z \xrightarrow{f} X$ 表示我们用来解释观测的表征模型。两组潜变量间的虚线强调保留感兴趣概念的线性结构，而非强求恢复每一个真实因素。

这是研究目标的示意图，不是另一个可识别定理。“模型更简单”也不表示可以在保持光滑可逆重建的同时随意压缩内在维度。图1(b)的平行概念平面将在第01章解释。

0.2 它没有完成哪些事情

- 没有识别潜变量之间的因果 DAG。
- 没有证明 GPT 预训练必然满足本文的筛选分布假设。
- 没有证明 next-token prediction 会学到本文的标准表示。
- 没有给出一般情况下的有限样本误差界。
- 没有证明对比学习优化一定达到总体全局最优。
- 没有证明 steering matrices 普遍优于静态 steering vectors。
- 没有证明概念在新的坐标系中“欧氏正交”，就代表现实语义上互不干扰。

明确这些边界之后，反而更容易看清论文真正有价值的部分。

0.3 你已有的因果结构学习知识如何接过来

在连续 DAG 学习中，你熟悉的是：

$$\min_{W} \mathcal{L}(X, W) + \lambda \|W\|_1, \qquad h(W) = 0.$$

这里数据列 X_i 已经是你选择的变量。本文把问题往前移了一层：数据可能是图像或模型激活，先要找到有意义的求值函数 $s_i(x)$。

$$x \longmapsto s_i(x) = a_i^\top f^{-1}(x).$$

本文主要约束的是 s_i 的可识别性，而不是 W 的无环性。 若未来要在这些概念上学因果图，还需要额外的结构假设、干预信息以及测量误差分析。

0.4 论文的逻辑链



教学补图0-1：先看整体依赖关系，再逐段推导。最后的LLM应用箭头不具有与前面定理相同的保证。

经验动机：基础模型中存在近似线性概念

↓ 作为建模假设，而非待证结论

概念：$s_i(x)=a_i^\top f^{-1}(x)$

↓ 含噪测量与贝叶斯筛选

环境分布：$p^e(z) \propto p^0(z) \times$ 高斯筛选权重

↓ 作对数密度比

$g^e(z)$=二次项 − 一次项 + 环境常数

↙ ↘

2n个条件环境的热身证明 n+1个条件环境的主要证明

充分统计量满秩 极小集几何 → M → B → 左零空间

↘ ↙

概念求值函数可识别，但无关坐标仍不确定

↓

共享编码器 + 二次分类头进行对比学习

↓ 启发，不是直接应用同一证明

真假激活差 → 均值 steering → 上下文相关矩阵 steering

0.5 符号字典

符号	维度/含义	最容易混淆的地方
x、z	$x \in \mathbb{R}^{d_x}$，$z \in \mathbb{R}^{d_z}$	观测与潜变量
f	潜变量到观测的混合/生成映射	LLM部分原文又用 $f(x)$ 表示编码，方向相反
$p^0 = p$	基准潜分布	不要求潜坐标独立
p^e	第 e 个筛选环境的分布	不是默认的干预分布
n	想识别的原子概念数	不是总潜维度 d_z
m	条件环境数	总环境数为 $m+1$，包括基准环境
a_i	第 i 个原子，列向量	$a_i^\top z$ 才是数值
A^e	若干 $a_i^\top$ 叠成的矩阵	不是因果邻接矩阵
b^e	环境筛选的目标值	通常不等于环境内概念的均值
S^e	环境 e 使用哪些原子	定理不要求已知
M	环境—原子筛选精度矩阵	不是 steering matrix
B	环境—原子目标值乘精度	$B_{ei} = 0$ 不足以判定没使用原子，因为目标值可能为0
σ	筛选噪声标准差	不是潜变量自身标准差
g^e	$\log p^0 - \log p^e$	分类 logit 用相反方向
φ	$\tilde{f}^{-1} \circ f$	两套潜表示间的过渡
$\Lambda = (M, B)$	充分统计量系数矩阵	与可识别关系中的对角尺度矩阵不是一回事
$H(x)$	本手册用于LLM激活的记号	避免与生成映射 f 混用
S_{steer}	本手册的 steering matrix	原文也叫 M，这里另命名

0.6 三层“吃透”标准

第一层：能解释。 能说清为什么要比较基准环境与筛选环境，为什么不需要知道基准分布的详细形式。

第二层：能推导。 不看原文，推导对数密度比；解释为什么要多出一个环境；完成左零空间证明；推导伪逆编辑。

第三层：能反驳和延伸。 能构造不满足假设的环境；知道任意加权 steering 为什么不保持目标值；能设计公平实验，区分理论成立、优化失败和模型设定失配。

0.7 原论文逐节对应

- 摘要、§1、§2、§6：本章与第13章，梳理问题、贡献与相关理论。
- §3：第02章；§4：第03章。
- 附录 A.1：第04章；A.2：第05–06章；A.3：第03、06章。
- §5.1、附录 E、F、G：第07章。
- 附录 B、C：第08章。
- §5.2、附录 D：第09章。
- 所有编号公式与关键未编号公式：第10章；核对意见：第11章。

建议先走完整条逻辑链，再回头精读公式，避免一开始被多套 M, B, f, Λ 淹没。

01 | 需要哪些数学工具？用一个例子贯穿

1.1 贯穿全文的可手算模型

【教学例子】 设潜变量 $z=(z_1,z_2,z_3)$，基准分布为 $\mathcal{N}(0,I_3)$。观测为

$$f(z)=(z_1,\ z_2+z_1^2,\ z_3,\ \sin z_1).$$

它虽然是非线性的，却单射，因为

$$z_1=x_1,\qquad z_2=x_2-x_1^2,\qquad z_3=x_3.$$

第四维 $x_4=\sin x_1$ 是冗余观测。这个例子满足“观测维度4、内在潜维度3”。

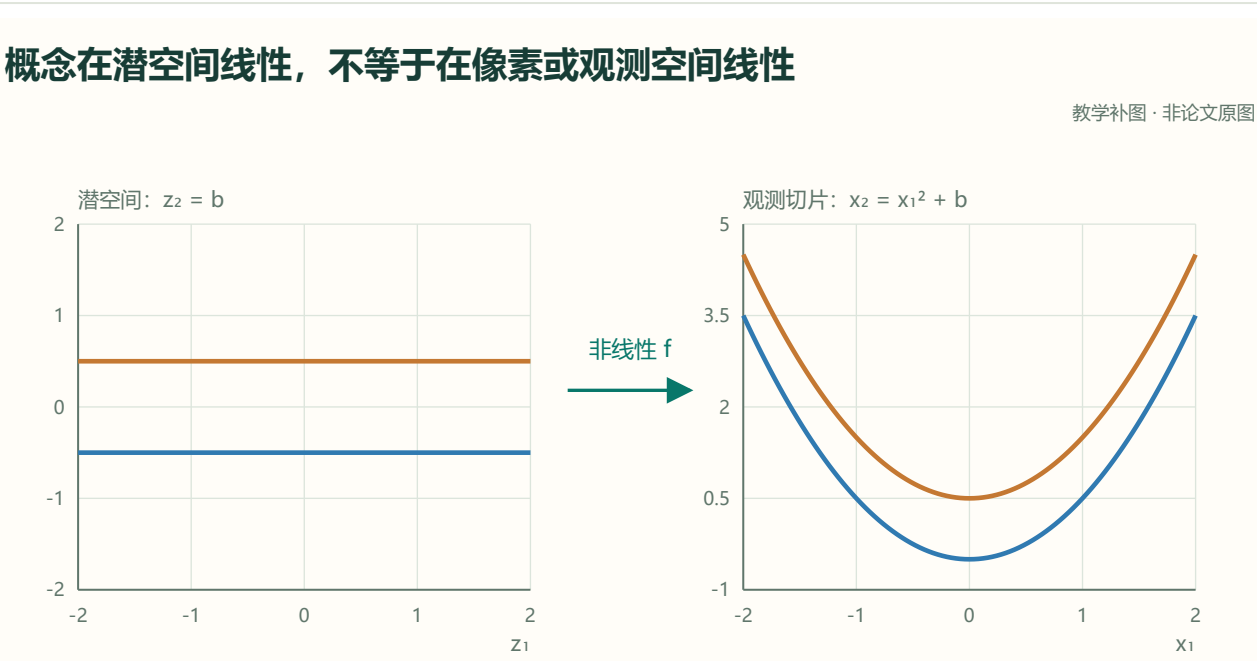
只关心两个原子：

$$a_1=(1,0,0)^\top,\quad a_2=(0,1,0)^\top.$$

因此两个求值函数是

$$s_1(x)=x_1,\qquad s_2(x)=x_2-x_1^2.$$

注意：**潜空间中的线性概念，在观测空间里可以是非线性函数。** 本文并不是说直接对原始像素或token做线性分类就够了。



教学补图1-1：同一概念在两个空间中的几何形状。只画潜变量第三坐标固定的二维切片，不代表整个数据只有二维。

所有筛选噪声均为标准高斯。设置三个条件环境：

环境	使用的原子	筛选目标
1	仅原子1	$z_1 \approx 0$
2	仅原子2	$z_2 \approx 0$
3	原子1和2	$z_1 \approx 1,\ z_2 \approx 2$

于是

$$M = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}, \qquad B = \begin{bmatrix} 0 & 0 \\ 0 & 0 \\ 1 & 2 \end{bmatrix}.$$

后续你会反复看见这个 M, B。z_3 是不关心的“无关坐标”，但并不是说观测中可以无损删掉它。

1.2 线性子空间、仿射空间与余维

$$\ker A = \{z : Az = 0\}$$

是线性子空间；若 $Az_0 = b$，则

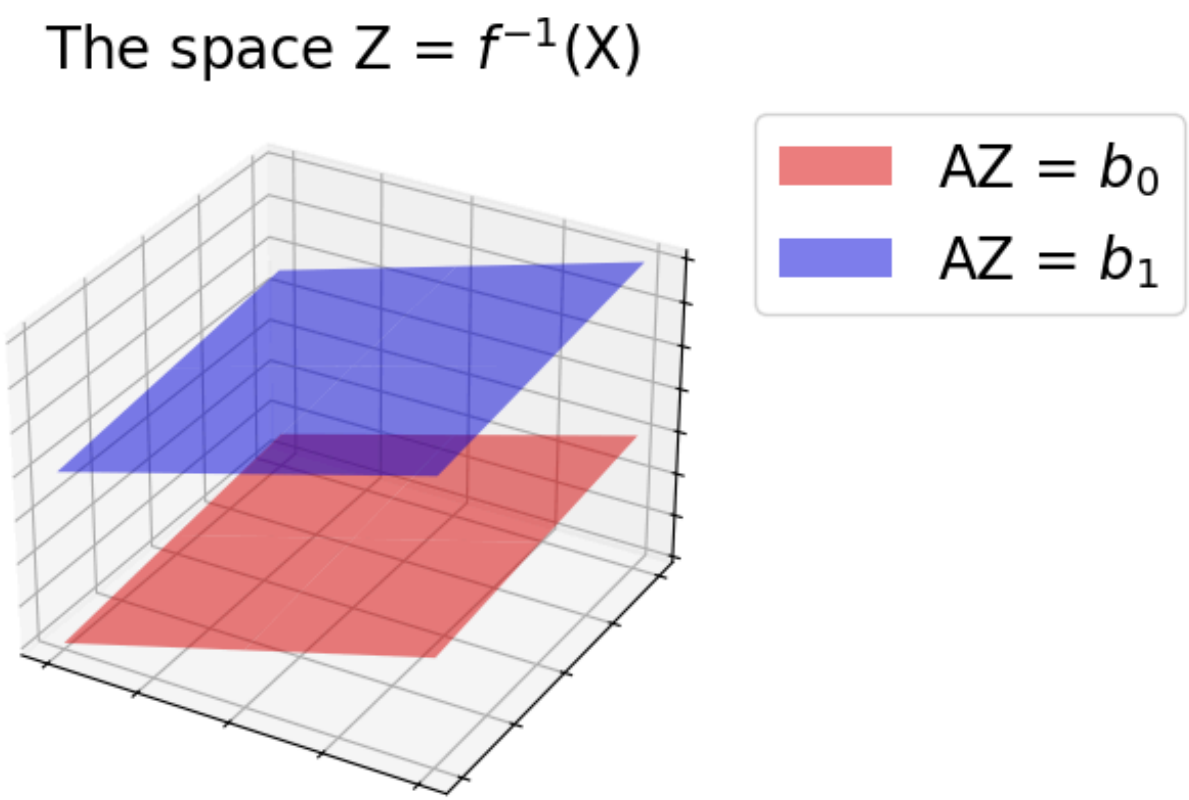
$$\{z : Az = b\} = z_0 + \ker A$$

是仿射空间。若 A 满行秩 k，则秩—零化度定理给出

$$\dim \ker A = d_z - k.$$

例如 $z_1 = 1$ 在三维中是二维平面，余维为1；$z_1 = 1, z_2 = 2$ 是一条直线，余维为2。论文所谓“概念维度 k”是测量/约束数，不是这个仿射集合自身的维度。

图1(b)的两张平行平面，就是同一个 a、不同的 b。换平面位置不等于换了概念方向。



原文图1(b)，来自作者源码中的fig.png，未重绘。红、蓝平面使用相同的A、不同的赋值。来源：Rajendran等，arXiv:2402.09236v2，CC BY 4.0。

1.3 线性独立不等于正交，更不等于统计独立

取

$$a_1 = (1,1,0)^\top, \qquad a_2 = (0,1,1)^\top.$$

它们线性独立，但 $a_1^\top a_2 = 1 \neq 0$。若 $z \sim \mathcal{N}(0, I)$，则

$$\mathrm{Cov}(a_1^\top z, a_2^\top z) = a_1^\top a_2 = 1.$$

因此概念求值可以相关。论文不要求各原子求值相互独立。

这里的“原子”是论文的数学名称，表示一维线性测量，**不是自动发现的自然语言最小语义单位。**

1.4 为什么能把非轴对齐概念变成坐标?

把上述 $a_1^\top, a_2^\top$ 和第三个补充行叠起来：

$$T = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix}, \qquad y = Tz.$$

$\det T = 1$，所以可逆。此时

$$y_1 = a_1^\top z, \quad y_2 = a_2^\top z, \quad y_3 = z_3.$$

第一、二个概念在 y 坐标中就是前两个坐标轴。一般情形下，线性独立的 n 个行向量可以补成一个可逆 $d_z \times d_z$ 矩阵。

这只是一种**选择坐标的规范化。**不代表算法已经知道 T，也不代表概念的欧氏几何是坐标无关的。

1.5 伪逆：从概念改变量得到最小激活改变量

若 $A \in \mathbb{R}^{k \times d}$ 满行秩，则

$$A^+ = A^\top (AA^\top)^{-1}.$$

例如

$$A = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix}, \quad AA^\top = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \quad (AA^\top)^{-1} = \frac{1}{3}\begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}.$$

希望概念值改变 $d=(1,2)^\top$，则

$$(AA^\top)^{-1}d=(0,1)^\top,\qquad A^+d=(0,1,1)^\top.$$

检验：$A(0,1,1)^\top=(1,2)^\top$。

所有解为

$$\eta=(0,1,1)^\top+t(1,-1,1)^\top.$$

因为两部分正交，$\|\eta\|^2=2+3t^2$，最小值在 $t=0$。第09章会给出一般证明。

1.6 高斯相乘：目标值不是筛选后均值

一维基准 $p(z)=\mathcal{N}(0,1)$，用 $q(z-b)=\mathcal{N}(z-b;0,\sigma^2)$ 筛选：

$$p_C(z)\propto\exp\left[-\frac{z^2}{2}-\frac{(z-b)^2}{2\sigma^2}\right].$$

展开并配方：

$$z^2+\frac{(z-b)^2}{\sigma^2}=\frac{1+\sigma^2}{\sigma^2}\left(z-\frac{b}{1+\sigma^2}\right)^2+\frac{b^2}{1+\sigma^2}.$$

所以

$$p_C=\mathcal{N}\left(\frac{b}{1+\sigma^2},\frac{\sigma^2}{1+\sigma^2}\right).$$

当 $b=1,\sigma=1$ 时，筛选后均值是 $1/2$，不是1。若基准分布在目标附近概率很小，先验会把后验拉回去。

1.7 密度比为什么比密度更好用?

等维可逆光滑变换 $x=f(z)$ 给出

$$p_X^e(f(z))=\frac{p_Z^e(z)}{|\det Df(z)|}.$$

同一个 f 用于所有环境，因此

$$\log \frac{p_X^0(f(z))}{p_X^e(f(z))} = \log \frac{p_Z^0(z)}{p_Z^e(z)}.$$

公共Jacobian项消掉了。若 $d_x > d_z$，应在观测流形上使用体积测度；满秩嵌入的体积因子为

$$J_f(z) = \sqrt{\det(Df(z)^\top Df(z))}.$$

贯穿例子中，直接求导可得

$$Df(z)^\top Df(z) = \begin{bmatrix} 1 + 4z_1^2 + \cos^2 z_1 & 2z_1 & 0 \\ 2z_1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix},$$

其行列式为 $1 + \cos^2 z_1$。这个因子同样会从两个环境的密度比中消失。

条件提醒： 分母密度须为正；单射可微并不自动保证逆映射可微或Jacobian处处满秩。原文证明涉及这些正则性时，第11章会单独提示。

1.8 左零空间到底是什么?

对 $H \in \mathbb{R}^{(n+1)\times n}$，若秩为 n，则

$$\{w : w^\top H = 0\}$$

是一维空间。列向量位于 $\mathbb{R}^{n+1}$ 中，共同张成一个 n 维超平面；w 就是其法向量。

若 $H_1 = H_2 J$ 且 J 可逆，两者列空间相同，所以左零空间相同。主定理最后一步会利用同一个法向量，比较两个矩阵中仅有的坐标差异。

1.9 为什么“非零多项式的零点集测度为零”？

【补充推导】 一维非零多项式只有有限个根。多维时，把多项式视作关于最后一个变量的多项式，其系数是前面变量的多项式。除去所有系数同时为零的低维例外集，每条垂直直线上只有有限个根；归纳加Fubini定理给出零点集的Lebesgue测度为零。

注意这依赖“多项式不是恒等于零”。例如 $\det(\mathrm{Diag}(z)-C)$ 的最高次项 $z_1\cdots z_n$ 系数为1，所以它不是零多项式。

“几乎处处成立”也不等于处处成立。主证明最后要用连续性，从稠密的正常点延拓到例外点。

02 | 模型、概念条件分布与可识别性：正文§3，公式(1)–(8)

2.1 先分清三个不同对象

$$\underbrace{a_i}_{\text{潜空间中的测量方向}}, \qquad \underbrace{b_i}_{\text{筛选时选择的目标值}}, \qquad \underbrace{s_i(x) = a_i^\top f^{-1}(x).}_{\text{观测上的概念求值函数}}$$

学习目标最重要的是第三个对象。只报告一个向量 a_i 不够，因为潜空间坐标本身没有被固定。

【原文】定义1： 一般概念是线性映射 $A : \mathbb{R}^{d_z} \to \mathbb{R}^{d_C}$。赋值 $b \in \mathbb{R}^{d_C}$ 对应集合 $Az = b$。定义2把 $d_C = 1$ 的概念叫原子。

【原文】假设1： f 单射且可微。单射保证在像集上可以谈论 $f^{-1}(x)$。不要把这读成 f 是线性函数，也不要把 f^{-1} 默认当成已经训练好的编码器。

原文提到用 A^+ 左乘，把约束改写成投影形式。若 A 满行秩，$Az = b$ 与 $A^+Az = A^+b$ 的几何解集确实相同。但**几何约束等价不等于筛选噪声模型不变**：一般线性变换会改变噪声协方差，不能一边改测量坐标，一边仍假定所有新坐标上的噪声独立且同方差。

2.2 公式(1)：从含噪测量到贝叶斯筛选

假设观测到的是概念的含噪数值：

$$\tilde{b} = a^\top z + \epsilon, \qquad \epsilon \perp z, \qquad \epsilon \sim q.$$

给定 z，$\tilde{b}$ 在 b 处的条件密度为 $q(b - a^\top z)$。贝叶斯公式给出

$$p(z \mid \tilde{b} = b) = \frac{p(z)q(b - a^\top z)}{\int p(u)q(b - a^\top u)\, du}.$$

这就是公式(1)的完整归一化形式。原文只写“正比于”。若 q 对称，可把参数改写成 $a^\top z - b$。

连续随机变量满足 $P(\tilde{b} = b) = 0$ 并不妨碍这里的条件密度；它不是用两个点概率相除。可以通过联合密度、正则条件分布或小区间极限理解。

2.3 公式(2)：多维概念

假设多个测量噪声相互独立，则

$$w_e(z) = \prod_{k=1}^{d_e} q\big((A^e z - b^e)_k\big), \qquad N_e = \int p^0(z) w_e(z)\, dz,$$

$$\boxed{p^e(z) = \frac{p^0(z) w_e(z)}{N_e}}.$$

这里需要 $0 < N_e < \infty$。高斯 q 有界且处处正，配合概率密度 p^0 可满足这一点。

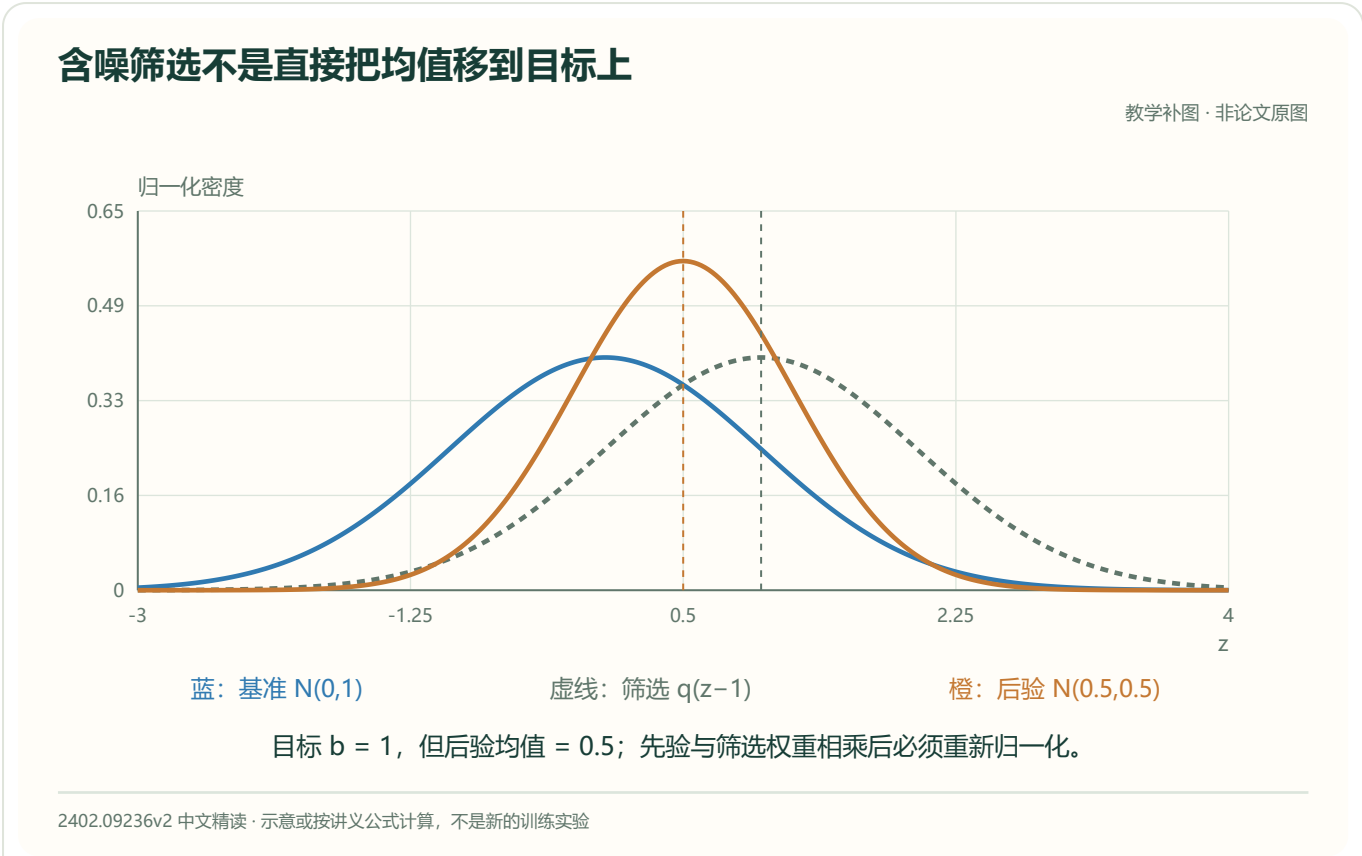
筛选所改变的不是生成映射 f，而是潜空间各处被抽取的概率。所有环境共享同一个 f，这是之后密度比能消掉体积项的关键。

一个完整的一维数值计算

取 $p^0 = \mathcal{N}(0,1)$，$q = \mathcal{N}(0,1)$，$b = 1$。

$$N = \int \frac{e^{-z^2/2}}{\sqrt{2\pi}} \frac{e^{-(z-1)^2/2}}{\sqrt{2\pi}}\, dz = \frac{e^{-1/4}}{\sqrt{4\pi}}.$$

所以筛选后是 $\mathcal{N}(1/2, 1/2)$。



教学补图2-1：按本节公式计算的三条密度曲线。筛选中心与后验均值不同；图中的橙色曲线已经归一化。

其对数密度比为

$$\log \frac{p^1(z)}{p^0(z)} = -\frac{1}{2}(z-1)^2 - \frac{1}{2}\log(2\pi) - \log N = -\frac{1}{2}z^2 + z - \frac{1}{4} + \frac{1}{2}\log 2.$$

当 $z=0$ 时，logit为 $-1/4 + (\log 2)/2 \approx 0.09657$；当 $z=1$ 时为 0.59657。两者之差恰为 $1/2$。

2.4 公式(7)(8)：为什么定义M和B?

【原文】假设2： 存在 n 个线性独立原子 a_i，每个 A^e 都从它们中选若干行，而且所有原子至少出现一次。

令 $s_i(z) = a_i^\top z$。使用共同高斯筛选噪声 σ^2 时：

$$M_{ei} = \begin{cases} \sigma^{-2} & i \in S^e \\ 0 & i \notin S^e, \end{cases} \qquad B_{ei} = \begin{cases} b^e_{k(i,e)}\sigma^{-2} & i \in S^e \\ 0 & i \notin S^e. \end{cases}$$

展开高斯指数：

$$-\frac{(s_i-b)^2}{2\sigma^2}=-\frac{s_i^2}{2\sigma^2}+\frac{bs_i}{\sigma^2}-\frac{b^2}{2\sigma^2}.$$

从而得到贯穿所有证明的式子：

$$\boxed{r_e(x):=\log\frac{p_X^e(x)}{p_X^0(x)}=-\frac{1}{2}\sum_i M_{ei}s_i(x)^2+\sum_i B_{ei}s_i(x)+c_e.}$$

其中

$$c_e=-\log N_e-\sum_{i\in S^e}\left(\frac{1}{2}\log(2\pi\sigma^2)+\frac{(b_i^e)^2}{2\sigma^2}\right).$$

这也是引理2的推导。证明部分常用相反符号 $g_e=-r_e$。**不要把符号相反的两个函数混着求梯度。**

贯穿例子的环境函数

略去与 z 无关的常数，有

$$g_1=\frac{1}{2}z_1^2,\qquad g_2=\frac{1}{2}z_2^2,$$

$$g_3=\frac{1}{2}z_1^2+\frac{1}{2}z_2^2-z_1-2z_2.$$

基准分布可以复杂、相关、多峰，但这些对数密度比仍是概念值的简单二次函数。这才是作者绕开复杂生成过程的方式。

2.5 公式(3)–(6)：究竟允许哪些不确定性?

想象学习出两个概念数值 s_1,s_2。另一套同样解释所有环境的模型，可能把它们叫成相反顺序，也可能把“温度”改为不同单位和零点。

最清楚的原子级表述是

$$\tilde{s}_{\pi(i)}(x)=\lambda_i s_i(x)+c_i,\qquad \lambda_i\neq 0.$$

这里 π 是原子置换；λ_i 是尺度/符号；c_i 是偏移。它比“任意可逆线性混合”更强：原子不会随意旋转成别的原子的混合。

同时，潜表示坐标本身仍可作一般可逆线性变换。若 $\tilde{z} = Tz$，则

$$\tilde{a} = T^{-\top} a, \qquad \tilde{a}^\top \tilde{z} = a^\top z.$$

所以“测量向量长什么样”不是坐标不变的；真正要比较的是求值函数。

一个明确的尺度与平移例子

$$\tilde{s}_1 = 2s_2 + 3, \qquad \tilde{s}_2 = -s_1 + 1.$$

知道这些变换后，所有原子数值都可以相互换算，语义信息并没有损失。反之，只知道 $\tilde{s}_1 = s_1 + s_2$、$\tilde{s}_2 = s_1 - s_2$ 可恢复整体子空间，却没有恢复逐原子的对应关系。

赋值也必须按同样方式变换

若 $\tilde{s}_i = \lambda_i(s_i + d_i)$，则 $s_i = b_i$ 对应

$$\boxed{\tilde{b}_i = \lambda_i(b_i + d_i).}$$

如果同时变换高斯筛选噪声，则应有 $\tilde{\sigma}_i^2 = \lambda_i^2 \sigma_i^2$。

【核对提醒】 原文(3)用了 $+w$，(4)的赋值关系却写 $-A^e w$，(31)与(32)也有正负不一致。按同一平移约定计算，赋值必须与求值同向变换。第04、11章有手算核对；不要把两个符号都当作可以同时成立。

2.6 为什么不能识别所有无关坐标?

贯穿例子只筛选 z_1, z_2。令

$$\tilde{z} = (z_1, z_2, z_3 + z_1^2), \qquad \tilde{f} = f \circ \varphi^{-1}.$$

这是可逆且非线性的坐标变化，前两个概念值完全没变，所有环境的观测分布也没变。因此仅凭这些环境，无法判定第三个坐标究竟应是 z_3 还是 $z_3 + z_1^2$。

这是**部分可识别性**，不是缺陷。学习任务只要求识别目标概念。

但不要把“只识别 n 个概念”误读为“可用 $n < d_z$ 个连续坐标无损重建整个观测流形”。对可逆光滑表示来说，其他自由度仍须存在；对比网络输出的 n 个概念特征不是完整可逆编码。

2.7 概念条件数据与因果干预的第一次区分

条件筛选可能改变未被筛选的变量分布，因为基准变量之间可以相关。

例如 $z_2 = z_1 + \epsilon$。选择较大的 z_2，会让样本中的 z_1 也变大；但执行 $\mathrm{do}(z_2 = b)$ 不会反向改变原因 z_1。本文的 $p^e \propto p^0 q$ 是前一种数据生成方式。

因此，本章证明“概念值能识别”不等于证明“概念间因果方向能识别”。第08章会把三种分布构造完整算出来。

03 | 五个假设、两个可识别性定理与引理1

3.1 五个假设分别排除什么困难?

假设	数学内容	作用/局限
1	f 单射、可微	保留潜变量信息；证明中的光滑逆还需额外注意
2	原子线性独立，环境选取共享原子子集，全部原子出现	允许将原子变成坐标；不是所有语义概念都满足
3	筛选噪声是高斯	让对数密度比成为二次式；不是基准潜分布为高斯
4	$\operatorname{rank} M = n$，存在 $v^\top M = 0$ 且 $(v^\top B)_i \neq 0$	环境组合可消去二次项，并保留每个概念的一次信号
5	对每个有序对 $i \neq j$，有环境包含 i 而不包含 j	能通过环境组合孤立某一概念方向

假设4和5是两种不同的多样性，不能用“数据够多”一句话代替。

3.2 用贯穿例子检查假设4



教学补图3-1：M表示筛选支持，B表示目标乘精度。按三行作线性组合时，二次项抵消，一次信号仍保留。

$$M = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}, \quad B = \begin{bmatrix} 0 & 0 \\ 0 & 0 \\ 1 & 2 \end{bmatrix}, \quad v = \begin{bmatrix} -1 \\ -1 \\ 1 \end{bmatrix}.$$

显然 M 的前两行独立，所以秩为2。并且

$$v^\top M = -(1,0) - (0,1) + (1,1) = (0,0),$$

$$v^\top B = (1,2).$$

两个分量都非零，因此满足假设4。

将环境函数按 v 组合，二次项消失：

$$-g_1 - g_2 + g_3 = -z_1 - 2z_2 + \text{常数}.$$

这解释了假设4的设计目的。但这一条线性组合只给出一个线性测量，**还不足以单独解出两个未知数**；不能在这里就声称证明完成了。

3.3 一个适用于任意n的环境构造

设置 n 个单原子环境，加一个包含全部原子的环境：

$$M = \begin{bmatrix} I_n \\ \mathbf{1}^\top \end{bmatrix}, \qquad v = (-1, \ldots, -1, 1)^\top.$$

前 n 个环境目标都设为0，最后环境的各目标设为非零 b_i，则

$$v^\top B = (b_1, \ldots, b_n).$$

单原子环境提供假设5要求的分离；最后一个多原子环境提供额外的一次变化。条件环境数为 $m = n + 1$，加基准环境后总数为 $n + 2$。

注意：$n + 2$不是样本数，也不是任意挑出$n + 2$个数据集就成立。

3.4 哪些环境会失败?

失败A：两个原子总是一起出现

若每行都是 $(1,1)$，则 M 秩为1，无法区分两个原子的筛选签名；假设4、5都失败。

失败B：有覆盖，但目标值没有有效变化

保留贯穿例子的 M，却把所有目标都设为0，则 $B=0$，任何 v 都给出 $v^\top B=0$。只看平方项时存在符号对称，无法用作者的主证明消除这类歧义。

失败C：仅“出现模式不同”还不够满足假设5

若原子1出现于环境 $\{1\}$，原子2出现于环境 $\{1,2\}$，两列不相同，但不存在“包含1而不包含2”的环境。假设5要求每个方向都能分离，强于列不相同。

每个原子必须至少有两次有效出现

若原子 i 只在一个环境 e 出现，则 $v^\top M=0$ 强迫 $v_e=0$，于是 $(v^\top B)_i=0$。更一般地，若它每次出现的目标都相同，则 $B_{:i}$ 与 $M_{:i}$ 成比例，也会失败。

这一观察是核对附录F实验构造的重要工具。

3.5 引理1：为什么一般位置的目标值通常足够?

【原文】 当 $m=n+1$，M 任意 n 行都线性独立，且环境赋值独立地从连续分布抽取时，假设4几乎必然成立。

【完整证明】

1. M 列秩为 n，所以 $\ker M^\top$ 维数为 $(n+1)-n=1$。存在非零 v，且只在乘非零标量的意义下唯一。原文“唯一一个向量”应如此理解。
2. 若某个 $v_e=0$，删去该行后，剩余 n 行的非平凡线性组合等于0，与其独立性矛盾。因此每个 $v_e\neq 0$。
3. 固定原子 i，有

$$(v^\top B)_i=\sum_{e:i\in S^e} v_e\frac{b_i^e}{\sigma^2}.$$

至少有一个非零系数。给定其他目标后，这个表达式为0只要求某个连续随机变量恰等于一个固定值，概率为0。

4. 原子只有有限个，有限个零概率坏事件的并集仍是零概率。因此所有分量同时非零，概率为1。

条件提醒： “连续分布”若仅指向量分布无原子，仍可能集中在超平面上；严格使用此证明时应要求相应线性组合无原子，例如联合分布对Lebesgue测度绝对连续。

3.6 定理1：主要结果

【原文】 五个假设成立时，概念按定义4可识别。

教学上的核心结论是：两套满足模型约束并产生相同环境分布的参数，其目标概念求值函数只能相差原子的置换、非零尺度和偏移。无关潜方向不要求被识别。

证明分五步：

1. 选坐标，把原子变成坐标轴、筛选方差变成1，固定平移与符号。
2. 从观测分布得到对数密度比函数。
3. 从其极小集的维度识别环境使用哪些原子，即 M。
4. 从受限极小值差识别环境目标距离，进而识别 B。
5. 比较两套表示的Jacobian，用左零空间证明概念坐标一致。

【核对提醒】 定义4的赋值平移公式存在符号不一致；全空间极小集和可微过渡映射也涉及正文未充分明确的支撑与正则条件。本手册会在一致的符号与适用条件下解释证明路线，不把原文按字面无条件地包装成一个已经形式化核验的定理。

3.7 定理2：环境更多时的热身结果

令

$$\Lambda = (M, B) \in \mathbb{R}^{m \times 2n}.$$

【原文】 假设1–3成立，已知原子数 n，且 $\operatorname{rank} \Lambda = 2n$，则可识别。

由于矩阵有 $2n$ 列，至少需要 $m \geq 2n$ 个条件环境，即总共 $2n + 1$ 个环境。这个定理允许每个原子在不同环境使用不同高斯筛选方差。

它使用充分统计量

$$(s_1^2, \ldots, s_n^2, s_1, \ldots, s_n)$$

的满秩变化；主定理则利用了更特殊的筛选几何，降低所需的环境数。

两条路线不是处处互相包含

主定理允许在其特定结构下用更少环境；定理2允许更自由的环境相关方差，也不使用同样的分离假设。因此不要简单概括为“定理1在每个假设上都严格弱于定理2”。

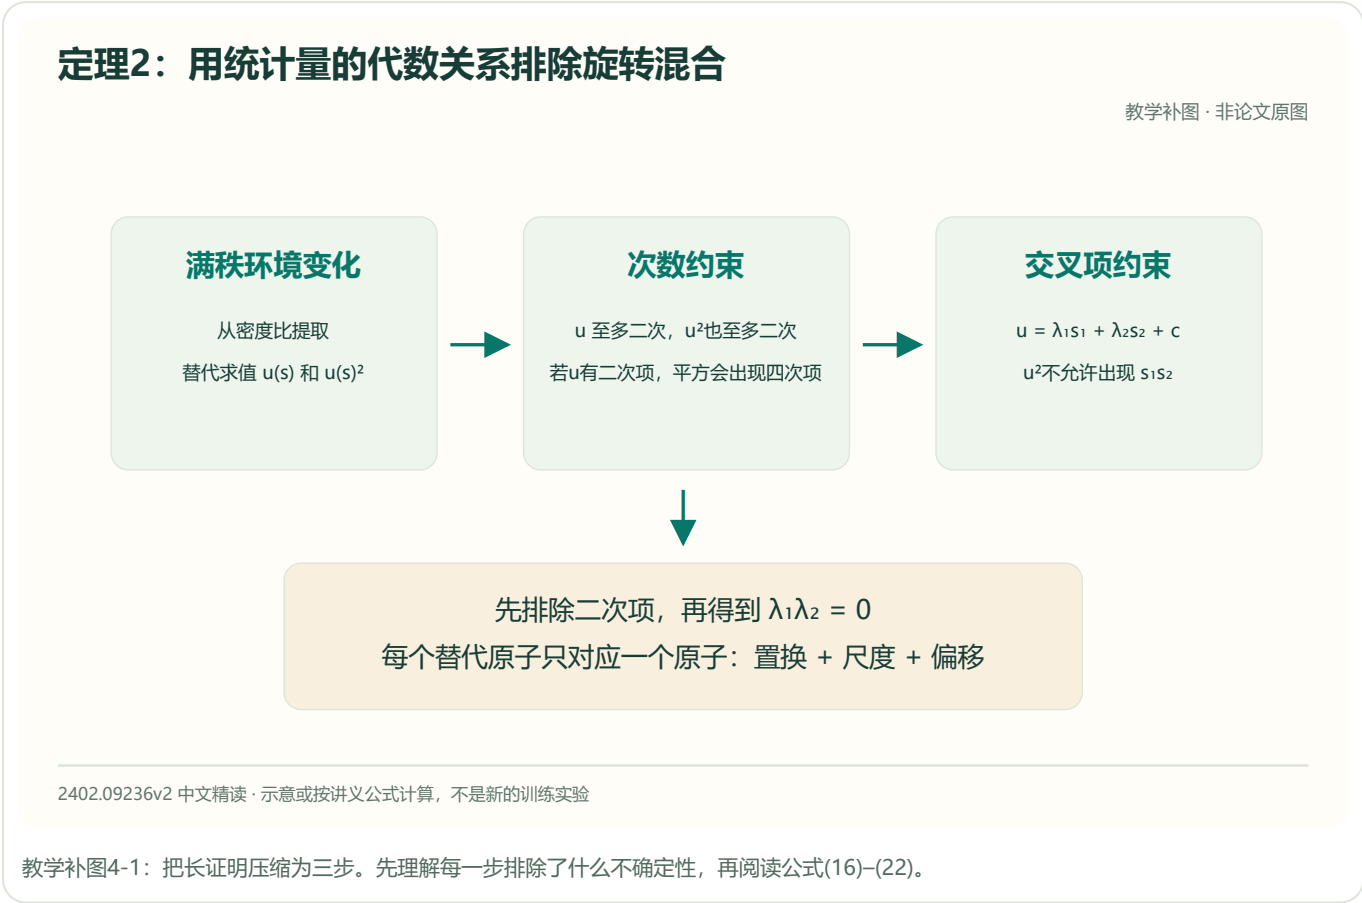
3.8 “近乎最优”如何理解?

由假设4推出 $m \geq n+1$，仅说明**这套充分条件**至少要求这么多环境。它不是对所有可能方法、所有信息设定的统一下界证明。作者也提到总共 $n+1$ 个环境在某些合适条件下可能足够。

同样，论文用 $O(d_z)$ 描述此前若干CRL设定的环境要求，不是“所有CRL永远需要d_z次干预”的普适定理。

04｜定理2的完整推导：附录A.1，公式(9)–(32)

这一证明的主线只有一句话：**先把每个替代概念求值写成二次多项式，再用“它的平方仍然只能是二次多项式”排除所有二次项和坐标混合。**



教学补图4-1：把长证明压缩为三步。先理解每一步排除了什么不确定性，再阅读公式(16)–(22)。

以下讨论在密度比有定义、相关概念值覆盖足够大的开集、过渡与换元合法的情形下展开。涉及全局表示时采用光滑嵌入/可微过渡等标准正则条件；第11章解释为何不应忽略这些条件。

4.1 公式(9)(10)：可变筛选方差

环境 e 中原子 i 的筛选方差可以为 $(\sigma_i^e)^2$，于是

$$M_{ei} = \frac{\mathbf{1}_{i \in S^e}}{(\sigma_i^e)^2}, \qquad B_{ei} = \frac{\mathbf{1}_{i \in S^e} b_i^e}{(\sigma_i^e)^2}.$$

原文用行号 k 标记该环境内的原子，这里改用共享原子编号 i，避免行索引混乱。

4.2 公式(11)(12)：同一数据分布带来的等式

比较两套参数 (f, p, a_i) 与 $(\tilde{f}, \tilde{p}, \widetilde{a}_i)$。令

$$\varphi = \tilde{f}^{-1} \circ f, \qquad \widetilde{z} = \varphi(z).$$

在等维可逆可微条件下，正确换元为

$$p^e(z) = \tilde{p}^e(\varphi(z)) |\det D\varphi(z)|.$$

【核对提醒】 原文(11)将这一侧的Jacobian写成逆映射的Jacobian。这里写出正确版本；核心是它对所有环境相同，随后会被抵消。

对基准与环境分别取对数再相减：

$$\log p^0(z) - \log p^e(z) = \log \tilde{p}^0(\widetilde{z}) - \log \tilde{p}^e(\widetilde{z}).$$

也可以直接用密度比在可逆变换下不变来证明，避免记忆换元行列式的方向。

4.3 公式(13)–(15)：把环境函数组织成向量

设 $s_i = a_i^\top z$，$\widetilde{s}_i = \widetilde{a}_i^\top \widetilde{z}$，记 $s^{\odot 2} = (s_1^2, \ldots, s_n^2)^\top$。

$$g(z) = \frac{1}{2} M s^{\odot 2} - B s + \kappa,$$

$$\frac{1}{2} M s^{\odot 2} - B s + \kappa = \frac{1}{2} \widetilde{M} \widetilde{s}^{\odot 2} - \widetilde{B} \widetilde{s} + \widetilde{\kappa}.$$

原文(14)(15)省略了环境常数。本手册保留 κ；之后所得多项式应允许常数项。忽略它们不改变次数论证，但不能把未归一化表达式当作相等的归一化密度。

定义

$$t(s) = \begin{bmatrix} s^{\odot 2} \\ s \end{bmatrix}, \qquad L = \begin{bmatrix} \frac{1}{2} M & -B \end{bmatrix}.$$

$\operatorname{rank} L = 2n$ 与 $\operatorname{rank}(M, B) = 2n$ 等价。

为什么替代模型的系数也可看作满秩?

原文证明直接对替代系数矩阵使用满秩。可补充的理由是：当原子线性独立、概念值覆盖开集时，$1, s_i, s_i^2$ 作为函数线性独立。环境函数模常数后的线性张成维数恰等于系数矩阵的秩。同一组观测密度比在两套表示中张成维数相同，而已知 n，所以替代矩阵也必须有秩 $2n$。

这一补充依赖支持集足够丰富；不能在仅有有限样本点时直接这么推理。

4.4 公式(16)：提取一个替代概念求值

因为 $\widetilde{L}$ 满列秩，它存在左逆。等价地，可以选择环境线性组合 v 满足

$$v^\top \widetilde{M} = 0, \qquad v^\top \widetilde{B} = -e_i^\top.$$

左乘环境向量等式得到

$$\tilde{s}_i = \frac{1}{2} v^\top M s^{\odot 2} - v^\top B s + c_i.$$

因此 $\tilde{s}_i$ 是 s 的至多二次多项式。关键是没有任何 $s_j s_k$ 的交叉项。

4.5 公式(17)：再提取它的平方

同理，选 v' 使

$$\frac{1}{2} v'^\top \widetilde{M} = e_i^\top, \qquad v'^\top \widetilde{B} = 0,$$

则

$$\tilde{s}_i^2 = \sum_j \eta_j s_j^2 + \ell(s),$$

其中 ℓ 为仿射函数。所以 $\tilde{s}_i^2$ 也只能是至多二次。

4.6 公式(18)：为什么二次项全部消失?

设 $\tilde{s}_i = P_2(s) + P_1(s) + c$，其中 P_2 是齐次二次项。它的平方中最高次部分为 $P_2(s)^2$，次数为4。

若 P_2 非零，实多项式 P_2^2 也非零，不可能与某个二次多项式在开集上恒等。因此 $P_2 = 0$，得到

$$\tilde{s}_i = \sum_j \lambda_j s_j + c_i.$$

这个论证用的是函数恒等式，不是“有限数据上看上去拟合得不错”。有限多个点完全可能同时被不同次数的函数拟合。

4.7 公式(19)–(21)：为什么不能混合两个原子?

把仿射式平方：

$$\tilde{s}_i^2 = \sum_j \lambda_j^2 s_j^2 + 2\sum_{j<k} \lambda_j \lambda_k s_j s_k + 2c_i \sum_j \lambda_j s_j + c_i^2.$$

而上一步的平方表达式没有交叉项，所以

$$\lambda_j \lambda_k = 0 \qquad (j \neq k).$$

每行最多只有一个非零 λ_j。这比原文(19)(20)的梯度比较更容易看清；两者完全同源。

原文梯度路线为：比较

$$2\sum_j \eta_j a_j (a_j^\top z) + w = 2\left(\sum_j \lambda_j a_j\right)\left(\sum_j \lambda_j a_j^\top z\right) + w'.$$

先令 $z = 0$ 得 $w = w'$，再利用 a_j 独立，逐个比较系数，得到

$$\eta_r a_r = \lambda_r \sum_j \lambda_j a_j.$$

若 $\lambda_r \neq 0$，其他 λ_j 必为0。替代原子不能是常值函数，因此恰有一个非零项。

两维手算

若假设 $\tilde{s}_1 = 2s_1 + 3s_2 + 1$，平方中会出现 $12 s_1 s_2$。但所有环境线性组合只能产生 $s_1^2, s_2^2, s_1, s_2, 1$。矛盾。若是 $\tilde{s}_1 = 2s_1 + 1$，则没有这个矛盾。

4.8 公式(22)–(26)：逐原子对应提升为整体等价

由反向使用同样论证，两个替代原子不能都只对应同一个原子，否则不能恢复全部 n 个独立概念。因此形成一个置换：

$$\tilde{s}_{\pi(i)} = \lambda_i s_i + c_i.$$

线性独立的原子可以分别补成基，所以存在一个可逆线性坐标映射把两套原子协向量对应起来，这对应原文(23)(25)。该 T 只负责在潜坐标中表示原子，不意味着整个过渡函数 φ 在无关方向也必须线性。

因为原子矩阵满行秩，总可以解出一个公共 w 满足 $a_i^\top w = c_i/\lambda_i$，于是

$$\tilde{s}_{\pi(i)} = \lambda_i (s_i + a_i^\top w).$$

把环境中使用的原子堆叠，即得到原文(26)形式的求值关系。

4.9 公式(27)–(32)：仔细核对目标值与噪声

把其他概念坐标固定，仅让一个 s 变化。对应的高斯二次能量必须相差常数：

$$\frac{(s-b)^2}{2\sigma^2} = \frac{(\lambda s + c - \tilde{b})^2}{2\tilde{\sigma}^2} + K.$$

比较 s^2 系数：

$$\frac{1}{\sigma^2} = \frac{\lambda^2}{\tilde{\sigma}^2} \quad \Longrightarrow \quad \tilde{\sigma}^2 = \lambda^2 \sigma^2.$$

比较 s 系数：

$$-\frac{b}{\sigma^2} = \frac{\lambda(c - \tilde{b})}{\tilde{\sigma}^2} \quad \Longrightarrow \quad \boxed{\tilde{b} = \lambda b + c.}$$

若 $c = \lambda a^\top w$，则 $\tilde{b} = \lambda(b + a^\top w)$。这与原文(32)的加号一致，与(31)和定义4相应位置的减号不一致。

【数值核对】 取 $\tilde{s} = 2(s+3)$，$b = 5, \sigma = 1$。正确目标是 $\tilde{b} = 16$，$\tilde{\sigma} = 2$。在 $s = 4$ 时，两边标准化残差都是 -1。若误用 $2(5-3) = 4$，替代残差为5，立即出错。

4.10 证明结束后，真正得到什么？

在所需支持与正则条件下，每个概念求值函数只差置换、尺度、平移；并不是识别整个非线性混合，也不是识别因果结构。

这条证明展示了一个可迁移的套路：**设计环境，让可观测密度比中的充分统计量线性满秩，再利用这些统计量的代数关系压缩可识别等价类。**

05 | 主定理上半场：标准化、识别M与B，公式(33)–(55)

本章解决“如果不知道哪个环境筛选哪个原子，也不知道目标值，怎样先把这些结构确定下来？”

阅读条件： 本章沿着原文使用全潜空间极小集的路线，采用基准密度在相关全空间为正、生成映射为光滑嵌入、过渡函数足够光滑的工作条件。若支持集截断或逆映射不可微，不应直接套用这些步骤；见第11章。

5.1 Step 1：把原子变成坐标，公式(33)–(43)

主定理的附录允许原子 i 有自己的筛选标准差 σ_i，但同一个原子在各环境使用相同标准差。正文的共同 σ 是特例。

令 $H_{ei} = \mathbf{1}_{i \in S^e}$。原文的矩阵为

$$M_{ei} = H_{ei}/\sigma_i^2, \qquad B_{ei} = H_{ei} b_i^e/\sigma_i^2.$$

选择可逆矩阵 T，其前 n 行为 $a_i^\top$，等价于 $T^{-\top} a_i = e_i$。令

$$\Sigma = \mathrm{Diag}(\sigma_1, \dots, \sigma_n, 1, \dots, 1),$$

$$y = L(z) = \Sigma^{-1} T z - \ell.$$

为避免与后续尺度 λ_i 混淆，本章把原文用于平移的 λ 写成 ℓ。于是对 $i \le n$：

$$y_i = \frac{a_i^\top z}{\sigma_i} - \ell_i, \qquad \overline{b}_i^e = \frac{b_i^e}{\sigma_i} - \ell_i.$$

关键核对是

$$y_i - \overline{b}_i^e = \frac{a_i^\top z - b_i^e}{\sigma_i}.$$

所以筛选指数完全相同，标准化后所有噪声方差为1，原子为坐标测量。

基准密度如何变？对应(36)

生成映射改为 $\overline{f} = f \circ L^{-1}$，基准密度必须用正确换元：

$$\overline{p}(y) = p(L^{-1}(y))|\det(T^{-1}\Sigma)|.$$

原文(36)少了 Σ 的行列式因子。它是与 y 无关的常数，但若声称这是归一化密度，就不能遗漏。

环境矩阵如何变？对应(38)(39)

设 $D_\sigma = \mathrm{Diag}(\sigma_i)$。则

$$\boxed{\overline{M} = MD_\sigma^2 = H,}$$

$$\boxed{\overline{B} = BD_\sigma - H\,\mathrm{Diag}(\ell) = BD_\sigma - MD_\sigma^2\,\mathrm{Diag}(\ell).}$$

【核对提醒】 原文(39)写成 $BD_\sigma^{-1} - M\,\mathrm{Diag}(\ell)$，与它自身的 B 和 $\overline{b}$ 定义不符。

手算：$\sigma = 2, b = 6, \ell = 1$。原始 $M = 1/4, B = 6/4 = 1.5$，标准化目标应为 $6/2 - 1 = 2$。本式给出 $1.5 \times 2 - 1 = 2$；原文写法会给 $1.5/2 - 1/4 = 0.5$。

高斯密度的常数，对应(40)–(43)

对于归一化高斯密度，正确关系是

$$q_1\left(\frac{u-b}{\sigma_i}\right) = \sigma_i q_{\sigma_i^2}(u-b).$$

所以筛选乘积相差的是与 z 无关的正常数，归一化后的环境分布经 L 推前后相同。不能把 $-2\log q_1(t)$ 直接写成 t^2 的精确等式；还差 $\log(2\pi)$。

固定平移和符号

每个原子 i 可取

$$\ell_i = \frac{\sum_{e:i\in S^e} b_i^e/\sigma_i}{\#\{e : i \in S^e\}}.$$

这样 $\sum_e \overline{B}_{ei} = 0$，即**每一列**的均值为0。原文此处一度写“每一行”，但后文实际使用的是按列中心化。

若需要，再令某个坐标 $y_i \mapsto -y_i$，使该列第一个非零赋值为正，去掉整体反射的不确定性。

假设4为什么在标准化后仍成立?

若 $v^\top M = 0$，则 $v^\top \overline{M} = 0$。而

$$v^\top \overline{B} = v^\top B D_\sigma.$$

乘以正的非零尺度不会让原来非零的分量变零。因此假设4保留。

此后把标准化记号的横线去掉：M 为0/1矩阵，原子求值是 $z_1, \ldots, z_n$，B_{ei} 是环境目标值。

5.2 Step 2：可观测的密度比，公式(44)–(47)

定义

$$g^e(z) = \log p^0(z) - \log p^e(z) = \sum_i \left(\frac{1}{2} M_{ei} z_i^2 - B_{ei} z_i \right) + \kappa_e.$$

观测上的函数是

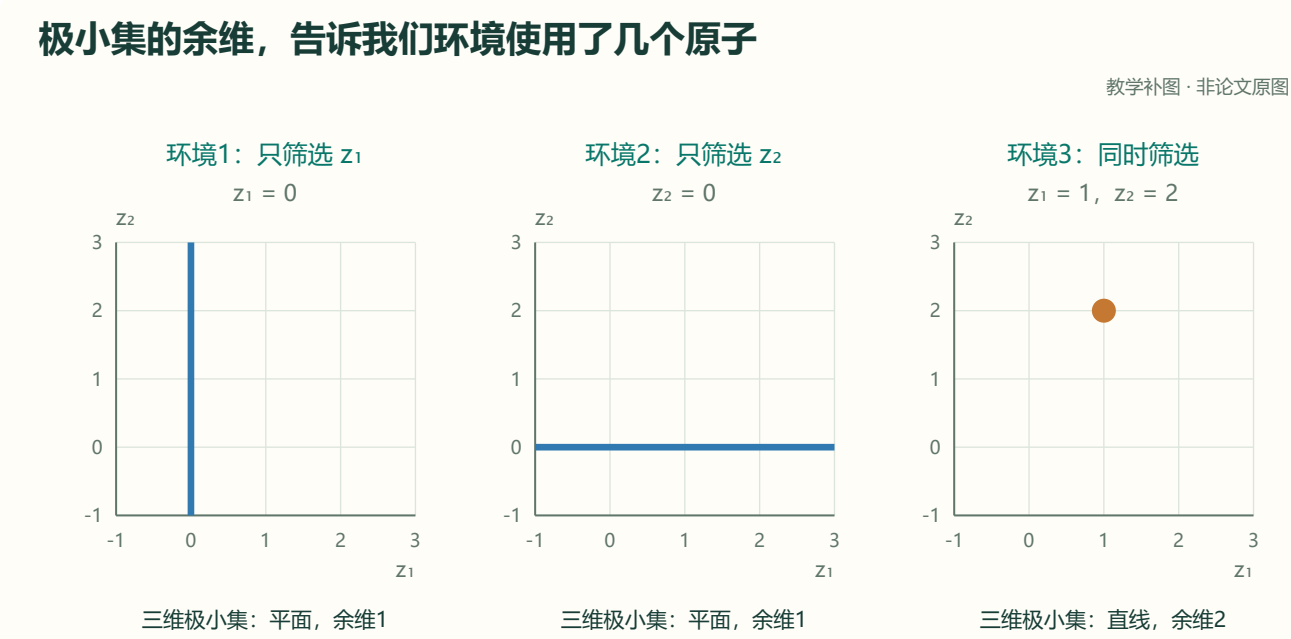
$$G^e(x) = \log p_X^0(x) - \log p_X^e(x).$$

公共生成映射消掉Jacobian，因此

$$\boxed{G^e(f(z)) = g^e(z).}$$

所谓“可识别的 G^e”是指如果知道总体分布，这个函数已经确定；不是指从有限样本中可以无误差、低成本地恢复它。

5.3 Step 3：用极小集的余维识别原子集合，公式(48)–(51)



教学补图5-1：图中只画概念坐标切片。未画的第三坐标始终自由，因此“一个点”在完整三维潜空间里其实是一条直线。

取任意环境子集 $T \subseteq [m]$，令

$$S_T = \bigcup_{e\in T} S^e, \qquad I_T = \operatorname*{argmin}_z \sum_{e\in T} g^e(z).$$

对每个坐标，把环境函数相加：

$$\sum_{e\in T} g^e(z) = \sum_i \left(\frac{1}{2}\mu_i^T z_i^2 - \nu_i^T z_i\right) + \text{常数},$$

其中 $\mu_i^T = \sum_{e\in T} M_{ei}$，$\nu_i^T = \sum_{e\in T} B_{ei}$。

- 若 $i \in S_T$，则 $\mu_i^T > 0$，唯一极小点是 $z_i^T = \nu_i^T/\mu_i^T$。
- 若 $i \notin S_T$，则 $\mu_i^T = \nu_i^T = 0$，此函数根本不依赖 z_i。

因此

$$I_T = \{z : z_i = z_i^T \text{ 对所有 } i \in S_T\}, \qquad \dim I_T = d_z - |S_T|.$$

在观测流形上同样有

$$f(I_T) = \operatorname*{argmin}_{x \in f(\mathbb{R}^{d_z})} \sum_{e \in T} G^e(x).$$

光滑嵌入保留维度，所以从极小集余维可确定 $|S_T|$。取所有环境，得到 $n = |S_{[m]}|$。

贯穿例子

环境1的极小集是 $\{z_1 = 0\}$，维数2；环境2是 $\{z_2 = 0\}$，维数2；环境3是 $\{z_1 = 1, z_2 = 2\}$，维数1。

环境1+2的极小集为 $\{z_1 = 0, z_2 = 0\}$，维数1，所以并集包含两个原子。环境1+3中 z_1 的极小值为 $1/2$，但余维仍为2：**计算并集大小关心自由度减少多少，不关心极小点位置。**

5.4 怎样从所有并集大小还原M？补全原文的组合论跳步

每个原子都有一个“出现签名”

$$U_i = \{e : i \in S^e\} \subseteq [m].$$

设 c_U 为签名恰好等于 U 的原子数，$h(T) = |S_T|$。那么

$$h(T) = \sum_{U : U \cap T \neq \varnothing} c_U.$$

进一步定义

$$F(V) = n - h([m] \setminus V).$$

$F(V)$ 数的是“只在 V 内出现”的原子，即

$$F(V) = \sum_{\varnothing \neq U \subseteq V} c_U.$$

布尔格上的容斥/Möbius反演给出

$$\boxed{c_U = \sum_{V \subseteq U} (-1)^{|U| - |V|} F(V).}$$

验证方法：将 $F(V)$ 展开；每个真子集对应的系数都是 $(1-1)^k=0$，只有 U 自身留下1。

这样得到了所有列签名，因此识别 M，只差原子列的排列。**环境标签本来就已知，不应任意置换环境行。**

这一步可能要考虑指数多个环境子集，所以它是可识别性证明，不是高效可执行算法的证明。

5.5 Step 4：隔离一个概念，公式(52)(53)

固定原子 i，令

$$T_i=\{e:M_{ei}=0\}.$$

这些环境都不使用原子 i。假设5保证：任意其他原子 j 至少在这些环境中的一个出现。因此

$$S_{T_i}=[n]\setminus\{i\}.$$

极小集 I_{T_i} 把除 z_i 外的所有目标概念坐标固定。把某个使用 i 的环境函数限制到该集合上，便只剩

$$g^e(z)=c_{T_i,e}+\frac{1}{2}z_i^2-B_{ei}z_i.$$

与 z_i 无关的无关坐标仍可自由变化，但不影响该二次函数。

5.6 公式(54)(55)：极小值差就是目标值距离

在 I_{T_i} 中进一步最小化环境 e_1，得到 $z_i=B_{e_1i}$。再考察环境 e_2：

$$\begin{aligned}&\min_{I_{T_i}^{e_1}} g^{e_2}-\min_{I_{T_i}} g^{e_2}\\&=\left[c+\frac{1}{2}B_{e_1i}^2-B_{e_2i}B_{e_1i}\right]-\left[c-\frac{1}{2}B_{e_2i}^2\right]\\&=\frac{1}{2}(B_{e_1i}-B_{e_2i})^2.\end{aligned}$$

这个值可由观测上的函数和极小集定义，所以它是可识别的。注意只比较都使用原子 i 的环境；未使用时矩阵中的0是结构占位，不是一个实际筛选目标。

为什么一维两两距离能确定全部赋值?

选择距离最远的两个目标，距离为 $D > 0$，把它们放在0与 D。对任意其他点，设到两端距离为 d_L, d_R，则其坐标

$$t = \frac{d_L^2 + D^2 - d_R^2}{2D}.$$

因为 $d_L^2 = t^2$、$d_R^2 = (D - t)^2$，相减就能解出 t。剩下只是不确定整体平移和左右反射，恰好已由标准化规则固定。

假设4保证原子有有效目标变化，所以不会出现该列所有目标都相同、$D = 0$的退化情形。

贯穿例子

对原子1，用环境2把 z_2 固定为0，再比较环境1和3，其受限极小值差为 $1/2$，识别距离1。

对原子2，用环境1固定 $z_1 = 0$，比较环境2和3，得到差值2，识别距离2。

原始赋值分别为 $\{0, 1\}$、$\{0, 2\}$。中心化后为 $\{-1/2, 1/2\}$、$\{-1, 1\}$；再选择首个非零值为正，可取

$$B_{\text{canonical}} = \begin{bmatrix} 1/2 & 0 \\ 0 & 1 \\ -1/2 & -1 \end{bmatrix}.$$

5.7 到这里还没有完成什么?

我们已经把两套等价候选的 M, B 规范到一致，但这不自动证明其 z_i 一致。它们仍可能通过非线性过渡映射产生同样的二次函数值。下一章专门排除这种剩余自由度。

06 | 主定理最后一公里：左零空间证明，公式(56)–(75)

6.1 现在已知什么，要证明什么?

两套模型已经标准化，具有相同的 M, B，目标概念都是前 n 个坐标。记

$$\varphi = \tilde{f}^{-1} \circ f, \quad z = (z^c, z^o), \quad z^c = (z_1, \ldots, z_n).$$

目标是证明

$$\pi^c \varphi(z^c, z^o) = z^c,$$

即前 n 个坐标相同。不要要求无关部分 z^o 相同。

固定一个 z^o，定义 $\psi(z^c) = \pi^c \varphi(z^c, z^o)$。$\psi$ 不必预先已知可逆；证明会在几乎所有点推出其Jacobian可逆。

6.2 公式(56)：环境密度比的函数恒等式

定义不含常数项的二次向量

$$Q(s) = \frac{1}{2} M s^{\odot 2} - Bs.$$

由于两套观测密度比相同，存在不依赖 s 的向量 d，使

$$Q(z^c) = Q(\psi(z^c)) + d.$$

原文(56)将两套环境常数也视为相同而直接写函数相等。对最后这段证明并不需要提前知道常数相同：求导会消掉 d。

6.3 公式(57)–(59)：求导得到矩阵关系

逐项求偏导:

$$\frac{\partial Q_e}{\partial z_i} = M_{ei} z_i - B_{ei}.$$

所以

$$DQ(z) = M\,\mathrm{Diag}(z) - B \in \mathbb{R}^{m\times n}.$$

由链式法则，设 $\tilde{z} = \psi(z)$：

$$\boxed{M\,\mathrm{Diag}(z) - B = [M\,\mathrm{Diag}(\tilde{z}) - B]\,D\psi(z).}$$

这是原文(59)的核心。左边 $m \times n$，右边是 $(m \times n)(n \times n)$，维度匹配。

6.4 公式(60)(61)：构造一个多一行的矩阵

因 M 满列秩，可取左伪逆

$$M^{+} = (M^{\top}M)^{-1}M^{\top}, \qquad M^{+}M = I_n.$$

再选假设4中的 v，令

$$L = \begin{bmatrix} M^{+} \\ v^{\top} \end{bmatrix}, \qquad LM = \begin{bmatrix} I_n \\ 0 \end{bmatrix}.$$

定义

$$C = M^{+}B, \quad r = v^{\top}B, \qquad H(z) = \begin{bmatrix} \mathrm{Diag}(z) - C \\ -r \end{bmatrix}.$$

其中 C 为 $n \times n$，r 为 $1 \times n$，H 为 $(n+1) \times n$。把(59)左乘 L：

$$\boxed{H(z) = H(\tilde{z})D\psi(z).}$$

现在未知坐标只出现在上半部分的对角线上；最下面一行 $-r$ 的每个分量均非零。

6.5 为什么H几乎处处满列秩?

令 $K(z) = \mathrm{Diag}(z) - C$。其行列式为多项式，最高次项是

$$z_1 z_2 \cdots z_n,$$

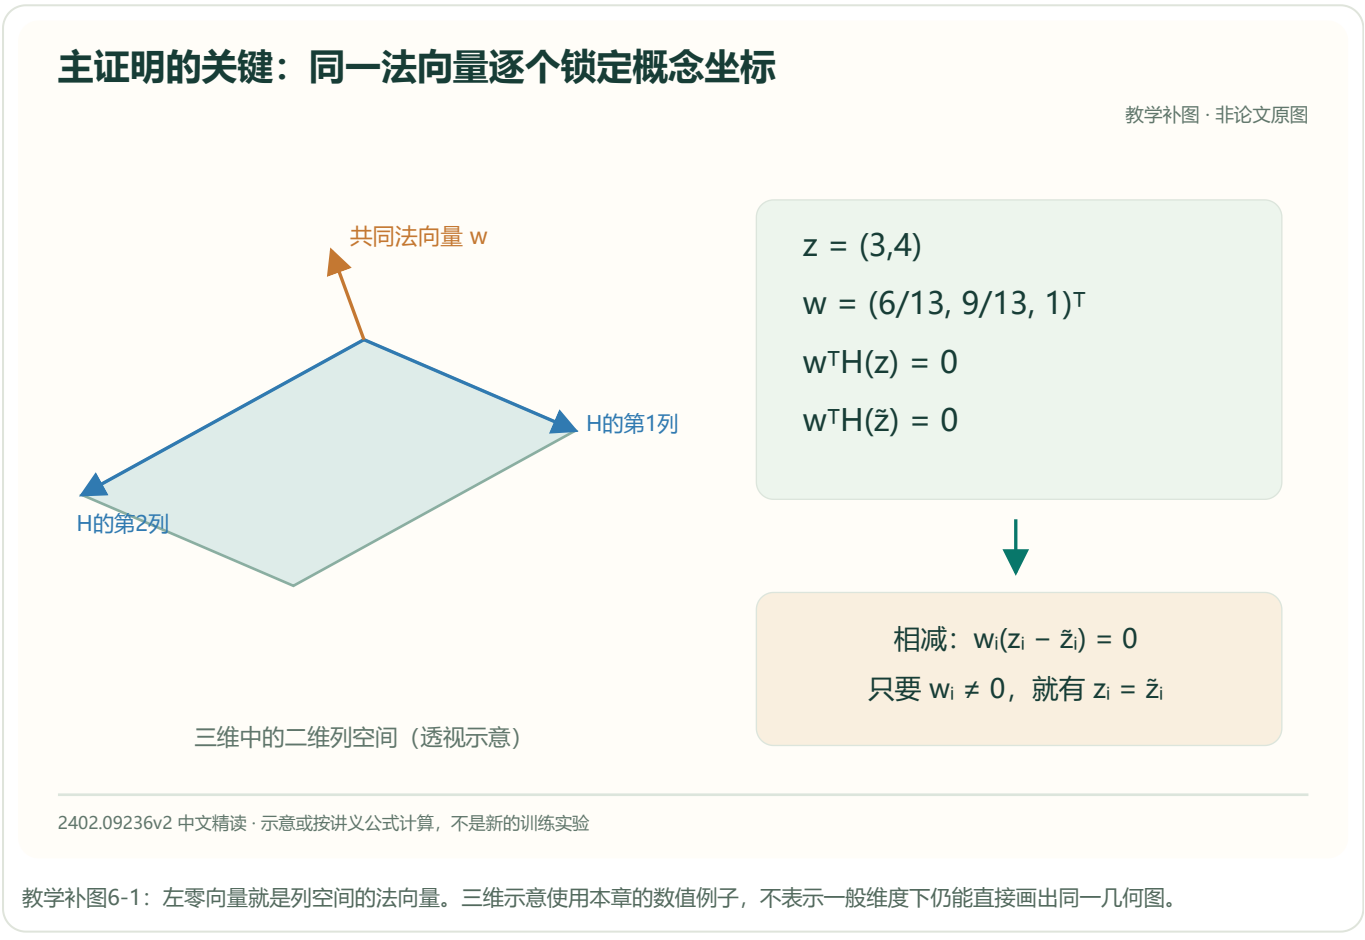
系数1。因此 $\det K$ 不是零多项式，在除一个零测集外的所有点非零。

在那里 K 可逆，H 显然秩为 n。由

$$n = \operatorname{rank} H(z) \le \operatorname{rank} D\psi(z) \le n,$$

可知 $D\psi(z)$ 可逆。我们并没有把切片上的可逆性当作假设。

6.6 公式(62)–(65)：共同左零向量及其非零分量



教学补图6-1：左零向量就是列空间的法向量。三维示意使用本章的数值例子，不表示一般维度下仍能直接画出同一几何图。

因 H 有 $n+1$ 行、秩为 n，左零空间维数为1。取非零 w：

$$w^\top H(z) = 0.$$

由 $H(z) = H(\tilde{z}) D\psi$ 且 $D\psi$ 可逆，得到

$$w^\top H(\tilde{z}) = 0.$$

还需要证明 $w_1, \ldots, w_n$ 几乎处处非零。否则下一步不能逐坐标相除。

最后一项为何非零？对应(64)

若 $w_{n+1} = 0$，则 $w_{1:n}^\top K = 0$。在 K 可逆的点，只能 $w = 0$，矛盾。因此可规范为 $w_{n+1} = 1$。

其他项为何非零？对应(65)

若 $w_i = 0$，剩下 n 个分量构成删去第 i 行后的 $n \times n$ 子矩阵的非平凡左零向量，所以该子矩阵行列式为0。

该行列式最高次项为

$$\pm r_i \prod_{j \neq i} z_j.$$

由于 $r_i \neq 0$，这是非零多项式，其零点只构成零测集。对有限个 i 取坏集合的并集，仍是零测集。

一个等价、方便手算的表达

在 K 可逆且 $w_{n+1} = 1$ 时，

$$w_{1:n}^\top K = r, \qquad w_{1:n}^\top = r K^{-1}.$$

每个分量是多项式比值；分子最高次项同样含 $r_i \prod_{j \neq i} z_j$，不是恒等于0。这个表达帮助直观看懂原文的余子式论证。

6.7 公式(66)：为什么相减后只剩坐标差？

两条左零等式相减：

$$0 = w^\top [H(z) - H(\tilde{z})] = w^\top \begin{bmatrix} \mathrm{Diag}(z - \tilde{z}) \\ 0 \end{bmatrix}.$$

逐列写出：

$$0 = (w_1(z_1 - \tilde{z}_1), \dots, w_n(z_n - \tilde{z}_n)).$$

因为每个 $w_i \neq 0$，得到 $z_i = \tilde{z}_i$。

这就是额外环境的关键作用： 它提供一行不消失的一次信号，使法向量对每个坐标都敏感。原文(66)最后多写了一个0，严格维度应是长度 n 的行向量。

6.8 公式(67)：从几乎处处到处处

正常点是零测代数集的补集，因而稠密。在该稠密集上 $\psi(z) = z$。若 ψ 连续，则对任意例外点 z_0，取正常点 $z_k \to z_0$：

$$\psi(z_0) = \lim_k \psi(z_k) = \lim_k z_k = z_0.$$

此前无关坐标 z^o 任意固定，所以对每个 z^o 都成立，最终

$$\tilde{f}^{-1}(x)_i = f^{-1}(x)_i, \qquad i \leq n$$

在标准化坐标中成立。撤销坐标、尺度、平移与置换，就得到概念级的可识别关系。

6.9 把整段证明手算一次

使用第01章**未中心化**的 M, B 演示最后的代数。只要两套候选已对齐同一组 M, B，这个代数步骤不要求 B 中心化。

$$M^+ = \frac{1}{3}\begin{bmatrix} 2 & -1 & 1 \\ -1 & 2 & 1 \end{bmatrix}, \quad C = \begin{bmatrix} 1/3 & 2/3 \\ 1/3 & 2/3 \end{bmatrix}, \quad r = (1, 2).$$

在 $z = (3, 4)$：

$$K = \begin{bmatrix} 8/3 & -2/3 \\ -1/3 & 10/3 \end{bmatrix}, \quad \det K = 26/3,$$

$$K^{-1} = \begin{bmatrix} 5/13 & 1/13 \\ 1/26 & 4/13 \end{bmatrix}, \quad w = (6/13, 9/13, 1)^\top.$$

第一列内积：

$$\frac{6}{13}\frac{8}{3}+\frac{9}{13}\left(-\frac{1}{3}\right)-1=\frac{16}{13}-\frac{3}{13}-1=0.$$

第二列内积：

$$\frac{6}{13}\left(-\frac{2}{3}\right)+\frac{9}{13}\frac{10}{3}-2=-\frac{4}{13}+\frac{30}{13}-2=0.$$

如果同一 w 也垂直 $H(\tilde{z})$，相减便给

$$\frac{6}{13}(3-\tilde{z}_1)=0,\qquad \frac{9}{13}(4-\tilde{z}_2)=0,$$

所以 $\tilde{z}=(3,4)$。

甚至可直接从 w 重建：

$$z_i=\frac{(w_{1:n}^{\top}C)_i+w_{n+1}r_i}{w_i}.$$

但这不是论文给出的有限样本算法，因为数据中并不直接提供精确的 w。

6.10 例外点为什么不能忽略?

在同一例子中，

$$\det K=z_1z_2-\frac{2}{3}z_1-\frac{1}{3}z_2.$$

$z=(0,0)$ 是奇异点。$z_1=0,z_2=1$ 虽然 K 可逆，却有 $w_2=0$。这些点说明“几乎处处”的确有必要，最后的连续性不是装饰。

数值算法在这些点附近也可能病态：理论上非零不等于数值上远离0。定理没有给出条件数和有限样本稳定性界，这正是可以继续研究的方向。

6.11 引理3与公式(68)–(75)：等价关系的完整解释

为了避免原文赋值正负号不一致，先用一致的原子求值关系来表述：

$$\tilde{s} = Rs + c,$$

其中 R 为置换与非零对角尺度相乘的单项矩阵。对应目标也按相同规则变换。

自反性： 取 $R = I, c = 0$。

对称性： 从 $\tilde{s} = Rs + c$ 解出

$$s = R^{-1}\tilde{s} - R^{-1}c.$$

R^{-1} 仍是单项矩阵。因此反向也具有同类形式。这对应原文(68)–(75)的反置换、逆尺度与反平移计算。

传递性： 若 $\hat{s} = R_2\tilde{s} + c_2$，则

$$\hat{s} = (R_2R_1)s + (R_2c_1 + c_2).$$

单项矩阵乘积仍是单项矩阵，所以仍在同一等价类。

为什么能提升到环境概念矩阵?

各环境只是选取共享原子的若干行。原子级的同一置换、尺度、平移限制到这些行，就得到环境级关系。任意原子偏移向量都能写成 Aw，因为共享原子矩阵满行秩。

如果原子线性相关，偏移就不能任意独立指定。例如 $a_2 = 2a_1$ 强迫 $a_2^\top w = 2a_1^\top w$。这解释原文为什么强调线性独立。

严格边界： 以上证明的是修正到一致符号后的自然求值等价关系，不是宣称含符号不一致的原始定义4已经按字面获得验证。形式化引用时应先统一定义与赋值变换。

07｜理论怎样变成算法：正文§5.1与附录E、F、G

7.1 引理2：分类logit为什么是密度比?

训练数据的正类来自环境 e，负类来自基准0，各占一半。记标签 $Y=1$ 代表环境 e。

由贝叶斯公式：

$$P(Y=1\mid x)=\frac{p_X^e(x)}{p_X^e(x)+p_X^0(x)}.$$

于是最优logit为

$$\operatorname{logit} P(Y=1\mid x)=\log\frac{p_X^e(x)}{p_X^0(x)}.$$

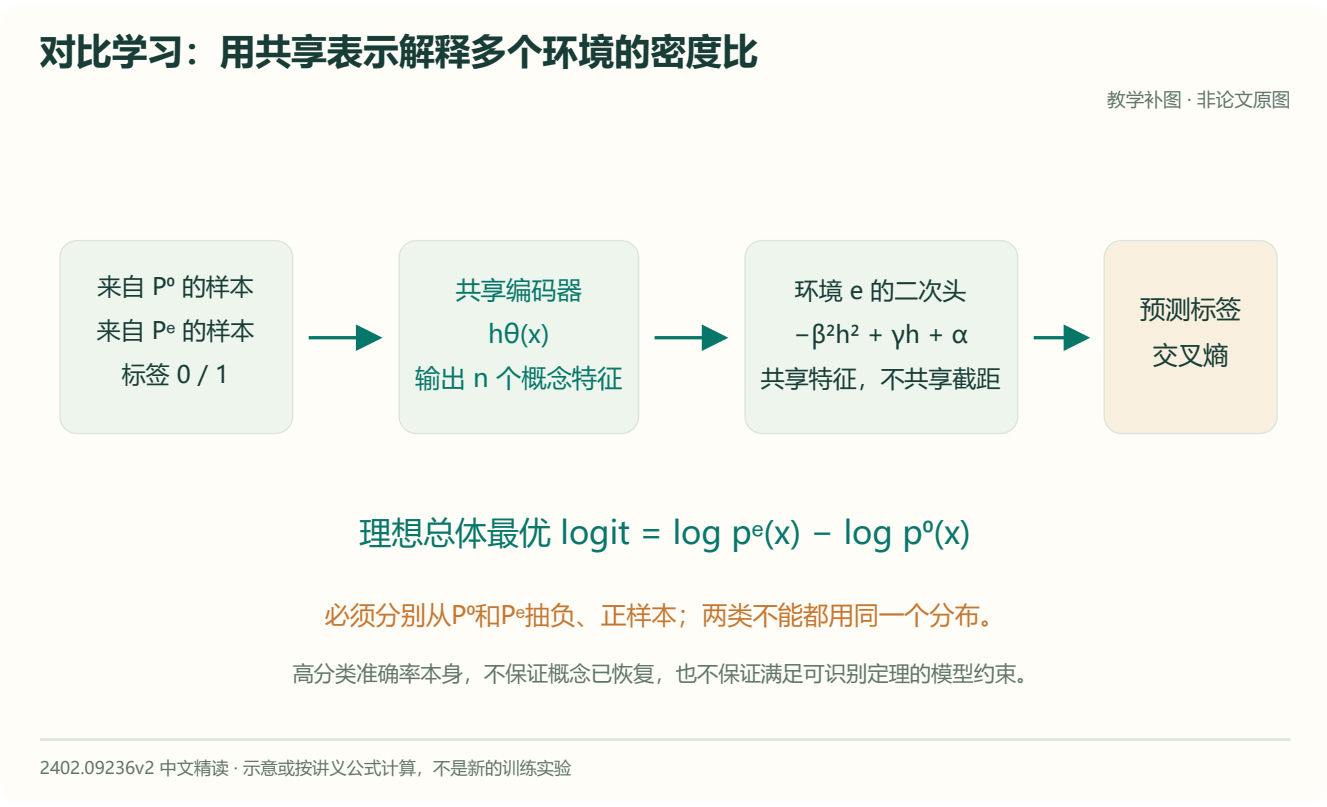
若两类先验不是各一半，还会多出常数 $\log[\pi/(1-\pi)]$。这可被分类头截距吸收。

再代入第02章的高斯展开，立即得到原文引理2：

$$r_e(x)=c_e-\frac{1}{2}\sum_i M_{ei}s_i(x)^2+\sum_i B_{ei}s_i(x).$$

所以原文附录E中“由式(13)直接得到”的一句话，实际包含了高斯展开、密度比不变与最优分类三个环节。

7.2 共享编码器与二次分类头



教学补图7-1：从分布恒等式到训练架构。正负样本必须来自不同环境，编码器共享，分类头依环境变化。

网络输出 $h_\theta(x) \in \mathbb{R}^n$，每个环境有自己的分类头。把原文写法的环境行索引明确后，可写成

$$\hat{r}_e(x) = \alpha_e - \sum_{i=1}^{n} \beta_{ei}^2 h_{\theta,i}(x)^2 + \sum_{i=1}^{n} \gamma_{ei} h_{\theta,i}(x).$$

理想对应为 $\beta_{ei}^2 = M_{ei}/2$、$\gamma_{ei} = B_{ei}$。

如果知道哪些原子属于该环境，则只对那些坐标求和；如果不知道，需要学习相应稀疏支持。原文写成 $k \le \dim(C_e)$，并不意味着每个环境都使用“前$\dim(C_e)$个共享概念”。

7.3 交叉熵的正确形式

单样本损失为

$$\ell(r, y) = \log(1 + e^r) - yr = \mathrm{softplus}(r) - yr.$$

总体目标为

$$\mathcal{L} = \sum_e \left[\frac{1}{2}\mathbb{E}_{X\sim P^e} \operatorname{softplus}(-\hat{r}_e(X)) + \frac{1}{2}\mathbb{E}_{X\sim P^0} \operatorname{softplus}(\hat{r}_e(X)) \right] + \eta\|\beta\|_1.$$

等价地，先抽 $j \sim \mathrm{Unif}\{0, e\}$，再抽 $X \sim P^j$。

【核对提醒】 原文损失中的内层期望对两个标签都写成 $X \sim X^e$。如果按字面执行，正负标签面对相同数据分布，最优分类器是常数0，不会学习目标密度比。应改为 $X \sim X^j$ 或上面的两项形式。

7.4 为什么总体交叉熵最优解是贝叶斯分类器?

固定 x，记 $\pi_x = P(Y=1 \mid x)$，条件风险为

$$R_x(r) = \log(1 + e^r) - \pi_x r.$$

求导:

$$R_x'(r) = \operatorname{sigmoid}(r) - \pi_x, \qquad R_x''(r) = \operatorname{sigmoid}(r)[1 - \operatorname{sigmoid}(r)] > 0.$$

所以唯一最优点为 $r = \log[\pi_x/(1-\pi_x)]$。这证明的是总体风险与充分函数容量条件下的结论，不是有限网络训练的全局收敛保证。

7.5 参数梯度如何计算?

记 $u_i = h_{\theta,i}(x)$，$p = \operatorname{sigmoid}(\hat{r}_e)$。对一个样本:

$$\frac{\partial \ell}{\partial \alpha_e} = p - y,$$

$$\frac{\partial \ell}{\partial \beta_{ei}} = (p-y)(-2\beta_{ei}u_i^2), \qquad \frac{\partial \ell}{\partial \gamma_{ei}} = (p-y)u_i,$$

$$\frac{\partial \ell}{\partial u_i} = (p-y)(-2\beta_{ei}^2 u_i + \gamma_{ei}).$$

再通过 u_i 对 θ 反向传播。ℓ_1 正则对非零 β 加 $\eta\,\mathrm{sign}(\beta)$，零点用次梯度或近端方法处理。

一次前向手算

令 $u=(1,2)$，$\alpha=0,\beta=(1,1),\gamma=(1,2)$：

$$\hat{r}=-(1+4)+(1+4)=0,\quad p=1/2.$$

若 $y=1$，损失 $\log 2$。梯度为

$$\partial_\alpha \ell=-1/2,\quad \partial_\beta \ell=(1,4),\quad \partial_\gamma \ell=(-1/2,-1),\quad \partial_u \ell=(1/2,1).$$

这些导数在数值脚本中用有限差分核验。

7.6 “正确分类”何时能推出“正确概念”？

还需要：

1. 每个环境分类器真的学到了总体密度比，而不仅是高分类准确率。
2. 学到的特征与分类头整体落在定理要求的模型类中。
3. 环境筛选结构、共同原子、方差共享等条件满足。
4. 没有通过额外特征或环境捷径绕开概念结构。

例如允许任意环境的 β_{ei} 独立变化，并不会自动满足主定理“同一原子跨环境精度固定”的设定；允许 $\beta_{ei}=0$ 但 $\gamma_{ei}\neq 0$，也不对应同一高斯筛选模型。

另一个尺度问题：若 $h_i\mapsto ch_i$，同时 $\beta_{ei}\mapsto \beta_{ei}/c$、$\gamma_{ei}\mapsto \gamma_{ei}/c$，分类logit不变，而 $\|\beta\|_1$ 可随 $c\to\infty$ 缩小。没有额外尺度控制时，单独的该正则不一定定义良好的概念尺度。

这些不是“算法一定无效”的证明，而是说明定理到实现之间还有需要检查的桥梁。

7.7 附录F：原文合成实验做了什么?

【原文报告】

- 基准分布：3个分量的高斯混合；权重从 $U(0.3,1)$ 抽取后归一化。
- 分量均值各坐标从 $U(-1,1)$ 抽取；对角协方差元素从 $U(0.01,0.015)$ 抽取。
- 混合函数：线性，或一个含16个隐藏单元、LeakyReLU斜率0.2的单隐藏层MLP。
- 概念向量坐标从 $U(-0.3,0.3)$ 抽取；筛选高斯方差0.005。

- 每环境5000个样本；通过拒绝采样产生。
- 学习器：线性编码，或两个各32单元的隐藏层；二次参数分类头。
- 训练100轮，Adam；参数分类头学习率0.5，非参数编码部分0.005；余弦退火；$\eta = 10^{-4}$。

表1（5个随机种子的均值）：

混合	n	d_z	d_x	R^2	MCC
线性	2	3	4	0.98	0.98
非线性	2	3	4	0.94	0.96
线性	3	4	6	0.99	0.86
非线性	3	4	6	0.97	0.92
线性	4	8	10	0.97	0.87
非线性	4	8	10	0.94	0.87

指标如何理解？

线性对齐后可用

$$R^2 = 1 - \frac{\sum_t \|s_t - \hat{s}_t\|^2}{\sum_t \|s_t - \bar{s}\|^2}.$$

回归对齐应在训练/验证部分拟合，在独立测试数据评估。多输出聚合方式需明确。原文没有在此附录完整指定每个实现细节，上式是常见解释，不是假称已核查作者代码。

原子级MCC通常通过最佳一一匹配计算：

$$\mathrm{MCC} = \max_{\pi} \frac{1}{n} \sum_i |\operatorname{Corr}(s_i, \hat{s}_{\pi(i)})|.$$

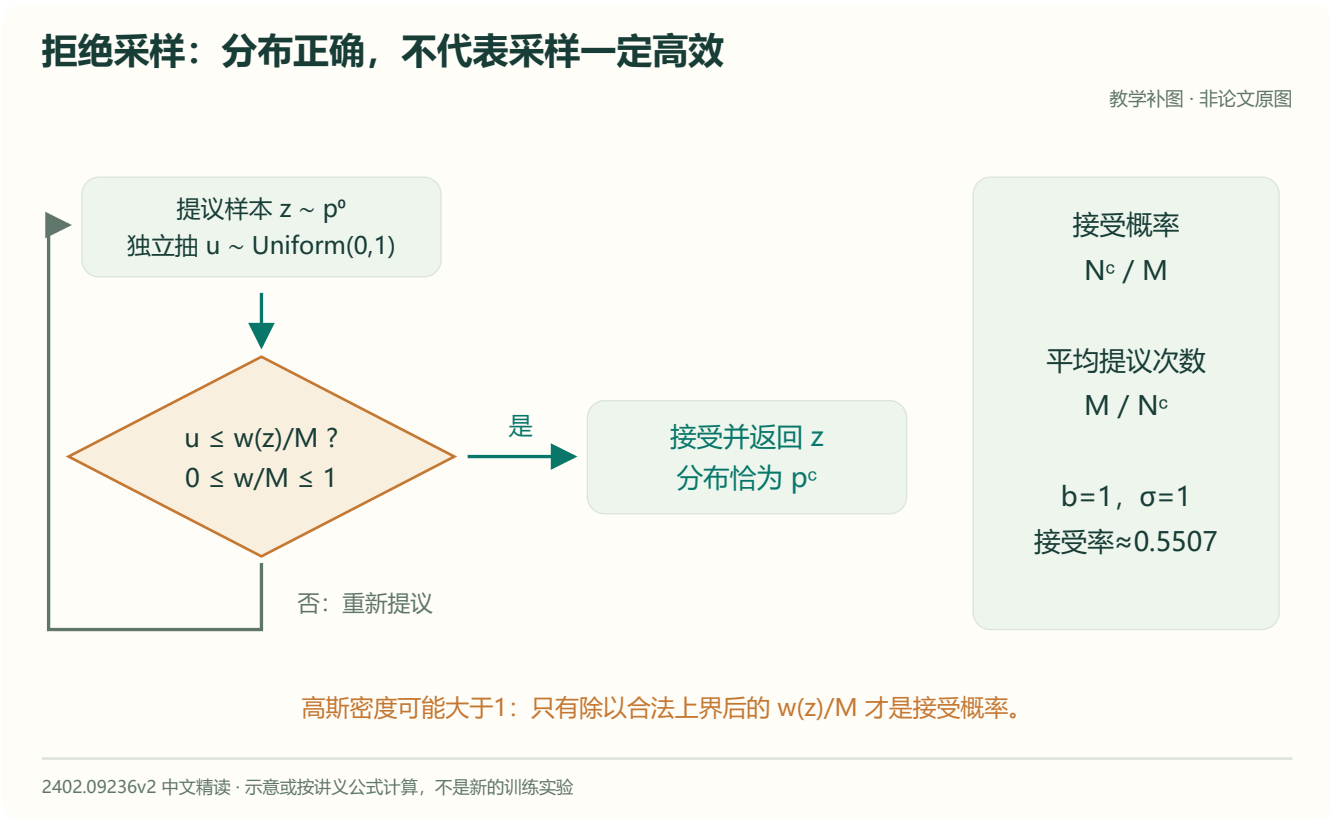
R^2高、MCC较低可能表示整体子空间恢复好，但原子仍有混合。以独立同方差的两个变量作45度旋转为例，线性对齐后 $R^2 = 1$，逐原子MCC却只有 $1/\sqrt{2}$。

复现时必须查清的缺口

附录F同时写“$m = n + 1$”和“概念都是原子的”。若按“每个条件环境只筛选一个原子”的字面解释，对 $n \geq 2$ 无法满足假设4：每个原子至少需要出现两次，共需至少 $2n$ 个单原子环境，而 $n + 1 < 2n$。

因此，需要作者代码或进一步说明来确定实际环境构造，不能直接将表1称为定理1所有假设的严格验证。此外，随机MLP的单射性也不是仅凭网络宽度就自动得到的。

7.8 附录G：拒绝采样算法1



教学补图7-2：算法1的接受、返回和重新提议分支。右侧同时显示接受概率与预期计算成本。

令 $k = \dim C$，$w(z) = \prod_{i=1}^{k} q((Az-b)_i)$。若 $q(t) \le L$，则 $w(z) \le M = L^k$。

```
反复进行：
    抽 z ~ p⁰
    独立抽 u ~ Uniform(0,1)
    若 u ≤ w(z)/M，则返回 z
```

实际编码时，高斯密度峰值可能大于1，所以不能直接把 q 当接受概率；必须除以合法上界。

7.9 引理4与推论1：接受概率、预期计算量

因为给定 z 时 u 均匀：

$$P(\text{accept} \mid z) = w(z)/M.$$

积分得到

$$P(\text{accept}) = \int p^0(z)\frac{w(z)}{M}\,dz = \frac{N_C}{M}.$$

各次尝试独立，等待次数 T 是成功概率 $a = N_C/M$ 的几何变量：

$$P(T=t) = (1-a)^{t-1}a, \qquad E[T] = \sum_{t\geq 1} P(T \geq t) = \frac{1}{a} = \frac{M}{N_C}.$$

原文引理4中将一般 $M \geq \max(q)^k$ 直接替成精确峰值的等式，只在取等号时成立；保留一般 M，上面三行证明始终正确。

7.10 定理3：为什么返回的样本分布正确?

对任意可测集合 E，

$$P(Z \in E \mid \text{accept}) = \frac{\int_E p^0(z)w(z)/M\,dz}{N_C/M} = \int_E p_C(z)\,dz.$$

若担心“算法等到第一次接受”和“单次条件接受”是否相同，再求和：

$$P(Z_T \in E) = \sum_{t\geq 1}(1-a)^{t-1}\int_E p^0(z)w(z)/M\,dz = \int_E p_C(z)\,dz.$$

这补全了算法停止规则的联系。原文通过多维CDF证明，同一个计算把 E 换成 $\prod_i(-\infty, t_i]$ 即可得到。

7.11 一个能算出成本的高斯例子

基准 $\mathcal{N}(0,1)$、高斯筛选标准差 σ 时，峰值 $L = (2\pi\sigma^2)^{-1/2}$，

$$N_C = \frac{1}{\sqrt{2\pi(1+\sigma^2)}}\exp\left[-\frac{b^2}{2(1+\sigma^2)}\right].$$

所以

$$a = \frac{\sigma}{\sqrt{1+\sigma^2}}\exp\left[-\frac{b^2}{2(1+\sigma^2)}\right].$$

当 $b=1,\sigma=1$，$a=2^{-1/2}e^{-1/4}\approx 0.55070$，平均约1.816次尝试产生一个样本。

贯穿例子的第三环境筛选两个独立坐标、目标为1与2：

$$a=\frac{1}{2}e^{-5/4}\approx 0.14325,$$

平均约6.981次尝试。如果筛选很多坐标、噪声非常小，或者目标远离基准高概率区域，成本可能爆炸。**正确采样不等于高效采样。**

7.12 一般高斯乘积的可计算形式

若 $p^0=\mathcal{N}(\mu_0,\Sigma_0)$、筛选噪声协方差为 $R\succ 0$，则配方得到

$$\Sigma_C=(\Sigma_0^{-1}+A^\top R^{-1}A)^{-1},$$

$$\mu_C=\Sigma_C(\Sigma_0^{-1}\mu_0+A^\top R^{-1}b).$$

归一化常数是含噪测量的边缘密度：

$$N_C=\mathcal{N}(b;A\mu_0,R+A\Sigma_0A^\top).$$

这组补充公式可以直接检查拒绝采样，但不意味着原文任意复杂基准分布的常数都能这样算。

08 | 附录B与C：与CRL的关系，以及三种“条件分布”

8.1 附录B：不要把概念向量与邻接矩阵混淆

标准CRL可以设潜变量满足

$$z = Wz + \epsilon, \qquad \epsilon \sim \mathcal{N}(0, I),$$

其中 W 是无环因果图的加权邻接矩阵。则

$$z = (I - W)^{-1}\epsilon.$$

若图的拓扑序确定，W 可排列为严格三角矩阵，故 $I - W$ 可逆。$W = 0$ 是相互独立潜变量的特例。

本文主模型中没有这样的 W，其 A 表示概念测量。因此识别 $Af^{-1}(x)$ 不是识别 W。

即使知道了真正的因果变量，只有观察数据时，图仍可能只识别到Markov等价类；若有额外函数模型、噪声或干预假设，才能进一步定向。

8.2 Gaussian不识别的最简单例子

若 $z \sim \mathcal{N}(0, I_d)$，任意正交矩阵 Q 都满足

$$Qz \sim \mathcal{N}(0, QIQ^\top) = \mathcal{N}(0, I_d).$$

令 $\tilde{z} = Qz$，$\tilde{f} = f \circ Q^\top$，就得到同样的观测分布，但坐标方向已经改变。这说明单环境中“独立标准高斯潜变量+任意混合”不足以确定语义轴。

对于完全非线性的混合，单凭独立性通常还有更大的不确定性。本文用环境相关的筛选密度比补充识别信息。

8.3 人类可解释概念不一定是真实生成因素

生成一个自然场景可能涉及光照、材料、相机、遮挡等大量因素，而任务只关心“红色”和“大小”。一个可用的人类概念也可能是许多底层物理变量的函数。

因此本文选择识别任务相关测量，而非声称恢复了唯一真实的世界生成坐标。好处是目标更弱、可能需要更少环境；代价是**不能自动赋予这些概念完整的SCM干预语义。**

8.4 附录C的空间分解

设 $C = \{z : Az = b\}$，并假设 A 满行秩。令

$$C_0 = \ker A, \qquad V = (\ker A)^{\perp} = \mathrm{row}(A).$$

每个 z 唯一写成 $z = c + v$，其中 $c \in C_0, v \in V$。在 V 中满足 $Av = b$ 的唯一向量是

$$v^C = A^{+}b.$$

因为两个这样的解之差同时在 V 和 $\ker A$，只能为0。

给定希望靠近目标的分布 $q_V(v)$，作者讨论三种构造。下面所有边缘、条件密度都假定有定义。

8.5 方案一：替换边缘，但保留原条件分布

$$p_1(c, v) = q_V(v)p^0(c \mid v) = q_V(v)\frac{p^0(c, v)}{p^0_V(v)}.$$

它已经归一化，因为先采 $v \sim q_V$，再采 $c \sim p^0(c \mid v)$。v 的边缘正是 q_V，但 c 与 v 的关联被保留。

8.6 方案二：替换v，同时让c保留原边缘

$$p_2(c, v) = p^0_{C_0}(c)q_V(v).$$

这使 c 与 v 独立。它可以对应某些特定图结构下的随机干预，但**没有SCM结构时，不能把任意坐标空间里的这一乘积都无条件叫做do操作。**

8.7 方案三：贝叶斯重加权，对应公式(76)

$$p_3(c, v) = \frac{p^0(c, v)q_V(v)}{\int p^0(c', v')q_V(v')\,dc'\,dv'}.$$

此时

$$p_{3,V}(v) \propto p_V^0(v) q_V(v), \qquad p_3(c \mid v) = p^0(c \mid v).$$

与方案一的区别在于：它**没有**把 v 的边缘强制替换成 q_V，而是先验与似然相乘。本文主要采用这一方案。

如果 q_V 是密度，它可能大于1，实际拒绝采样要按上界缩放；“以概率q_V接受”只能作为省略常数的直觉。

8.8 用相关高斯把三种方案算出来

【教学例子】 基准为

$$v \sim \mathcal{N}(0,1), \qquad c = \rho v + \sqrt{1-\rho^2}\epsilon, \quad \epsilon \sim \mathcal{N}(0,1), \quad |\rho| < 1.$$

目标 $q_V = \mathcal{N}(b, \sigma^2)$。

方案一

$$E[v] = b, \quad \mathrm{Var}(v) = \sigma^2,$$

$$E[c] = \rho b, \quad \mathrm{Var}(c) = 1 - \rho^2 + \rho^2\sigma^2, \quad \mathrm{Cov}(c, v) = \rho\sigma^2.$$

方案二

$$E[v] = b, \quad E[c] = 0, \quad \mathrm{Var}(v) = \sigma^2, \quad \mathrm{Var}(c) = 1, \quad \mathrm{Cov}(c, v) = 0.$$

方案三

先算 v 的后验：

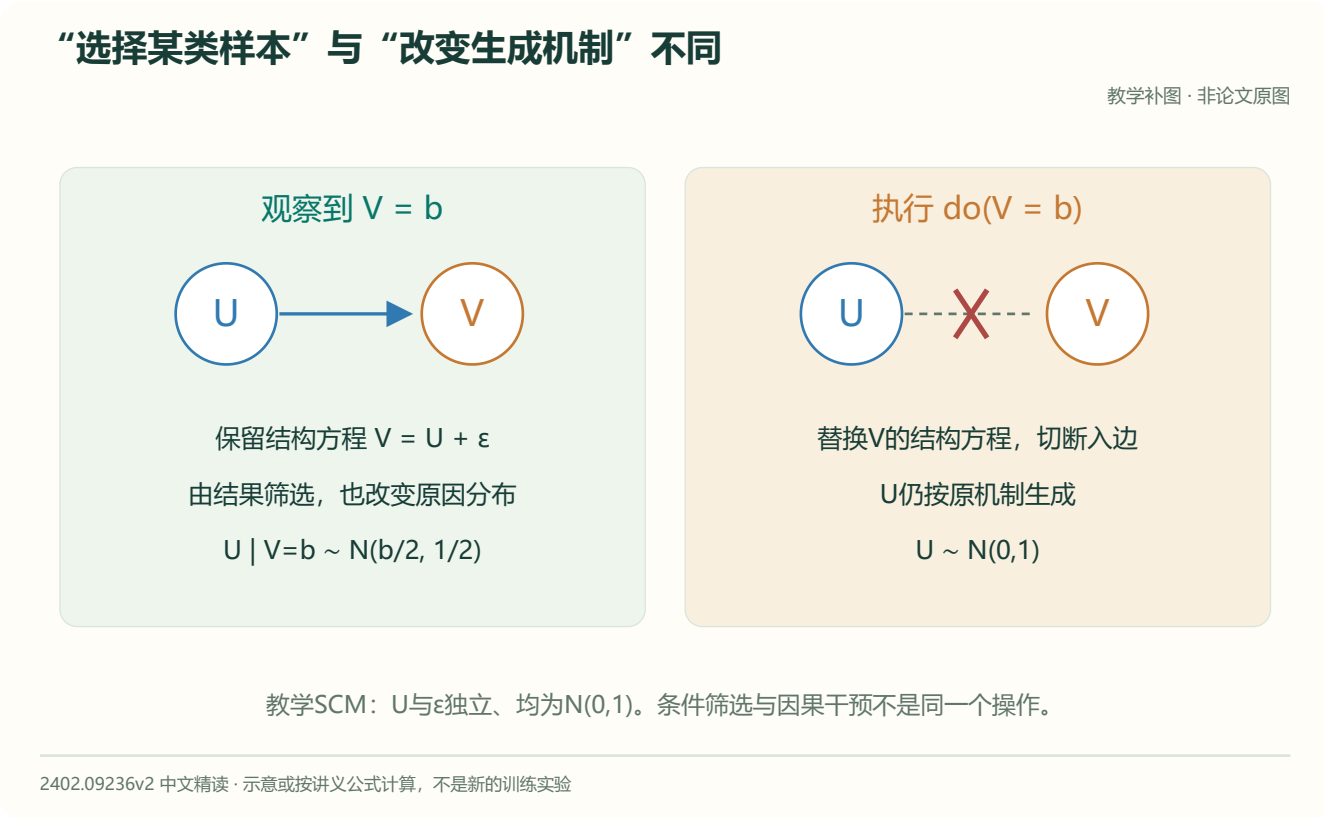
$$\mu_v = \frac{b}{1+\sigma^2}, \qquad \tau^2 = \frac{\sigma^2}{1+\sigma^2}.$$

再保留 $c \mid v$：

$$E[c]=\rho\mu_v,\quad \mathrm{Var}(c)=1-\rho^2+\rho^2\tau^2,\quad \mathrm{Cov}(c,v)=\rho\tau^2.$$

取 $\rho=1/2, b=2, \sigma=1$，三种方案的 $(E[v],E[c])$ 分别为 $(2,1)$、$(2,0)$、$(1,1/2)$。同一句“让v靠近2”，对应了完全不同的联合分布。

8.9 为什么条件筛选不是一般的因果干预?



教学补图8-1：左边是观察结果后筛选样本，右边是替换结构方程。不要把两种操作都叫作干预。

取 $U\sim\mathcal{N}(0,1)$、$V=U+\epsilon$，$\epsilon\sim\mathcal{N}(0,1)$。则

$$U\mid V=b\sim\mathcal{N}(b/2,1/2).$$

但 $\mathrm{do}(V=b)$ 替换的是 V 的结构方程，原因 U 仍为 $\mathcal{N}(0,1)$。因此观测条件下 $E[U]=b/2$，干预下 $E[U]=0$。

这也是为什么本文可以利用便宜的条件筛选数据，却不能仅凭其主定理恢复因果方向。

8.10 公式(77)：给概念法向空间一个高斯

作者考虑

$$q_V = \mathcal{N}(v^C, \sigma^2 I_V).$$

这里是在 V 子空间上定义的高斯，不一定是整个 $\mathbb{R}^{d_z}$ 上非退化高斯。

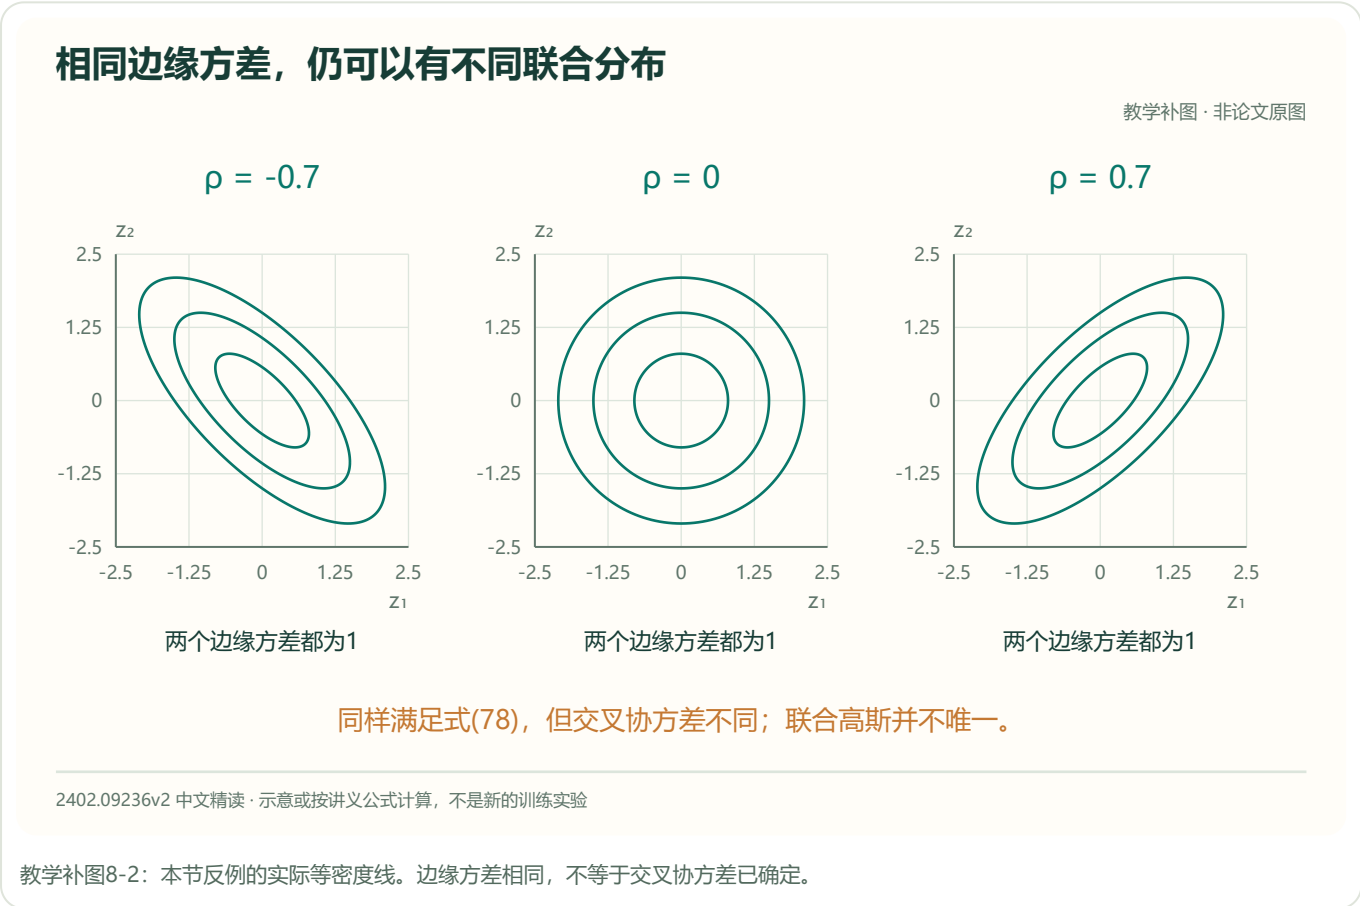
它与正文的 $\prod_i q((Az-b)_i)$ 不能在任意非正交 A 下直接视为相同的各向同性噪声：正文高斯乘积在法向空间的精度与 $A^\top A$ 有关。只有在合适的正交规范或同步调整协方差后，才能进行这种等价解释。

若另想让 Az 的分布恰为 $\mathcal{N}(b, I)$，在 V 上可取协方差

$$\Sigma_V = A^+(A^+)^\top = (A^\top A)^+.$$

于是 $A\Sigma_V A^\top = I$。当 A 宽而满行秩时，$A^\top A$ 在全空间奇异，原文所写 $(A^\top A)^{-1}$ 不能作为普通全空间逆，必须限制到 V 或用伪逆。

8.11 公式(78)：边缘协方差约束不保证唯一联合协方差



教学补图8-2：本节反例的实际等密度线。边缘方差相同，不等于交叉协方差已确定。

多组概念希望满足

$$A^e \Sigma (A^e)^\top = I.$$

这是对协方差的线性约束，但通常不足以确定全部交叉协方差。

【直接反例】 取二维中两个正交概念

$$A^1 = (1, 0), \quad A^2 = (0, 1), \quad \Sigma_\rho = \begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix}, \quad |\rho| < 1.$$

无论 ρ 为何，都有 $A^1 \Sigma_\rho (A^1)^\top = 1$、$A^2 \Sigma_\rho (A^2)^\top = 1$。而特征值 $1 \pm \rho > 0$，所以它们都是合法正定协方差。

因此，即使概念子空间正交、维度和非退化，也存在无穷多个联合高斯。要唯一，必须再给交叉协方差、独立性或其他选择原则。

这纠正的是附录C的一个探索性推测，不是否定主定理；主定理没有依赖该推测。

09 | LLM推理时干预：正文§5.2、附录D的全部关键公式

9.1 首先划清定理与启发式的分界

【原文明确说明】 附录D.3基于启发式和非正式假设，不作严格理论结论。

这部分假设：真假概念在选定激活空间中近似线性；配对答案具有可比性；不相关概念变化会平均抵消；小幅底层编辑对更高层的复杂传播可以暂时忽略。这些都不能由前面的环境可识别定理自动推出。

本文也没有证明“真假”在所有语境中对应同一个真实的一维轴。

9.2 Transformer与ITI的前向公式

为避开原文 f 方向混用，本章把LLM激活提取记作 $H(x)$。

论文用简化的注意力残差式

$$x_{\ell+1} = x_\ell + \sum_{h=1}^{H} Q_\ell^h x_\ell^h, \qquad x_\ell^h = \mathrm{Att}_\ell^h(P_\ell^h x_\ell).$$

这是解释head编辑的简化式，不是包含MLP、归一化、位置编码等细节的完整Transformer定义。实际 x_ℓ 还随token位置变化。

ITI在选中的head输出上加向量：

$$x_{\ell+1} = x_\ell + \sum_h Q_\ell^h \left(x_\ell^h + \alpha \sigma_\ell^h \hat{\eta}_\ell^h\right).$$

未选中的head对应编辑量为0。$\hat{\eta}$ 通常单位化；σ 是该head激活在该方向上的标准差；α 控制强度。推理时的每一步自回归前向都会受到编辑。

9.3 ITI怎样选择head与方向?

1. 准备问题及其真假候选答案。
2. 将问题与答案拼接，提取末token的各head激活。
3. 对每个head训练线性探针 $\mathrm{sigmoid}(\theta^\top h)$ 区分真假。
4. 在独立验证数据上选择区分能力较强的前 K 个head。

5. 编辑方向使用真假激活的均值差，并非必须直接用探针权重。

探针能预测标签，说明激活里包含可解码信息，**不意味着沿探针权重编辑就一定获得最好的因果控制**。相关性、方向度量和激活分布都会影响结果。

9.4 概念空间：真假数据靠近两张仿射平面

设概念矩阵 $A \in \mathbb{R}^{k\times d}$，激活为 $H(x) \in \mathbb{R}^d$，理想化地

$$\mathcal{S}_F = \{x : AH(x) = b_0\}, \qquad \mathcal{S}_T = \{x : AH(x) = b_1\}.$$

实际只是近似满足。若概念条件分布仍受复杂基准分布影响，“围绕目标平面集中”也需要基准分布不过度压制目标附近；不是任意 p^0 下都自动成立。

令 $d_b = b_1 - b_0$。编辑 η 应满足

$$A(H(x) + \eta) = b_1 \quad \Longleftrightarrow \quad A\eta = d_b.$$

9.5 理想编辑为何是伪逆？完整证明

考虑最小欧氏扰动：

$$\min_{\eta} \frac{1}{2}\|\eta\|_2^2 \quad \text{s.t. } A\eta = d_b.$$

假设 A 满行秩。拉格朗日函数

$$\mathcal{J}(\eta, \nu) = \frac{1}{2}\eta^\top\eta + \nu^\top(A\eta - d_b).$$

一阶条件给 $\eta + A^\top\nu = 0$。代入约束：

$$-AA^\top\nu = d_b, \qquad \eta^* = A^\top(AA^\top)^{-1}d_b = A^+d_b.$$

任何其他可行解为 $\eta^* + v$，其中 $v \in \ker A$。因 $\eta^* \in \mathrm{row}(A)$，两者正交，所以

$$\|\eta^* + v\|^2 = \|\eta^*\|^2 + \|v\|^2 \geq \|\eta^*\|^2.$$

严格凸性给唯一最小解。若 A 不满行秩，需先确认 d_b 在 A 的像空间内，再用Moore–Penrose伪逆处理。

若另一个概念矩阵 B 的行空间与 A 正交，则 $BA^\top = 0$，于是

$$B\eta^* = BA^+(b_1 - b_0) = 0.$$

这只保证**线性且欧氏正交的概念**不变，不能保证所有语义概念、所有后续层行为和最终输出都不变。

9.6 配对激活差为何有用?

对真假配对答案，定义

$$\Delta_i = H(c_i^T) - H(c_i^F).$$

若理想化地所有配对满足 $AH(c_i^T) = b_1$、$AH(c_i^F) = b_0$，则

$$A\Delta_i = d_b.$$

于是可以唯一分解

$$\Delta_i = \eta^* + \xi_i, \qquad \xi_i \in \ker A.$$

“对同一个问题的真假答案”不必是因果推断中的严格反事实对；两句话可能还改变长度、措辞、话题细节、置信度等。因此 ξ_i 往往存在。

9.7 均值差为什么可能接近最小编辑?

$$\overline{\Delta} = \frac{1}{N}\sum_i \Delta_i = \eta^* + \frac{1}{N}\sum_i \xi_i.$$

【补充推导】 若 ξ_i 独立同分布、均值0、协方差 Σ_ξ 有限，则

$$E[\overline{\Delta}] = \eta^*, \qquad E\|\overline{\Delta} - \eta^*\|^2 = \frac{\operatorname{tr}\Sigma_\xi}{N}.$$

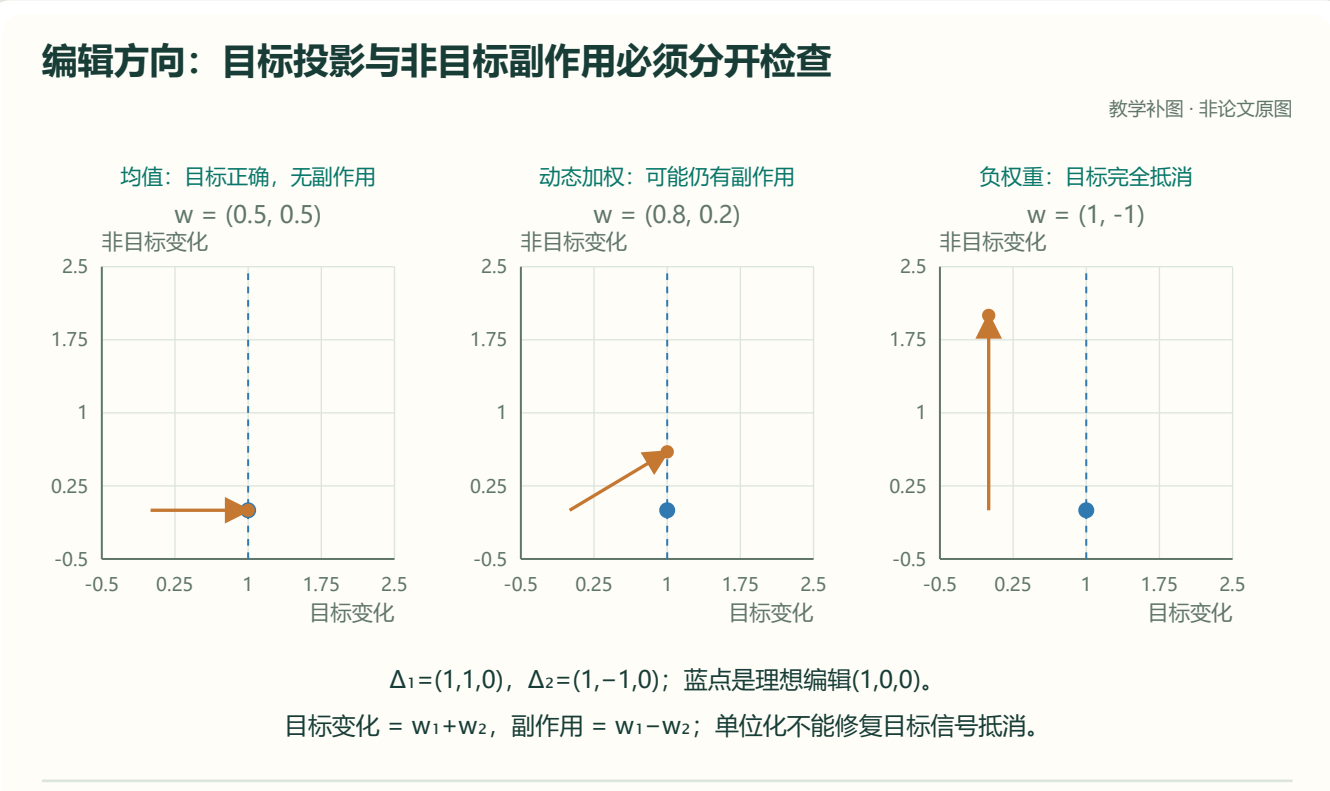
误差标准尺度随 $N^{-1/2}$ 缩小。更一般的弱相关条件也可能给相应界，但不能只说“语境多样”就自动得到零均值与独立性。

若 $E[\xi_i] = \mu \neq 0$，则平均趋于 $\eta^* + \mu$，样本再多也无法消除系统性偏差。

例子： $A = (1, 0)$、$d_b = 1$，两个激活差是 $(1, 1)$ 和 $(1, -1)$。均值为 $(1, 0)$，恰是最小编辑。若两个差都是 $(1, 1)$，平均后副作用仍为1。

原文D.3某处将“给同一对两端都加上同一向量后仍相等”当作保持概念的说明；真正需要检查的是 $B(H(x) + \eta) = BH(x)$，即 $B\eta = 0$，不是平移后两端互相相等。

9.8 任意加权组合都保持目标吗？必须算权重和



教学补图9-1：蓝点是理想编辑，橙箭头是实际编辑。横轴为目标变化，纵轴为非目标变化，二者必须同时检查。

令

$$\eta = \sum_i w_i \Delta_i.$$

则

$$\boxed{A\eta = \left(\sum_i w_i\right) d_b.}$$

若要求精确达到同一个 b_1，通常需要 $\sum_i w_i = 1$。因此原文“任意加权组合都精确满足目标”的说法缺少归一化条件。

取前述两个激活差：

- 权重 $(1/2, 1/2)$：$\eta = (1, 0)$，目标正确、副作用抵消。
- 权重 $(1, 1)$：$\eta = (2, 0)$，目标改变量翻倍。
- 权重 $(1, -1)$：$\eta = (0, 2)$，目标改变量完全消失，只剩副作用。
- 两个权重之和为负时，目标方向可能反转。

对结果做单位范数归一化不能把“目标投影为0”变成正确目标，也不能消除方向反转。

若目标只是得到一个再由 α 调节强度的方向，权重和不必严格为1，但此时就不能声称保持了精确赋值等式。

9.9 上下文相关权重与有效样本量

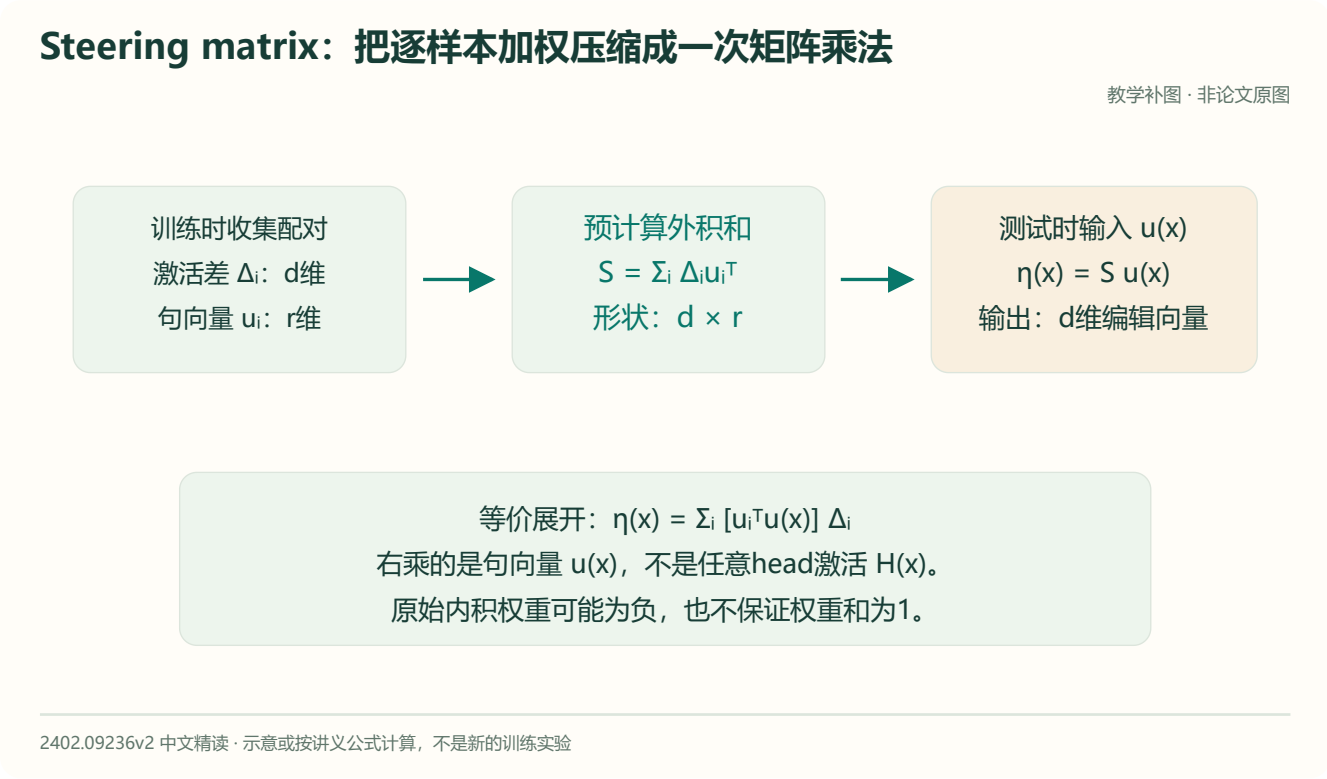
可以让 $w_i = w_i(x)$，对与测试问题相关的训练对赋更大权重。但要避免“语义相似”恰好也选择了同一类系统偏差。

若条件于上下文表示后 $E[\xi_i \mid \lambda(c_i^F)] = 0$，噪声条件独立且同协方差，归一化权重满足

$$\mathrm{Cov}\left(\sum_i w_i \xi_i\right) = \left(\sum_i w_i^2\right) \Sigma_\xi.$$

定义 $N_{\mathrm{eff}} = 1/\sum_i w_i^2$。均匀权重的有效样本数为 N；权重过度集中时可能接近1。动态加权可能减小局部偏差，也可能增大方差，并非必然优于均值。

9.10 Steering matrix的正确矩阵推导



教学补图9-2：矩阵法的训练预计算与测试乘法。右乘向量的空间和维度不能混用。

设句向量 $u_i = \lambda(c_i^F) \in \mathbb{R}^r$、$u(x) = \lambda(x) \in \mathbb{R}^r$，head激活差 $\Delta_i \in \mathbb{R}^d$。

原文选取相似度权重 $w_i(x) = u_i^\top u(x)$，因此

$$\begin{aligned}\eta(x) &= \sum_i [u_i^\top u(x)]\Delta_i \\ &= \left(\sum_i \Delta_i u_i^\top\right) u(x) \\ &= S_{\text{steer}} u(x), \qquad S_{\text{steer}} \in \mathbb{R}^{d\times r}.\end{aligned}$$

【核对提醒】 原文最后写 $MH(x)$，但其 M 是 $\sum_i \Delta_i \lambda(c_i^F)^\top$。一般应右乘 $\lambda(x)$，不是head激活；除非另有 $\lambda(x) = H(x)$ 的额外定义。即使 $d = r$ 恰好维度相同，也不意味着两个表达式相等。

一个完整外积计算

$$\Delta_1 = (1,1,0)^\top, \quad \Delta_2 = (1,-1,0)^\top, \quad u_1 = (1,0)^\top,\ u_2 = (0,1)^\top.$$

$$S_{\text{steer}} = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} (1, 0) + \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix} (0, 1) = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 0 & 0 \end{bmatrix}.$$

若 $u(x) = (0.8, 0.2)^\top$，则 $\eta(x) = (1, 0.6, 0)^\top$，与逐样本加权完全一致。

这展示了计算恒等式，并不证明动态权重让副作用更小；在这个例子里，均值反而完全抵消第二坐标。

9.11 复杂度怎么计算?

- 存储全部训练差与句向量：$O(N(d + r))$。
- 每次直接算权重和加权差：$O(Nr + Nd)$。
- 预计算矩阵：一次 $O(Ndr)$，存储 $O(dr)$；每次乘法 $O(dr)$。
- 矩阵秩至多 $\min(N, d, r)$；若低秩截断为 q，乘法可降至 $O(q(d + r))$，但截断可能引入误差，这是补充思路，不是论文已给出的保证。

还要加句向量编码成本。对于每个被编辑head，都有相应的输出维度和矩阵。

若换成softmax相似度权重，通常不能再精确压缩为同一常矩阵乘输入；不要把修改后的算法仍称为原式的等价实现。

9.12 动态方向的标准差如何算?

令 $\hat{\eta}(x) = \eta(x)/\|\eta(x)\|$，head激活参考协方差为 Σ_h，则

$$\sigma_h(x) = \sqrt{\hat{\eta}(x)^\top \Sigma_h \hat{\eta}(x)}.$$

编辑量为 $\alpha \sigma_h(x) \hat{\eta}(x)$。若方向范数太小，应跳过或采取明确的回退规则，不能除以0。

完整协方差二次型一般需要 $O(d^2)$；对角近似为 $O(d)$，但改变了估计。原文称张量化后的开销不大，并未给出一般复杂度定理。

9.13 一个重要几何问题：欧氏最小编辑依赖坐标

可识别性允许一般可逆潜坐标变化，但一般线性变化不保持欧氏长度或正交。因此“哪一个编辑最小、哪些概念正交”需要一个固定度量。

【补充推广】 若使用正定度量 G：

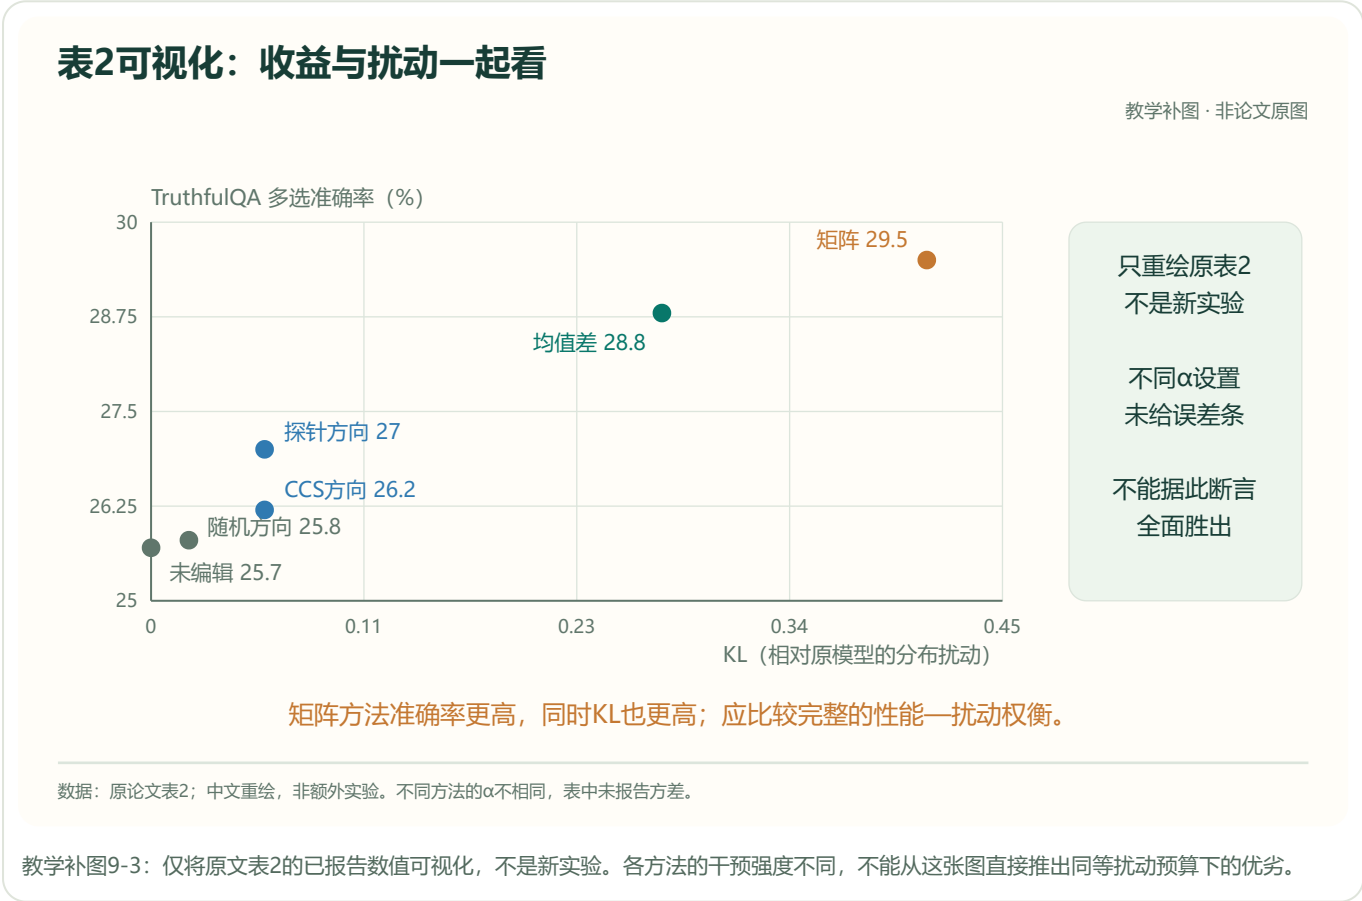
$$\min_{\eta} \frac{1}{2}\eta^\top G\eta \quad \text{s.t. } A\eta = d_b,$$

同样用拉格朗日法得到

$$\eta^*_G = G^{-1}A^\top(AG^{-1}A^\top)^{-1}d_b.$$

例如 G 可来自激活协方差或输出局部敏感性，但怎样选取、怎样保证泛化，是额外研究问题。本文的可识别性本身不自动指定一个唯一因果编辑方向。

9.14 表2：真实结果与代价一起看



教学补图9-3：仅将原文表2的已报告数值可视化，不是新实验。各方法的干预强度不同，不能从这张图直接推出同等扰动预算下的优劣。

【原文】 LLaMA 7B；SBERT句向量；TruthfulQA多选任务；3个随机种子；2折交叉验证。表中：

方法	α	准确率%	CE	KL
未编辑	—	25.7	2.16	0.00
随机方向	20	25.8	2.19	0.02
CCS方向	5	26.2	2.21	0.06

方法	α	准确率%	CE	
ITI探针权重方向	15	27.0	2.21	0.06
ITI均值差	20	28.8	2.41	0.27
Steering matrices	15	29.5	2.61	0.41

相比未编辑，提高3.8个百分点；相比均值差，提高0.7个百分点。但CE和KL也更高，表明对原模型分布的扰动更大。表中没有给出方差或显著性检验，不能断言0.7个百分点是稳定、普适的优势。

CE是在背景语言建模数据上的下一token交叉熵：

$$\mathrm{CE} = -\frac{1}{T}\sum_{t} \log P_{\mathrm{edited}}(y_t \mid y_{<t}).$$

KL衡量编辑前后下一token分布变化，例如

$$D_{\mathrm{KL}}(P\|Q) = \sum_{v} P(v)\log\frac{P(v)}{Q(v)}.$$

必须在复现时明确KL方向、语料与聚合方法。KL小不保证正确或安全；KL大也不能单独证明性能下降，但它提示需要检查干预副作用。

原文只评测此处的多选任务，未完整评测自由生成。作者明确将其定位为概念验证。

附录D还说明了一个历史实现原因：原先推荐的自由生成评测依赖特定微调GPT-3评估器，而相关旧服务已不可用，若更换评估器就需要重跑比较。因此“仅做多选”是这次实验的范围选择，不是算法在数学上只能用于多选题。

9.15 原文的三个观察可以推出多强的结论?

1. 找到多个正交但都能预测真假的探针：说明标签信息分布在多个方向，不足以单独证明“真理是非原子概念”。
2. 增强truthfulness后helpfulness下降：可能是共享成分，也可能是离开训练流形、方向误差或后续网络耦合；不能据此唯一识别共享原子。
3. 更多上下文可能帮助平均噪声：需要零均值、覆盖和依赖性条件，不是多样性口号自动给出的定理。

9.16 若自己复现，最低限度怎样保证公平?

- 按问题分组划分训练、验证和测试，不能将同题不同答案分散到不同集合。
- head选择、K、α、相似度温度等只能用训练/验证集调节。
- 比较相同干预范数、相近KL预算或完整的性能—扰动曲线，而不仅挑各方法最好的一点。
- 加入随机方向、均值差、探针方向、打乱句向量对应关系的对照。
- 检查改写问题、未见主题、真假类别不平衡和多个随机种子。
- 记录计算/显存开销；矩阵法不是免费获得上下文相关性。

做到这些，才能判断提升来自“更好的概念控制”，还是更强扰动、数据泄漏或调参预算差异。

10 | 逐式索引：原文(1)–(78)与未编号公式

这一章是对照原文的导航，不代替前面各章的推导。**所有编号公式都有对应说明**；同一个计算链的重复写法合并解析，不假装它们是不同定理。

原文公式的逐字LaTeX提取见 `output/original_formula_inventory.md` 与 `.json`。这是机器提取的原文，不会自动改正问题。理论解释与修正式以相应中文章节为准。

10.1 正文公式

原式	内容/计算作用	中文推导	核对重点
(1)	贝叶斯得到 $p_C(z) \propto p(z)q(b-a^\top z)$	第02章§2.2	用条件密度，不是零概率事件相除
(2)	多测量噪声乘积筛选	第02章§2.3	加归一化常数 N_e
(3)	概念求值的置换、尺度、偏移	第02章§2.5	与赋值平移约定一致
(4)	概念矩阵和目标值的对应	第02、04章	原文目标平移负号与(3)冲突
(5)	原子协向量的坐标对应	第04章§4.8	比较求值函数，不只比较向量
(6)	原子求值的逐坐标仿射关系	第02章§2.5、第06章§6.11	原子层面强于任意旋转
(7)	环境—原子精度矩阵 M	第02章§2.4	未出现为0，出现为 σ^{-2}
(8)	目标乘精度矩阵 B	第02章§2.4	目标0与未出现不同

10.2 定理2证明

原式	内容/计算作用	中文推导	核对重点
(9)	环境相关方差的 M	第04章§4.1	不同于主定理跨环境共享方差
(10)	环境相关方差的 B	第04章§4.1	$b/(\sigma_i^e)^2$
(11)	两套表示的密度换元	第04章§4.2	原文Jacobian方向需修正
(12)	作密度比，抵消Jacobian	第01章§1.7、第04章§4.2	这是证明的公共入口
(13)	高斯能量展开为二次+一次+常数	第02章§2.4、第04章§4.3	基准密度完全消失
(14)	向量化 $g = Ms^{\odot 2}/2 - Bs + \kappa$	第04章§4.3	原文省略常数向量
(15)	两套二次表达相等	第04章§4.3	需允许两侧常数不同
(16)	环境线性组合提取 $\tilde{s}_i$	第04章§4.4	满列秩系数矩阵的左逆
(17)	提取 $\tilde{s}_i^2$	第04章§4.5	平方也至多二次

原式	内容/计算作用	中文推导	核对重点
(18)	排除四次项，得仿射函数	第04章§4.6	非零二次齐次项的平方不可能消失
(19)	对平方恒等式取梯度	第04章§4.7	常数导数对齐
(20)	利用原子独立比较系数	第04章§4.7	与消除交叉单项式等价
(21)	每个替代原子只对应一个原子	第04章§4.7	对应系数不能全为0
(22)	反向推理建立置换	第04章§4.8	不允许两个原子塌到一个
(23)	构造协向量对应的线性映射	第04章§4.8	将独立行补成基
(24)	用公共 w 表示各原子偏移	第04章§4.8	满行秩保证可解
(25)	提升到环境概念矩阵	第04章§4.8	环境只选择共享原子的一部分
(26)	用 $f^{-1}(x)$ 写概念等价	第04章§4.8	不要求无关坐标线性
(27)	固定其他原子，只比较一维能量	第04章§4.9	隔离一个可变求值
(28)	代入仿射求值关系	第04章§4.9	保留常数偏移
(29)	比较二次系数	第04章§4.9	$\tilde{\sigma}^2 = \lambda^2\sigma^2$
(30)	比较一次系数	第04章§4.9	真正一次系数为 $-b/\sigma^2$
(31)	目标值的变换	第04章§4.9	原文负号与展开不符
(32)	矩阵形式的目标变换	第04章§4.9	与求值同向加偏移

10.3 定理1证明：标准化与几何

原式	内容/计算作用	中文推导	核对重点
(33)	每原子共享方差的 M	第05章§5.1	可依原子变，不能任意依环境变
(34)	对应 B	第05章§5.1	目标乘精度
(35)	再次展开密度比	第02章§2.4、第05章§5.1	需保留归一化常数
(36)	标准化坐标、生成映射、密度	第05章§5.1	密度Jacobian需含 Σ
(37)	标准化赋值 $b/\sigma - \ell$	第05章§5.1	可直接代入验算
(38)	$\overline{M} = MD_\sigma^2$	第05章§5.1	得到0/1筛选矩阵
(39)	$\overline{B}$ 的变换	第05章§5.1	原式尺度因子不一致；本手册给出修正
(40)	验证标准化后高斯权重	第05章§5.1	Σ^{-1}；高斯log含常数
(41)	将标准化目标代回	第05章§5.1	标准化残差相同
(42)	多个筛选因子相差正常数	第05章§5.1	归一化后才是同一推前分布
(43)	标准化环境分布对应	第05章§5.1	含坐标变换的密度关系

原式	内容/计算作用	中文推导	核对重点
(44)	标准坐标中的环境二次函数	第05章§5.2	原子成为坐标轴
(45)	定义 $g^e = \log p^0 - \log p^e$	第05章§5.2	与分类logit方向相反
(46)	潜密度比等于观测密度比	第01章§1.7、第05章§5.2	公共体积项消失
(47)	简写 $g^e = G^e \circ f$	第05章§5.2	总体可识别不等于样本可精确估计
(48)	环境函数和的极小集 I_T	第05章§5.3	全空间/支持条件关键
(49)	环境和按坐标可分	第05章§5.3	每个坐标是一维二次函数
(50)	极小集固定并集内全部概念	第05章§5.3	维度 $d_z - \lvert S_T \rvert$
(51)	极小集在观测空间的像	第05章§5.3–5.4	维度识别并集基数，容斥恢复 M
(52)	排除原子i的环境隔离其他坐标	第05章§5.5	使用假设5
(53)	受限函数只含一个二次坐标	第05章§5.5	其他项成为常数
(54)	再取极小值，令 $z_i = B_{e_1 i}$	第05章§5.6	使用同一原子的环境
(55)	两次极小值之差为目标距离平方/2	第05章§5.6	识别一维点集，固定平移与反射

10.4 定理1最后的代数与引理3

原式	内容/计算作用	中文推导	核对重点
(56)	两套概念坐标产生同一环境函数	第06章§6.1–6.2	投影维度与环境常数需谨慎
(57)	$\partial_i g^e = M_{ei} z_i - B_{ei}$	第06章§6.3	一次求导
(58)	$Dg = M\,\mathrm{Diag}(z) - B$	第06章§6.3	$m \times n$矩阵
(59)	链式法则得到过渡Jacobian关系	第06章§6.3	核心矩阵等式
(60)	叠加 M^+ 与 $v^\top$	第06章§6.4	构成 $(n+1) \times m$矩阵
(61)	变为 $H(z) = H(\tilde{z}) D\psi$	第06章§6.4–6.5	对角未知量加非零底行
(62)	原坐标的左零向量	第06章§6.6	一维左零空间
(63)	同一向量也消去替代矩阵	第06章§6.6	用到 $D\psi$ 可逆
(64)	排除最后一个分量为0	第06章§6.6	否则 K 有非平凡核
(65)	排除其他分量为0	第06章§6.6	子式最高次项含非零 r_i
(66)	相减得到 $w_i(z_i - \tilde{z}_i) = 0$	第06章§6.7	结果长度应为n
(67)	概念求值一致	第06章§6.8	连续性扩展例外点，再撤销标准化
(68)	原子置换与坐标变换的逆	第06章§6.11	协向量转置须保持一致
(69)	反向偏移的选择	第06章§6.11	原子独立使偏移可解

原式	内容/计算作用	中文推导	核对重点
(70)	重述原子级仿射关系	第06章§6.11	可直接求逆
(71)	反向原子求值关系	第06章§6.11	逆尺度与反置换
(72)	提升到环境偏移关系	第06章§6.11	共享原子确保兼容
(73)	反向环境求值关系	第06章§6.11	R^{-1}仍是单项矩阵
(74)	反向概念矩阵关系	第06章§6.11	线性映射求逆
(75)	反向目标值关系	第06章§6.11	原文此处 $w/\widetilde{w}$ 与符号须统一

10.5 附录C

原式	内容/计算作用	中文推导	核对重点
(76)	贝叶斯重加权分布	第08章§8.7–8.8	边缘通常不是 q_V
(77)	法向子空间上的高斯分布	第08章§8.10	子空间协方差与全空间协方差不同
(78)	多组概念的边缘协方差约束	第08章§8.11	不保证唯一，给出正交反例

10.6 未编号公式不能漏掉

原文位置	公式内容	中文解释与证明
§3.1，定义1前后	$X = f(Z)$、$AZ = b$、$A^{+}A$投影	第01章§1.2、1.5，第02章
§3.2，定义4后	$\langle a, Z\rangle = \langle Ta, T^{-\top}Z\rangle$	第02章§2.5
§4，定理2动机	$\Lambda = (M, B)$满秩	第03章§3.7，第04章
§5.1，引理2	高斯筛选产生二次logit	第02章§2.4，第07章§7.1
§5.2	$H(x) + \alpha\sigma\eta$、均值激活差	第09章§9.2–9.7
§5.2	相似度加权 $\eta(x)$	第09章§9.8–9.10
附录B.1	高斯SCM $Z = AZ + \epsilon$	第08章§8.1–8.2（邻接矩阵另记为W）
附录C方案一	$q_V(v)p(c \mid v)$	第08章§8.5、8.8
附录C方案二	$q_V(v)p(c)$	第08章§8.6、8.8
附录C	正交分解、法向目标、$(A^{\top}A)^{-1}$	第08章§8.4、8.10
附录D.1	attention head残差前向	第09章§9.2
附录D.1	线性探针与head选择	第09章§9.3
附录D.1	ITI编辑前向	第09章§9.2

原文位置	公式内容	中文解释与证明
附录D.3	真假仿射概念集合	第09章§9.4
附录D.3	$A^{+}(b_1 - b_0)$	第01章§1.5，第09章§9.5完整证明
附录D.3	配对约束 $AH_F = b_0, AH_T = b_1, B_i H_F = B_i H_T$	第09章§9.6–9.7
附录D.3	真假精确、正交概念近似保持	第09章§9.5–9.8，明确条件
附录D.3	常权重与动态权重组合	第09章§9.8–9.9
附录D.3	相似度内积与外积矩阵分解	第09章§9.10–9.11，纠正右乘向量
附录E	二次分类头与CE+ℓ_1	第07章§7.2–7.6，包含所有参数梯度
附录G	目标密度、归一化常数、接受条件	第07章§7.8–7.9
附录G引理4	接受概率积分链	第07章§7.9
附录G推论1	几何分布期望	第07章§7.9
附录G定理3	接受后CDF/条件分布的积分链	第07章§7.10，另补首次接受求和

重复的内联数学符号不另造新“定理”。如果某个地方在机器原式中和本手册不一致，优先查看第11章，而不是尝试强行把两边算成相同。

11 | 原文核对清单：哪些是符号问题，哪些是条件或证据边界?

本章依据下载的 **arXiv v2原始TeX** 与HTML核对，不仅依赖网页转录。以下是本手册的非正式核对意见，**不是作者发布的勘误，也不是对整篇论文所有结论的形式化审计。**

分为三类：

- **代入即可核实的不一致**：给出明确修正式或反例。
- **证明需要明确的条件**：不能仅靠改一个符号解决。
- **理论与实验的证据边界**：不等于数学错误，但影响如何解释结果。

11.1 求值平移与目标平移的正负号

位置：定义4的(3)(4)，附录A.1的(24)、(28)–(32)。TeX中定义的关键行为505–512，(32)的加号位于1244附近。

由 $\tilde{s} = \lambda(s + d)$ 必有 $\widetilde{b} = \lambda(b + d)$，而不是 $\lambda(b - d)$。原文(31)写减号，下一行(32)又写加号。

影响：若按字面同时使用这些关系，会得到矛盾。只把同一个 w 改名成 $-w$ 不能同时保留求值式中的加号和赋值式中的减号。第04章用一维数值验算解释。

11.2 换元Jacobian方向

位置：(11)。若 $\tilde{z} = \varphi(z)$，应为

$$p(z) = \tilde{p}(\varphi(z))|\det D\varphi(z)|.$$

原文该侧写逆映射Jacobian。后续作密度比时公共项抵消，所以主要路线可修正后继续。

11.3 常数项不应从精确密度恒等式中悄悄消失

位置：(14)(15)、(35)、(40)(41)、(56)。密度归一化产生环境常数，归一化高斯还有对数常数。

影响：导数、argmin或同一函数的差值不受常数影响，因而许多证明步骤仍可通过保留常数来完成；但精确概率密度的相等、两套二次函数的逐点相等，不能不加说明地删常数。

11.4 标准化密度缺少尺度行列式

位置：(36)，TeX1402–1406。$L=\Sigma^{-1}Tz-\ell$，因此

$$\overline{p}(y)=p(L^{-1}y)|\det(T^{-1}\Sigma)|.$$

原式只含 $|\det T^{-1}|$。可作为比例表达式，但不能作为已经归一化的密度公式。

11.5 标准化B矩阵的尺度因子

位置：(39)，TeX1417–1419。按原文自己的定义应为

$$\overline{B}=BD_\sigma-\overline{M}\,\mathrm{Diag}(\ell).$$

原式的 D_σ^{-1} 及未转换的 M 与(37)不符。当所有 $\sigma_i=1$ 时部分问题被掩盖。第05章给出了 $\sigma=2$ 的反例。

11.6 标准化使用的是Σ的逆

位置：(40)，TeX1402与1428。前文定义 $L=\Sigma^{-1}Tz-\ell$，代入行却一度写 $\Sigma Tz-\ell$。后续展开又使用 σ_i^{-1}，所以应按逆矩阵理解。

11.7 应按列中心化，不是按行

位置：主证明Step1末尾，TeX1516；Step4使用 $\sum_e B_{ei}=0$。

平移第 i 个潜坐标改变的是环境—原子矩阵的第 i 列。固定平移自由度应对每个原子跨环境中心化，而非把每个环境横向的均值设为0。

同时，环境标签是已知的，因此识别 M,B 的自然不确定性是原子**列**的置换，不是任意环境行的置换。

11.8 单射可微不自动给光滑逆、满秩嵌入

位置：假设1，以及主证明中“过渡函数由假设可微”的使用。

反例：$f(t)=t^3$ 单射可微，但 $f^{-1}(x)=x^{1/3}$ 在0处不可微。高维情况也不能由单射可微直接得到所用的光滑流形结构。

本手册讲解换元、流形极小集维度和链式法则时，明确采用光滑嵌入与可微过渡等工作条件。要严格按原始最弱假设证明，需要额外论证，不能把这一点当作自动成立。

11.9 任意基准密度与全空间argmin的可观测性

位置：§3.2宣称对 p 不作更多限制；主证明(48)–(55)在全潜空间求极小。

若 p 只支持某个有界区域，密度比只在该支持上有定义；一个二次函数的全空间极小点可能不在数据支持内。此时不能直接从观测分布得知论文使用的完整极小集。

因此原证明路线需要正密度/足够支撑等条件，或另给局部论证。**这是证明适用条件的提醒，不是本手册已经给出了原定理在所有受限支撑下的反例。**

11.10 T与投影映射的维度

位置：定义4中先允许不同 d_z 又写 T^{-1}；主证明(56)把投影后的 φ^o 直接送入完整生成映射。

普通逆需要等维可逆映射；在光滑嵌入且共同观测流形的条件下，可以通过内在维度解释等维性，但应先说明。

最后的代数只需使用 $Q(z^c) = Q(\psi(z^c)) + d$，不必把 n 维投影向量直接代入 d_z 维解码器。第06章按此写出维度一致的证明。

11.11 (66)的结果长度、引理1的“唯一”

(66)左边是长度 n 的行向量，右边末尾额外写0不合维度。引理1中的非零左零向量是“差一个非零尺度意义下唯一”，不是只有一个数值向量。这两处不会改变主要论证思路。

11.12 交叉熵的负样本分布写错索引

位置：附录E，TeX2522。抽 $j \in \{0, e\}$ 后应取 $X \sim P^j$，原式两种标签都取 $X \sim P^e$。

按字面实现会让标签独立于数据，最优logit为0。第07章给出正确损失与所有参数梯度。

11.13 算法参数化不自动等于定理模型类

位置：附录E的自由二次头。任意自由的 β_{ei}, γ_{ei} 不自动满足跨环境方差共享与支持耦合。单独 $\ell_1(\beta)$ 还存在表示尺度放大的退化方向。

影响：总体分类最优与概念可识别之间仍需核查模型约束，不能仅凭分类准确率宣称定理条件已被实现。

11.14 “任意加权组合精确保留目标值”缺少权重和条件

位置：附录D.3，TeX2443、2449。

$$A\sum_i w_i\Delta_i = (\sum_i w_i)(b_1 - b_0).$$

精确达到同一目标通常需权重和为1。负权重可使目标信号抵消或反向，单位化不能修复。第09章给出可运行反例。

此外，“给一对激活两端都加同一向量后仍相等”不等于“该向量不改变某个概念”；后者应检验 $B\eta = 0$。

11.15 Steering matrix应右乘句向量

位置：附录D.3，TeX2471–2477。

若矩阵为 $S = \sum_i \Delta_i \lambda(c_i^F)^\top$，正确恒等式是 $\eta(x) = S\lambda(x)$。原文写成 $SH(x)$，除非两个表示额外相同，否则既可能维度不符，也可能数值不等。

这是矩阵因式分解的直接检查，不是对某个未公开实现到底用了哪个向量的猜测。

11.16 附录C协方差唯一性推测不成立

位置：(78)后。边缘协方差约束不指定交叉协方差，即便子空间正交，也可有 $\Sigma_\rho = \left[\begin{smallmatrix} 1 & \rho \\ \rho & 1 \end{smallmatrix}\right]$ 的连续解族。

另一个问题是宽矩阵 A 的 $A^\top A$ 奇异，不能直接写普通逆；需限制到法向子空间或用伪逆。第08章完整解释。这些探索性讨论不是主定理的证明前提。

11.17 合成实验的环境描述需要进一步说明

位置：附录F，TeX2537以及 $m = n + 1$ 的说明。

若“所有概念都是原子”意味着每个环境只含一个原子，则 $n \geq 2$ 时 $n + 1$ 个条件环境无法让每个原子至少出现两次，因而无法满足假设4。

这说明字面实验描述与理论假设无法直接对齐。不能在没有代码或作者说明时断言实际实验一定采用了何种未写明的构造。本学习包未复现该实验，也不伪造相应结果。

11.18 拒绝采样的上界等式

位置：附录G引理4证明。对一般 $M \geq \max(q)^k$，不能在等式链中直接替换成精确峰值幂。保留 M，接受率仍是 N_C/M，正确性也不受影响。

11.19 LLM部分的解释不是因果识别定理

真实文本离散、激活高度受网络结构约束；预训练数据多样不自动满足本文高斯筛选模型。均值抵消需要噪声零均值等条件，多个探针或指标trade-off也不能唯一证明某种语义几何。

论文自己明确将D.3定位为启发式。理解时应保留这一层级，不能为了“形成理论体系”把所有观察都升级成定理。

11.20 怎样使用这份清单而不失去主线?

还有一个常见的概率与几何混淆：将 $Az = b$ 左乘伪逆，几何上可改写为投影约束；但高斯噪声的独立性、方差和坐标体积并不会自动保持。正文定义1后的投影说明与附录C的各向同性描述，应在同步处理噪声协方差后理解，而非任意非正交变换下概率模型都不变。

先按一致符号把模型与两条证明走通；再逐条核对哪些修改只影响写法、哪些需要新增条件、哪些影响实验解释。

最值得学习的仍是：密度比消去复杂性、用可观测函数的几何识别隐结构，以及通过左零空间压缩剩余非线性自由度。正确的批判阅读不是忽略贡献，也不是替作者补出未经证明的更强结论。

12 | 练习与逐题答案：从看懂到自己推导

建议先遮住答案，用纸笔完成。目标不是背公式，而是能解释每一步用了哪个假设。

A组：模型与计算

题1：概念维度与平面维度

在 $\mathbb{R}^5$ 中，A 为满行秩 2×5 矩阵，概念维度、核维度和非空集合 $Az=b$ 的维度各是多少?

▼ 答案

概念维度2，核维度 $5-2=3$，仿射集合维度3。约束数与解集自由度不要混淆。

题2：非线性观测中的线性概念

贯穿例子中，给 $x=(2,7,4,\sin 2)$，算两个概念值。

▼ 答案

$s_1=2$，$s_2=7-2^2=3$。潜变量第三坐标为4。第二概念在潜空间线性，在观测空间是二次函数。

题3：自己做一次贝叶斯筛选

基准 $z\sim\mathcal{N}(0,1)$，筛选目标 $b=2$、标准差 $\sigma=1$。求后验均值、方差及拒绝采样接受率。

▼ 答案

均值1、方差 $1/2$；接受率 $2^{-1/2}e^{-1}\approx 0.26013$。平均尝试次数 $\sqrt{2}e\approx 3.844$。

题4：B中的0是什么意思?

$B_{ei}=0$ 能推出环境 e 没有筛选原子 i 吗?

▼ 答案

不能。原子可能被筛选到目标0，此时 $M_{ei} > 0$ 但 $B_{ei} = 0$。筛选支持由 M 区分。

题5：验证一个环境构造

对 $n = 3$，取 $M = [I_3; \mathbf{1}^\top]$，前三个环境目标0，最后目标 $(1, 2, 3)$。找 v 并验证假设4和5。

▼ 答案

$v = (-1, -1, -1, 1)^\top$。$v^\top M = 0$、$v^\top B = (1, 2, 3)$，M 秩3。任意原子对可用对应单原子环境分离，故假设5成立。总环境数为5，而非4。

题6：共享原子与各环境任意方向的区别

环境各自选一个随机方向；如果这些方向总数大于n，能否直接套用“只有n个共享原子”的定理?

▼ 答案

不能。假设2要求每个环境的行来自同一组线性独立的 n 个原子。任意不同方向即使都位于同一个n维子空间，也不等于从同一原子字典选行。

B组：证明关键点

题7：密度比为什么消掉Jacobian?

写出两环境各自的换元公式，再相除。若环境使用不同的 f_e，还成立吗?

▼ 答案

共同映射时 $p_X^e(f(z)) = p_Z^e(z)/J_f(z)$，所以比值中的 J_f 消失。若不同环境使用不同映射，一般不消失，而且“同一个x对应同一个z”的比较本身也不再自动成立。

题8：多项式次数论证

假设 $u(s)$ 和 $u(s)^2$ 都是至多二次多项式，证明 u 至多仿射。为什么有限训练点上不能这样证明?

▼ 答案

若 u 有非零齐次二次项 P_2，则 u^2 的四次部分为非零 P_2^2，矛盾。这个结论使用开集上的多项式恒等；有限点上的拟合相等不足以比较所有单项式系数。

题9：为什么逐原子只允许置换与尺度?

设 $\tilde{s}_1 = s_1 + s_2$，计算平方，指出不被原统计量允许的项。

▼ 答案

平方为 $s_1^2 + 2s_1s_2 + s_2^2$。交叉项 $2s_1s_2$ 不能由仅含平方项、一次项、常数的环境线性组合产生。

题10：识别极小集的维度

$F(z) = \frac{1}{2}(z_1 - 1)^2 + 2(z_3 + 2)^2$ 定义在 $\mathbb{R}^4$。极小集、维度与被筛选原子数是什么?

▼ 答案

极小集为 $\{z_1 = 1, z_3 = -2\}$，z_2, z_4 自由，维度2、余维2，识别到两个被使用的独立方向。正二次系数的大小不改变余维。

题11：距离恢复赋值

三个目标的两两距离为 $d_{12} = 2, d_{13} = 5, d_{23} = 3$。恢复一组坐标，并中心化。

▼ 答案

可取 $(0, 2, 5)$；中心化得到 $(-7/3, -1/3, 8/3)$。整体加常数或反射后仍有相同距离。

题12：主证明中哪里用了假设4的每个非零分量?

▼ 答案

用在删去第 i 行后的子式最高次项：$\pm r_i \prod_{j\neq i} z_j$。若 $r_i = 0$，该证明不能保证对应法向分量几乎处处非零，随后无法由 $w_i(z_i - \tilde{z}_i) = 0$ 推出该坐标一致。

题13：在z=(3,4)手算左零向量

不看第06章，计算 C, r, K, w，检验 $w^\top H = 0$。

▼ 答案

C 两行都是 $(1/3, 2/3)$，$r = (1, 2)$。$K = [[8/3, -2/3], [-1/3, 10/3]]$；$w = (6/13, 9/13, 1)$。逐列内积分别为 $16/13 - 3/13 - 1 = 0$、$-4/13 + 30/13 - 2 = 0$。

题14：为什么连续性不可少?

任意函数若只在一个点改变数值，是否仍与恒等函数几乎处处相同？这能否支持“处处相等”？

▼ 答案

它仍几乎处处相同，但在该点不相同。连续性排除了这种修改，才能利用正常点的稠密性推到所有点。

C组：算法与大模型

题15：非平衡分类先验

正类比例 $\pi = 0.8$ 时，最优分类logit与对数密度比差多少?

▼ 答案

差常数 $\log(0.8/0.2) = \log 4$。必须扣掉先验，或让分类头截距吸收它。

题16：拒绝采样上界变松

若把合法上界 M 变成 $2M$，采样结果分布变吗？接受概率和平均次数怎么变？

▼ 答案

目标分布不变，因为条件接受后的常数仍抵消。接受概率减半，平均尝试次数翻倍。若错误地使用小于真实峰值的上界，接受概率可能超过1，算法一般不再正确。

题17：最小编辑

$A=(1,1)$，希望概念增加2。最小欧氏范数编辑是什么？若还想保持 $B=(1,0)$ 不变呢？

▼ 答案

仅要求 $A\eta=2$ 时，$\eta=(1,1)$。若另要求 $B\eta=0$，则第一坐标不能动，唯一解为 $(0,2)$，范数更大。A 与 B 不正交，所以最小原编辑并不保持 B。

题18：任意加权的反例

激活差为 $(1,1)$、$(1,-1)$，目标概念读取第一坐标。权重 $(1,-1)$ 为什么失败？

▼ 答案

加权和为 $(0,2)$。目标变化0、副作用2。把它归一化为 $(0,1)$ 仍无法改变目标概念。不能用“最终会单位化”掩盖目标信号抵消。

题19：矩阵维度核对

激活维度128，SBERT向量维度384，$S=\sum_i \Delta_i u_i^\top$ 是多少维？应右乘什么？

▼ 答案

S 为 128×384，右乘384维的句向量 $u(x)$，输出128维编辑方向。不能直接乘128维head激活。

题20：为什么均值法不能消除系统偏差?

设 $\Delta_i = \eta^* + \mu + \epsilon_i$，$E\epsilon_i = 0$。平均趋向哪里?

> **▼ 答案**
>
> 趋向 $\eta^* + \mu$。随机方差可以随样本量缩小，但偏差 μ 不会消失。这是检查真假配对数据的关键。

题21：从表2能否宣称全面胜出?

准确率29.5%对28.8%，但CE2.61对2.41、KL0.41对0.27。还需要哪些证据?

> **▼ 答案**
>
> 至少需要方差/置信区间、相同扰动预算下的性能比较、独立调参、跨数据与模型验证，以及生成质量和非目标能力评测。单一多选均值不够支撑全面优势。

题22：究竟发现了因果结构吗?

已经准确恢复 s_1, s_2，但只有其观察联合分布。是否可以直接判定 $s_1 \to s_2$?

> **▼ 答案**
>
> 一般不可以。还需要排除混杂，处理等价类，或引入函数模型、噪声、环境变化、干预等附加信息。本文主要解决概念测量的识别，不是图定向。

最终闭卷任务

在一页纸内画出论文逻辑链；在另一页纸上写出 p^e/p^0、五个假设、$H(z) = H(\tilde{z})D\psi$ 和 $\eta^* = A^+ d_b$ 的推导。若每个箭头都能解释依赖条件，就不只是记住了摘要。

13 | 形成理论体系：把这篇论文放回你的研究路线

13.1 用四层体系整理，而不是把所有概念混在一起

第一层：世界如何生成观测？

潜变量、混合映射、噪声、因果机制。这里要问模型是否合理、变量是否保留了必要信息。

第二层：给定数据，哪些对象在原则上可被识别？

这是总体分布层面的唯一性问题。本文属于**目标概念求值的部分可识别性**；它没有识别全部潜坐标或因果图。

第三层：怎样估计与优化？

有限样本、密度比估计、神经网络容量、正则、尺度退化、局部极值、计算复杂度。可识别定理没有自动解决这一层。

第四层：学到的量能支持哪些控制与预测？

输出分类、概念编辑、干预预测、规划、跨分布泛化。本文的LLM实验主要属于这一层的概念验证。

你原来的连续因果发现主要积累在第三层；向大模型迁移时，不要跳过第二层与第四层的连接条件。

13.2 从本文抽出三个可以重复使用的证明套路

套路一：密度比消掉公共未知项

$$p_e(z) \propto p_0(z)\exp\{\eta_e^\top T(z)\} \quad \Longrightarrow \quad \log\frac{p_e}{p_0} = \eta_e^\top T(z) - \log Z_e.$$

这不只适用于高斯。关键是环境如何调制共同基准分布，以及系数变化是否足以识别统计量。但换一种筛选分布后，可识别等价类与证明都需要重新分析。

套路二：把隐结构转成可观测函数的几何不变量

本文用argmin集合的维度、集合包含关系和受限最小值差识别隐藏原子使用模式与目标距离。可迁移的思想是“找在可逆坐标变化下保留的结构”，而不是盲目比较神经网络参数。

但几何对象的可识别性不保证它们可从噪声有限数据稳定估计。

套路三：对函数恒等式求导，再分析剩余对称性

$$Q(z) = Q(\varphi(z)) + c \quad \Longrightarrow \quad DQ(z) = DQ(\varphi(z))D\varphi(z).$$

接着通过左逆、秩、零空间或张量分解压缩 φ。这是从分布信息过渡到代数可识别性的常见框架。

13.3 结合你的优化背景，最有价值的进一步问题

方向A：从精确识别走向局部稳定性

主证明用 $w_i \neq 0$，但没有保证它远离0。有限样本中，密度比和导数稍有误差，接近零的 w_i 可能放大误差。

【补充的局部扰动计算，不是原文定理】 假设 M, B 已对齐、J 可逆，而只满足

$$H(z) = H(\tilde{z})J + E.$$

取 $w^\top H(z) = 0$，则

$$w^\top H(\tilde{z}) = -w^\top E J^{-1}.$$

相减并利用 H 的对角结构：

$$w_i(z_i - \tilde{z}_i) = (w^\top E J^{-1})_i.$$

因此

$$\boxed{|z_i - \tilde{z}_i| \leq \frac{\|w\|_2 \|E\|_2 \|J^{-1}\|_2}{|w_i|}.}$$

这只是一条在较强条件下的确定性局部界，还没有解决 M, B 估计误差、J 存在性或总体统计一致性。但它准确指出一个瓶颈：**识别条件非退化与数值稳定性的差距。**

可以问：如何设计环境、目标值或优化正则，改善 $\min_i |w_i|/\|w\|$ 与Jacobian条件数？这比泛泛“换一个网络提高性能”更接近你的既有研究方式。

方向B：让对比学习的参数化真正匹配识别模型

明确共享原子、环境支持和方差结构，研究尺度规范化、近端稀疏更新、环境选择与分类头约束。分别测量：密度比误差、概念恢复误差、优化速度、病态程度。

理论目标可以是受限模型下的驻点性质或局部恢复稳定性；不要把优化收敛当作因果真值保证。

方向C：带副作用预算的上下文相关概念编辑

以 $A\eta = d_b$ 为目标，把背景能力或其他概念变化纳入约束/代价。研究权重归一化、系统偏差、有效样本量与度量选择。

对比均值、动态矩阵与低秩矩阵时，固定扰动或KL预算。这样才能分辨“更好的上下文选择”与“仅仅更强的干预”。

这些都是研究候选问题，不是对新颖性的保证；应继续检查后续文献。

13.4 最小可实施学习实验，不冒充原论文复现

1. 先用本手册的 $n = 2, d_z = 3, d_x = 4$ 模型，核对每个环境的 M, B、接受率与潜分布。
2. 用真实 $s(x)$ 计算密度比，检验理论恒等式。
3. 再训练一个小共享编码器，观察总体理论与有限样本训练之间的差距。
4. 有意让环境假设失败：原子总一起出现、目标不变、一个原子仅出现一次。
5. 加入表征误差和环境噪声，画恢复误差与条件数的关系。
6. 最后才替换为冻结小型语言模型激活，并明确哪些原模型假设不再可验证。

本包已经执行的是代数、概率与数值教学检查，尚未执行第3步的神经网络训练或第6步的真实LLM实验。

13.5 原文相关文献怎样组织?

不需要先读完全部参考文献。按依赖关系分组：

- **可识别非线性ICA与iVAE**：Khemakhem等(2020)，Hyvärinen等(2019)。帮助理解充分统计量、环境变化与密度比路线。
- **非线性表示不唯一**：Hyvärinen与Pajunen(1999)，Locatello等(2019)。帮助理解为什么单环境独立性不够。
- **干预式CRL**：Brehmer等(2022)、Buchholz等(2023)、Ahuja等(2023)。对比它们需要什么干预信息、识别什么对象。
- **线性表示几何**：Park等(2023)、Tigges等(2023)。区分“经验线性现象”与“可识别理论”。
- **ITI**：Li等(2023)，arXiv:2306.03341。理解原始head选择、均值方向与实验协议。
- **TruthfulQA**：Lin等(2021)，arXiv:2109.07958。理解多选与生成评测的不同。
- **机制可解释性与activation patching实践**：原文引用的Olah、Zhang与Nanda等。理解干预证据能支持多强的结论。

此处只梳理本文引用依赖，不声称解析了这些参考论文的全部定理。

13.6 最终应在脑中留下的理论图景

环境提供识别信息，密度比提取这份信息，结构假设限制解释自由度，算法估计相应函数，干预实验检验这些函数是否真能用于控制。

每跨一层都要检查条件。能清楚说出这一点，并独立完成两条可识别证明与最小范数编辑推导，你就已经把这篇论文纳入了一个可继续扩展的理论体系，而不只是记住了几个公式。

词典 | 基础术语随查：直觉、定义、例子与论文用途

本词典包含61个词条，由 `glossary.cjs` 生成。它是教学补充，不是原论文的新增定义或结论。不要从头背诵；先读基础补课，再按卡点查询。正文的虚线术语和“查术语”按钮会打开相同的解释。

概率基础

随机变量 • random variable

直觉： 还没抽样时，用一个符号代表可能出现的数值；抽样后，它才落成一个具体结果。

定义： 随机变量是把随机结果映射成数的函数。Z通常表示随机变量，z表示一次实现；多个数一起记录就是随机向量。

例子： 随机抽一张图片，Z_1记录物体的颜色强度。抽之前Z_1不确定，抽之后可能得到$z_1 = 0.7$。

在论文中的用途： 论文用Z表示潜变量、X表示观测。分清大写随机对象和小写取值，才不会把一条方程当成一个概率。

> **别混淆：** “随机”不表示毫无规律；规律由概率分布描述。

概率分布 • probability distribution

直觉： 描述各种结果各有多容易出现，而不是一张具体图片或一个数。

定义： 离散分布给出$P(Z = z)$；连续分布通常用密度$p(z)$描述区域概率。分布本身是给集合赋概率的规则。

例子： 抛硬币的分布可以是正反各一半；扔100次得到的那串结果只是这个分布产生的一组样本。

在论文中的用途： 基准环境和筛选环境有不同分布，即使所有环境使用同一个生成映射。

> **别混淆：** 两个环境样本数量不同，不等于它们的生成分布一定不同；一次抽样也无法精确揭示总体分布。

概率密度 • probability density

直觉： 连续数值轴上“概率有多集中”的高度。概率是曲线下的面积，不是曲线高度。

定义： 若Z有密度p，则$P(a \le Z \le b) = \int_a^b p(z)\,dz$，且$p \ge 0$、$\int p = 1$。

例子： $Z \sim U[0, 0.2]$时，区间内密度为5，而整个区间的概率为$5 \times 0.2 = 1$。

在论文中的用途： 论文的p(z)、q(z−b)是密度。高斯密度可能大于1，所以拒绝采样必须除以合法上界。

> **别混淆：** 连续分布在单点上的概率可以为0，但该点的密度不必为0，也不必小于1。

期望 • expectation

直觉： 按照每个结果出现的可能性进行加权平均。

定义： 离散时$E[Z] = \sum_z zP(Z = z)$；连续时$E[Z] = \int zp(z)\,dz$，前提是相应期望存在。

例子： 公平骰子的期望为$(1 + 2 + 3 + 4 + 5 + 6)/6 = 3.5$。一次投掷不可能出现3.5，但平均位置可以是3.5。

在论文中的用途： 配对激活差取均值，是希望非目标变化在平均中抵消。是否零均值需要假设和数据检查。

> **别混淆：** 总体期望不等于一次样本的值；样本均值也不保证恰好等于总体期望。

方差与标准差 • variance / standard deviation

直觉： 描述数值围绕均值散得多开。标准差与原变量同单位，方差使用平方单位。

定义： $\mathrm{Var}(Z) = E[(Z - EZ)^2]$，标准差为$\sqrt{\mathrm{Var}(Z)}$。

例子： 等概率取0和2：均值1，方差$[(0-1)^2 + (2-1)^2]/2 = 1$。等概率取−1和3，均值仍为1，方差变成4。

在论文中的用途： 高斯筛选的σ是噪声标准差，σ²才是方差。不要把它与潜变量本身的标准差混在一起。

> **别混淆：** 论文写N(μ,σ²)时第二个参数是方差；有些软件接口却要求传标准差。

协方差 • covariance

直觉： 检查两个数是否倾向一起偏大或反向变化，主要衡量线性共变。

定义： $\mathrm{Cov}(U,V)=E[(U-EU)(V-EV)]$。非零方差时，相关系数是协方差除以两个标准差之积。

例子： 若$U\sim U[-1,1]$、$V=U^2$，由对称性可得协方差为0，但V完全由U决定。

在论文中的用途： 附录C的协方差约束只固定部分边缘变化，不一定确定交叉协方差。向量的协方差矩阵把所有坐标对的协方差排成表。

> **别混淆：** 不相关通常不等于独立。对联合高斯这一特殊模型，零交叉协方差才可推出相应独立性。

统计独立 • statistical independence

直觉： 知道其中一个随机量的结果，不会改变另一个随机量的分布。

定义： 对任意合适集合A、B，$P(U\in A,V\in B)=P(U\in A)P(V\in B)$。有联合密度时对应$p(u,v)=p(u)p(v)$。

例子： 两枚独立硬币中，看到第一枚是正面，并不会改变第二枚正面的概率。

在论文中的用途： 含噪概念测量假设噪声与潜变量独立；多个测量噪声独立时，似然才能拆成乘积。

> **别混淆：** 这是随机变量的性质，不是向量的线性独立或正交。三个“独立/正交”概念不能互换。

条件概率与条件分布 • conditional distribution

直觉： 得到额外信息后，重新计算可能性。可以理解为只在满足信息的样本中比较比例。

定义： 当$P(B)>0$时，$P(A\mid B)=P(A\cap B)/P(B)$。连续条件常通过联合密度定义$p(z\mid y)=p(z,y)/p_Y(y)$。

例子： 100个物体中20个红色，其中8个是圆的。条件在“红色”后，圆形概率是8/20，不是8/100。

在论文中的用途： 论文的条件环境来自含噪测量或筛选，而不是默认执行了因果干预。

> **别混淆：** 连续条件Y=y不能机械地用两个零概率相除；应使用条件密度或适当的条件分布定义。

贝叶斯更新 • Bayesian update

直觉： 用新证据给原来的可能性重新加权，再把总量归一化。

定义： $p(z \mid y) = p(z)p(y \mid z)/p(y)$。先验$p(z)$是看证据前的分布；似然$p(y \mid z)$衡量给定z时证据多符合；后验是更新后的分布。

例子： 两种情况先验各1/2，证据似然分别0.8和0.2，未归一化权重为0.4和0.1；后验为0.8和0.2。

在论文中的用途： 公式(1)就是$p_C(z) \propto p^0(z)q(b - a^\top z)$：基准分布乘上概念测量的似然。

> **别混淆：** 似然作为z的函数，一般不是关于z已经归一化的概率分布。

归一化 • normalization

直觉： 把相对权重缩放成总和或总积分为1的概率。

定义： 若$w(z) \geq 0$且$0 < N = \int w(z)\,dz < \infty$，则$p(z) = w(z)/N$是密度，N叫归一化常数。

例子： 权重2、3、5的总和为10，归一化概率为0.2、0.3、0.5。只有比例信息，也能得到概率。

在论文中的用途： 论文环境密度需要除以Ne。取对数后，log Ne成为不随z变化的环境常数。

> **别混淆：** 向量除以自身长度也叫“归一化”，但它与概率归一化不是同一操作。

高斯分布 • Gaussian distribution

直觉： 由中心位置和扩散程度控制的钟形分布。

定义： $\mathcal{N}(\mu, \sigma^2)$的密度为$\frac{1}{\sqrt{2\pi\sigma^2}} \exp[-(z-\mu)^2/(2\sigma^2)]$，其中$\sigma > 0$。

例子： 标准高斯是$\mathcal{N}(0, 1)$。均值从0改成2会平移曲线；减小方差会使曲线更窄、更高。

在论文中的用途： 本文主要要求筛选噪声是高斯，从而对数密度比是概念值的二次式；不要求基准潜变量为高斯。

> **别混淆：** 多维高斯还要给协方差矩阵。只有对角协方差并满足联合高斯模型时，坐标才相互独立。

密度比 • density ratio

直觉： 比较同一位置在两个环境中相对有多常见。

定义： 在分母正的区域，密度比为$p^e(z)/p^0(z)$，对数密度比为$\log p^e(z) - \log p^0(z)$。

例子： 若$p^e(z) = p^0(z)w(z)/N_e$，则比值为$w(z)/N_e$。复杂的基准密度被约掉了。

在论文中的用途： 这是论文最核心的桥梁：用环境差异提取概念，而不必完整建模基准密度。共同可逆观测变换的体积项也会抵消。

> **别混淆：** 分母为0处不能直接相除。密度比大于1表示相对密度增加，不代表该点的概率超过1。

支撑集 • support

直觉： 数据分布实际上能到达的区域，而不是符号上允许写出的整个空间。

定义： 严格地说，支撑中的点的任意邻域都有正概率。对常见连续密度，可以从密度为正的区域及其边界来理解。

例子： 均匀分布U[0,1]不会产生2。只在[0,1]上观察数据，不能直接知道某个函数在2处的值。

在论文中的用途： 主证明在整个潜空间上找极小集；若数据只支持一个小区域，就需要额外说明如何知道区域外的极小集。

> **别混淆：** 有限样本没有碰到某处，不等于该处分布概率严格为0。

线性代数

向量 • vector

直觉： 把一组有顺序的数打包；也可在固定坐标系中表示一个方向或位置。

定义： 列向量$z = (z_1, z_2, z_3)^\top \in \mathbb{R}^3$有三个分量。行列方向影响矩阵乘法的维度。

例子： z=(2,3,4)可以记录三个潜因素。它有三个数，不意味着每个数已经有“颜色、大小、形状”的语义。

在论文中的用途： 潜变量、概念方向、激活差与编辑方向都用向量表示，但它们的空间和维度可以不同。

> **别混淆：** 坐标取决于表示方式。不同潜坐标中的两个向量，不能不做坐标对齐就直接比较。

内积 • inner product

直觉： 一个向量对另一个向量做加权求和；也能衡量方向对齐程度。

定义： 欧氏内积$a^\top z = \sum_i a_i z_i$，结果是一个标量。它等于$\|a\|\|z\| \cos\theta$。

例子： a=(1,2)、z=(3,4)时，$a^\top z = 1 \times 3 + 2 \times 4 = 11$。

在论文中的用途： 原子概念的数值就是$a^\top z$。a负责“怎样读”，z是“被读取的表示”，结果才是概念值。

> **别混淆：** 内积不是逐元素乘积向量；内积把所有分量相乘后还要相加。

矩阵 • matrix

直觉： 把多个线性测量排成一张表，一次读出多个数值。

定义： $A \in \mathbb{R}^{k \times d}$乘$d$维列向量，得到$k$维向量；第i个结果是A第i行与z的内积。

例子： $A = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}$、$z = (3,4)^\top$，则$Az = (3,8)^\top$。

在论文中的用途： 论文A的行表示概念方向；M的行表示环境；B表示环境目标乘精度。这三种矩阵不能混用。

> **别混淆：** 先查维度再计算。k×d矩阵不能直接右乘k维向量，除非k恰等于d。

转置 • transpose

直觉： 把矩阵的行和列互换。

定义： $(A^\top)_{ij} = A_{ji}$。列向量a转置后为行向量$a^\top$，这样$a^\top z$才是通常的标量内积。

例子： $\begin{bmatrix}1 & 2\\ 3 & 4\end{bmatrix}^\top = \begin{bmatrix}1 & 3\\ 2 & 4\end{bmatrix}$。

在论文中的用途： $v^TM=0$是左乘；$M^Tv=0$是同一个关系的转置写法。

> **别混淆：** 转置通常不是求逆。只有正交方阵等特殊情形，转置才等于逆矩阵。

线性映射 • linear map

直觉： 输入的加法和缩放可以直接穿过这个映射。

定义： $L(\alpha u + \beta v) = \alpha L(u) + \beta L(v)$。有限维空间中可用矩阵表示，且$L(0) = 0$。

例子： L(z)=2z是线性的；L(z)=2z+1是仿射而非线性；$L(z)=z^2$通常是非线性的。

在论文中的用途： 概念求值Az在潜空间里线性，生成映射f可以非线性，因此观测上的概念函数也可以非线性。

> **别混淆：** “线性”不是“容易”“看上去像直线”的同义词；必须看映射对加法和缩放是否满足定义。

线性独立 • linear independence

直觉： 这组向量中没有一个方向能完全由其他方向拼出来。

定义： 若$\sum_i c_i a_i = 0$只能推出所有$c_i = 0$，则这些向量线性独立。

例子： (1,0)与(1,1)独立但不正交；(1,0)与(2,0)不独立，因为第二个是第一个的两倍。

在论文中的用途： 假设2要求原子线性独立，才能把它们补成一个坐标系，并逐个比较多项式系数。

> **别混淆：** 线性独立不要求概念求值在统计上独立，也不要求向量互相垂直。

正交 • orthogonality

直觉： 在指定内积下方向互相垂直，投影为零。

定义： 欧氏空间中，$u^\top v = 0$表示正交。两个子空间正交，是指各自任意向量的内积都为0。

例子： (1,0)与(0,1)正交；(1,0)与(1,1)不正交，但它们仍线性独立。

在论文中的用途： 最小欧氏范数编辑在A的行空间中，因此不会改变与这个行空间正交的线性概念。

> **别混淆：** 一般可逆坐标变换不保持欧氏正交。几何正交不自动等于语义互不影响或统计独立。

张成空间 • span / column space / row space

直觉： 用一组向量作任意线性组合，能到达的全部方向。

定义： $\mathrm{span}(a_1, \ldots, a_n) = \{\sum_i c_i a_i\}$。矩阵的列空间由列向量张成，行空间由行向量张成。

例子： (1,0,0)与(0,1,0)张成三维中的一个平面；再加(1,1,0)不会增加新方向。

在论文中的用途： 主证明比较H(z)与H(ž)的列空间，进而找到它们共同的法向量。

> **别混淆：** 行空间与列空间可以位于不同维度的环境空间；不能只因秩相同就把二者当成同一个集合。

矩阵的秩 • rank

直觉： 矩阵中真正独立的信息方向有多少个。

定义： 秩等于列空间维度，也等于行空间维度。$m \times n$矩阵满列秩指秩为n，满行秩指秩为m。

例子： $\begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}$ 有3行但只有2列，秩为2；它满列秩，不满行秩。

在论文中的用途： M满列秩表示环境对各原子的筛选组合足够有区别；定理2需要更大的统计量系数矩阵满列秩。

> **别混淆：** 矩阵大、样本多或行列数多，并不自动意味着满秩；重复信息不会提高秩。

零空间 • null space / kernel

直觉： 输入沿这些方向变化，矩阵测量完全看不见。

定义： $\ker A = \{v : Av = 0\}$。若$Az = b$，则对任意$v \in \ker A$，都有$A(z + v) = b$。

例子： A=(1,0)只读第一坐标；所有(0,t)都在零空间中，改变第二坐标不改变该测量。

在论文中的用途： 配对激活差可分成目标所需改变量和A零空间中的非目标成分。

> **别混淆：** 零空间不是只有零向量的空间；通常包含很多非零向量。

左零空间 • left null space

直觉： 给矩阵的各行配权重，让加权结果完全抵消；等价于垂直于全部列向量。

定义： $\{v : v^\top M = 0\} = \ker M^\top$。若M有m行、秩为r，左零空间维度为m−r。

例子： 对三行两列的$M = [(1,0); (0,1); (1,1)]$，$v = (-1,-1,1)^\top$满足$v^\top M = 0$。

在论文中的用途： 假设4用左零向量消掉二次项；主证明的w则是H列空间的法向量。

> **别混淆：** v和w在证明中承担不同角色；左零向量也只在乘非零尺度的意义下可能唯一。

逆映射与可逆 • inverse

直觉： 可以从输出唯一地找回输入。

定义： 若f在其像集上单射，就有该像集上的逆f^{-1}。方阵T可逆时，$T^{-1}T = TT^{-1} = I$。

例子： f(z)=2z可由x/2恢复；f(z)=z²若定义在整个实数轴上，则无法区分z和−z。

在论文中的用途： 本文f把潜变量变为观测，f^{-1}才把观测变回潜表示。

> **别混淆：** 单射可微不保证逆映射处处可微；f(t)=t³的逆在0处不可微。

伪逆 • pseudoinverse

直觉： 普通逆不存在时，用一个有明确最小二乘/最小范数含义的替代算子。

定义： 满行秩时$A^{+} = A^{\top}(AA^{\top})^{-1}$，且$AA^{+} = I$。在约束可解时，$A^{+}b$给出$A\eta = b$的最小欧氏范数解。

例子： A=(1,1)、b=2时，所有解满足$\eta_1+\eta_2=2$；伪逆给出(1,1)，比(0,2)的长度更短。

在论文中的用途： 附录D的理想编辑是$A^{+}(b_1-b_0)$。第09章给出完整最小范数证明。

> **别混淆：** 一般$A^{+}A$不是单位阵，而是投影矩阵。不能把伪逆当成对所有输入都无损恢复的普通逆。

仿射空间 • affine space

直觉： 把过原点的线性空间整体平移；方向不变，位置可以变。

定义： 若$Az_0=b$有解，则$\{z : Az = b\} = z_0 + \ker A$。仿射映射的形式是Tz+c，允许有偏移c。

例子： 二维里y=0是线性子空间，y=2是平移后的仿射直线；它们方向相同、位置不同。

在论文中的用途： 同一概念A的不同赋值b对应平行仿射集合；图1(b)画的就是这个区别。

> **别混淆：** 仿射空间不一定经过原点；因此它通常不满足向量相加后还留在集合中。

维度与余维 • dimension / codimension

直觉： 维度数还可以自由变化的独立方向；余维数相对于整个空间少了几个自由方向。

定义： 在d维空间中，满行秩k个线性约束Az=b的非空解集维度为d−k，余维为k。

例子： 三维里一个平面有2个自由度、余维1；一条直线有1个自由度、余维2。

在论文中的用途： 论文“概念维度k”数的是独立测量数，不是满足概念的集合维度；极小集余维用于识别使用了几个原子。

> **别混淆：** 观测坐标个数d_x、潜空间维度d_z与目标概念数n，是三个不同的数字。

投影 • projection

直觉： 保留某个子空间中的分量，舍弃与它正交的分量。

定义： 欧氏正交投影矩阵P满足$P^2 = P$且$P^\top = P$。A^+A投影到A的行空间。

例子： 把(3,4)投影到横轴得到(3,0)；第二分量被舍去，通常不能再恢复。

在论文中的用途： 最小编辑属于概念行空间；配对差中落在其正交补内的部分可能形成副作用。

> **别混淆：** 投影一般不可逆。改写几何约束为投影形式，也不自动保持噪声独立同方差。

范数与最小范数 • norm / Euclidean norm

直觉： 用一个数衡量向量有多大；先指定测量大小的规则，才谈得上最小扰动。

定义： 欧氏范数$\|v\|_2 = \sqrt{\sum_i v_i^2}$；$\ell_1$范数$\|v\|_1 = \sum_i |v_i|$。

例子： (3,4)的欧氏长度是5，ℓ_1长度是7。同一个约束下，不同度量可能选出不同的最小编辑。

在论文中的用途： 伪逆编辑最小化的是固定激活坐标下的欧氏范数；一般坐标变换后，这种“最小”可能改变。

> **别混淆：** 小范数不自动意味着语义副作用小；网络输出对不同方向的敏感性可能不同。

正定矩阵与特征值 • positive definite / eigenvalue

直觉： 协方差对任何方向都不可能给出负方差；正定进一步要求每个非零方向都有严格正的方差。

定义： 对称矩阵G正定指$v^\top Gv > 0$对所有非零v成立；半正定允许等于0。特征向量满足$Gv = \lambda v$，λ为特征值。

例子： $\begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix}$的特征值是1+ρ和1−ρ；当|ρ|<1时都为正，因此矩阵正定。

在论文中的用途： 附录C的协方差反例、一般高斯配方和带度量的编辑推导都需要检查这些条件。

> **别混淆：** 矩阵所有元素为正并不等于正定；正定看的是所有方向的二次型，或对称矩阵的特征

> 值。

微积分与证明

导数与偏导数 • derivative / partial derivative

直觉： 输入轻微改变时，输出以多快的速度变化。

定义： 一元导数$f'(z) = \lim_{h\to 0}[f(z+h) - f(z)]/h$；偏导数则只改变一个坐标、固定其他坐标。

例子： $f(z) = z^2$时$f'(z) = 2z$；在z=3附近，输入增加0.01，输出约增加0.06。

在论文中的用途： 对$\frac{1}{2}Mz^{\odot 2} - Bz$求偏导，会把二次函数变成关于z的一次矩阵表达。

> **别混淆：** 导数描述局部变化，不等于整个函数值；导数为0也不自动意味着全局最小。

梯度 • gradient

直觉： 把一个标量函数对所有输入坐标的偏导排成向量。

定义： $\nabla L = (\partial L/\partial z_1, \ldots, \partial L/\partial z_d)^\top$，在欧氏度量下指向局部最快上升方向。

例子： $L(z_1, z_2) = z_1^2 + 2z_2^2$时，$\nabla L = (2z_1, 4z_2)^\top$；在(1,1)处为(2,4)。

在论文中的用途： 训练网络通过梯度更新参数；证明中也会通过求导提取环境函数的结构。

> **别混淆：** 梯度与Jacobian的形状取决于函数输出维度。不要把向量输出的所有导数都叫一个普通梯度向量。

雅可比矩阵 • Jacobian

直觉： 向量函数在一个点附近如何拉伸、旋转和混合小扰动的局部说明书。

定义： 对$f:\mathbb{R}^d \to \mathbb{R}^k$，$Df$是k×d矩阵，元素为$\partial f_i/\partial z_j$，且$f(z+\delta) \approx f(z) + Df(z)\delta$。

例子： $f(z_1, z_2) = (z_1, z_2 + z_1^2)$时，$Df = \begin{bmatrix} 1 & 0 \\ 2z_1 & 1 \end{bmatrix}$。

在论文中的用途： 密度换元中的体积项来自Jacobian；主证明对过渡函数求导后使用链式法则。

> **别混淆：** 只有方阵才有普通行列式。高维嵌入的体积因子不能直接写成非方阵的det。

链式法则 • chain rule

直觉： 一个变化先经过内层函数、再经过外层函数时，将两段局部变化组合起来。

定义： 一元时$(g \circ f)'(z) = g'(f(z))f'(z)$；向量时$D(g \circ f)(z) = Dg(f(z))Df(z)$。

例子： y=(2z+1)²时，导数是$2(2z+1) \times 2 = 4(2z+1)$，最后的2来自内层函数。

在论文中的用途： H(z)=H(z̃)Dψ(z)来自对两套概念表示产生相同环境函数这一恒等式求导。

> **别混淆：** 矩阵乘法的顺序不能随便调换；先检查各段输入、输出维度。

最小值与argmin • minimum / argmin

直觉： 最小值是最低的函数高度；argmin是达到这个高度的输入位置，可能有很多个。

定义： $\min_z F(z)$是数，$\operatorname{argmin}_z F(z)$是集合。本论文极小集写作argmin，使用的是全局最小位置。

例子： $F(z_1, z_2) = (z_1 - 1)^2$的最小值为0，argmin是整条直线$\{(1, t) : t \in \mathbb{R}\}$。

在论文中的用途： 主证明不是只看最低数值，而是看极小集合的维度，再看受限最小值之间的差。

> **别混淆：** 局部极小与全局最小不同。梯度为0的点也可能是极大点或鞍点。

多项式 • polynomial

直觉： 由变量的非负整数次幂相加组成的函数；次数记录最高的总幂次。

定义： $2z_1^2 + 3z_1z_2 + z_2 + 1$是二次多项式；$z_1z_2$是交叉项，$z_1^2z_2$总次数为3。

例子： 若$u = z_1 + z_2$，则$u^2 = z_1^2 + 2z_1z_2 + z_2^2$；平方会暴露两个坐标的混合。

在论文中的用途： 定理2利用“求值和其平方都至多二次”排除非线性，再用没有交叉项排除原子混合。

> **别混淆：** 比较多项式系数需要足够区域上的函数恒等；有限训练点拟合相等不足以证明这些系数恒等。

几乎处处 • almost everywhere

直觉： 允许一个相对于指定体积测度可以忽略的例外集合；不是说没有例外。

定义： 关于Lebesgue测度，有限点、平面中的曲线等常见低维集合可以测度为零。几乎处处相等意味着不相等的集合测度为零。

例子： 在实数轴上，改变一个点的函数值不影响常见积分，却会使两函数不再处处相等。

在论文中的用途： 主证明先在非退化点证明坐标一致，再利用连续性扩展到例外点。

> **别混淆：** Lebesgue零测集不一定对任意概率分布都概率为零；一个点质量分布可以把全部概率放在一个点上。

连续与可微 • continuity / differentiability

直觉： 连续表示输入足够接近时输出也接近；可微进一步要求局部能用线性变化近似。

定义： 可微蕴含连续，反过来通常不成立。连续性还能把稠密集合上的函数等式延拓到极限点。

例子： $|z|$在0处连续但不可微；z^3单射且可微，其逆$x^{1/3}$在0处却不可微。

在论文中的用途： 证明中的链式法则需要适当可微性，最后从几乎处处到处处则需要连续性。

> **别混淆：** 单射、连续、可微、光滑逆是不同条件，不能看到其中一个就默认其他全部成立。

模型与识别

潜变量与观测变量 • latent variable / observed variable

直觉： 观测变量是直接记录的数据；潜变量是模型用来解释数据、通常看不到的内部因素。

定义： 模型写成$X = f(Z)$：Z是潜变量，X是观测，f把潜因素变成可观测对象。

例子： 拍摄物体时，图片像素是观测；颜色、光照、相机角度等可以是潜因素。

在论文中的用途： 本文不要求学习的潜坐标等于真实世界的全部生成机制，只关心若干可解释概念求值。

> **别混淆：** 给潜变量起了“颜色”这个名字，不代表已证明它真的对应颜色或具有因果意义。

表征 • representation

直觉： 把复杂对象变成便于计算的一组特征，相当于给对象换一种记账方式。

定义： 表征可以是图片、文本对应的向量；学习表征是从数据中学习这种转换。一个可用表征不一定唯一。

例子： 同一温度可以用摄氏度或华氏度记录；同一图片也可以用多套可相互换算的特征表示。

在论文中的用途： 论文研究的不是任意特征都能解释，而是环境信息能把目标概念限制到什么等价类。

> **别混淆：** 能分类、能重建、可解释、可识别、具有因果意义是不同评价目标。

概念、原子与赋值 • concept / atom / valuation

直觉： 概念决定“读哪个属性”，赋值决定“这个属性要是多少”。

定义： 一般概念是线性映射A；原子概念只有一维输出。给观测x的求值是$Af^{-1}(x)$，筛选目标为b。

例子： a=(1,0)读取第一潜坐标；z=(3,4)时求值为3。目标b=1表示选择“第一坐标接近1”，不表示所有样本本来都等于1。

在论文中的用途： a、b、$a^{T}f^{-1}(x)$分别是方向、目标、实际求值。本文主要识别最后这个函数。

> **别混淆：** “原子”是输出维度为1的数学术语，不是已经证明存在的最小自然语言语义单位。

环境 • environment

直觉： 论文里是按特定规则取得的一组数据分布，不一定指物理场景。

定义： 基准环境分布为p^0；条件环境为$p^e \propto p^0 w_e$，所有环境共享同一个生成映射f。

例子： 从同一个图片库分别筛出红色物体、小物体、红色小物体，就可形成不同条件数据集。

在论文中的用途： 环境之间的多样性提供识别信息；n+2指环境数量，不是每个环境只需n+2个样本。

> **别混淆：** 任意不同的数据集不自动满足论文的高斯筛选、共享原子或环境多样性假设。

可识别性 • identifiability

直觉： 即使知道了所有总体数据规律，还有没有两种本质不同的解释都同样说得通？

定义： 若产生相同可观测分布的所有合法模型，只能相差预先允许的等价变换，就称目标在该等价意义下可识别。

例子： 若s和2s+3只差单位和零点，可以允许；若s与s加上另一个概念的混合也无法区分，逐原子识别就更弱。

在论文中的用途： 主定理限制目标概念求值的置换、尺度、偏移，不是保证恢复全部潜变量或因果图。

> **别混淆：** 可识别性是“原则上信息够不够”，不是“训练算法是否找得到”“有限样本误差有多小”。

等价类 • equivalence class / permutation

直觉： 把只差允许记号或坐标变换的表示视为同一种解释。

定义： 逐原子关系常写成$\tilde{s}_{\pi(i)} = \lambda_i s_i + c_i$，其中π是重排、λ非零、c是零点偏移。

例子： 将“颜色、大小”两列交换名称，或把米换成厘米，并没有损失同样的测量内容。

在论文中的用途： 论文识别到这样的等价类；一般旋转混合比置换与逐坐标缩放更自由。

> **别混淆：** 允许什么等价变换必须先定义。不能把所有不同模型都随意说成“只是换坐标”。

总体与有限样本 • population / finite sample

直觉： 总体是完整的数据生成规律；样本是这条规律随机产生的有限记录。

定义： 总体风险是对真实分布取期望的损失；经验风险是有限样本上的平均损失。二者一般不完全一样。

例子： 公平硬币的总体正面概率是1/2，但10次投掷可能出现7次正面；这不说明总体概率变成0.7。

在论文中的用途： 可识别性定理通常从总体分布相同出发；真实训练只能用有限数据近似估计。

> **别混淆：** “无限数据仍有歧义”和“有限数据估不准”是两个不同困难，不能混为一谈。

充分统计量 • sufficient statistic

直觉： 统计量是数据的函数；充分统计量在指定统计模型下保留了关于参数所需的信息。

定义： 一个严格刻画是：给定该统计量后，数据的条件分布不再依赖待估参数。它始终相对于某个模型和参数定义。

例子： 高斯对数密度可写成$\eta_1 z + \eta_2 z^2 - c$，因此z和$z^2$是自然出现的指数族统计量。

在论文中的用途： 定理2利用概念值及其平方的环境系数满秩，提取这些函数并压缩可识别等价类。

> **别混淆：** 这里不能只凭“压缩后好用”就宣称充分性，也不能忽略模型中未知基准分布等设定。

指数族 • exponential family

直觉： 把分布写成“公共基底 × 指数中的参数与统计量内积 × 归一化”的结构。

定义： 常见形式$p_\eta(z) = h(z)\exp[\eta^\top T(z) - A(\eta)]$，A负责让积分为1。

例子： 高斯中T(z)包含z和z^2；取对数后，复杂的指数变成关于这些统计量的线性组合。

在论文中的用途： 本文环境密度是共同基准乘上高斯筛选权重；密度比暴露了环境相关的统计量系数。

> **别混淆：** “对统计量线性”不表示“对原始数据线性”。T(z)=z^2本身就是非线性函数。

编码器与解码器 • encoder / decoder

直觉： 编码把观测变成特征；解码或生成把特征变回观测。

定义： 本论文生成方向是$Z \xrightarrow{f} X$，所以理想编码方向是$X \xrightarrow{f^{-1}} Z$。实际概念网络只输出目标特征，未必是完整可逆编码器。

例子： 图片输入编码器得到颜色、形状等向量；生成器把一组潜变量变成图像。

在论文中的用途： 正文和LLM部分对f的用法有方向差异，手册在LLM中改用H(x)表示激活提取，避免混淆。

> **别混淆：** 输出n个概念值不意味着可以用n<d_z个连续坐标无损重建整个观测流形。

学习与算法

损失函数 • loss function

直觉： 把模型做得不好这件事转成一个可计算、希望变小的数。

定义： 学习算法通常最小化样本损失加正则。损失的定义决定了模型被鼓励完成什么任务。

例子： 预测0/1标签时，交叉熵会给“对错误答案非常自信”的预测很大惩罚。

在论文中的用途： 本文通过区分基准与条件环境学习密度比，再利用共享结构约束概念表示。

> **别混淆：** 损失低不自动等于因果正确。模型可能利用捷径或落在不满足定理约束的参数空间。

对比学习 • contrastive learning

直觉： 通过比较或区分不同来源的样本，学习能解释差别的特征。

定义： 本文的具体做法是二分类：条件环境样本标签为1，基准环境样本标签为0，共享编码器为多个环境提供特征。

例子： 若红色物体是条件环境、整个图片库是基准环境，分类器需要捕捉两者的分布差异。

在论文中的用途： 两类先验相等时，最优logit是条件环境与基准环境的对数密度比。

> **别混淆：** “对比学习”是宽泛名称。不要把本文的环境分类损失与所有InfoNCE或配对学习算法视

> 作同一公式。

Sigmoid与logit • sigmoid / logit

直觉： Sigmoid把任意实数分数压到0与1之间；logit把概率变回相应的实数分数。

定义： $\mathrm{sigmoid}(r) = 1/(1+e^{-r})$；$\mathrm{logit}(p) = \log[p/(1-p)]$，要求0<p<1。

例子： r=0对应p=1/2；p=0.8对应logit=log4。r=2不是“概率为2”。

在论文中的用途： 附录E的二次分类头输出logit，经过Sigmoid后才得到预测标签概率。

> **别混淆：** “log概率”与“logit概率”不同。后者包含p与1−p的比值。

交叉熵 • cross entropy

直觉： 检查模型给真实答案分配了多少概率；真实答案概率越小，惩罚越大。

定义： 二分类单样本损失为$-y\log p-(1-y)\log(1-p)$。用logit r写成$\log(1+e^r)-yr$。

例子： 真实y=1时，p=0.8的损失为−log0.8≈0.223；p=0.2时约为1.609。

在论文中的用途： 最优总体交叉熵分类器给出真实条件标签概率，从而连接到密度比。

> **别混淆：** 交叉熵与准确率不同。两个模型分类对错一样多，置信度不同仍可有不同交叉熵。

正则化与稀疏 • regularization / sparsity

直觉： 在拟合数据之外，额外偏好某类结构，例如更少的非零参数。

定义： 常见目标是$L(\theta)+\lambda R(\theta)$。$\ell_1$惩罚为$\sum_i|\theta_i|$，常用于鼓励稀疏。

例子： 两个分类器拟合相近时，可以更偏好只使用少数概念坐标的那个。

在论文中的用途： 论文对二次头参数加稀疏正则；同时需要留意编码器放大、分类头缩小的尺度自由度。

> **别混淆：** 加了稀疏惩罚不代表已证明找到了真实原子；正则化也不能替代可识别性条件。

拒绝采样 • rejection sampling

直觉： 先从容易抽样的分布提议，再按一个概率保留样本，从而得到想要的分布。

定义： 目标$p_C \propto p^0 w$，若$0 \le w(z) \le M$，则从p^0抽z，以$w(z)/M$接受。

例子： 三种颜色先各抽到1/3概率，再以不同概率保留，就能改变保留样本中的颜色比例。

在论文中的用途： 附录G证明接受率为N/M，平均提议次数M/N，接受后的样本正是概念条件分布。

> **别混淆：** 上界太小会破坏正确性；上界太大或目标区域太稀有，会使算法很慢。

优化收敛 • optimization / stationary point / backpropagation

直觉： 优化是在某个已选定的目标函数上找小值；收敛只说明算法在某种意义上稳定或接近目标。

定义： 可微无约束问题的驻点满足$\nabla L = 0$，但可能是局部最小、极大或鞍点。反向传播是用链式法则高效计算网络参数梯度。

例子： $L(\theta) = \theta^2$在0处为最小；$L(\theta) = -\theta^2$在0处也梯度为0，却是极大。

在论文中的用途： 概念可识别不保证神经网络训练能找到正确解；优化达到驻点也不证明因果恢复。

> **别混淆：** 稳定训练、全局最优、统计一致和语义正确是不同层次的结论。

因果与LLM

因果干预 • causal intervention

直觉： 不是挑选已经发生的结果，而是主动替换系统里某个变量的生成机制。

定义： 结构方程模型写$Z_i = f_i(\mathrm{Pa}_i, \epsilon_i)$；$\mathrm{do}(Z_i = b)$把这一条方程替换成常数b，其他方程保持。

例子： 观察“开空调的房间更热”可能因天气炎热导致开空调；主动打开空调的效果不能只靠这种观察相关性判断。

在论文中的用途： 本文的条件筛选不自动等于do干预。编辑LLM激活是对模型内部的操作，也不自动证明外部世界的因果关系。

> **别混淆：** “干预”一词在不同领域含义有层级差别。必须说清改变了什么、保留了什么机制。

因果图与DAG • causal graph / DAG

直觉： 用箭头表示变量间的直接因果关系；DAG要求沿箭头走不会绕回原点。

定义： DAG是有向无环图，邻接矩阵记录哪些有向边存在。单有观察分布通常还会有因果方向的等价类。

例子： U→V→W无环；U→V→U含有有向环。你以前的连续因果发现主要在搜索这类图结构。

在论文中的用途： 本文A是概念测量矩阵，不是因果邻接矩阵；主定理也不恢复DAG。

> **别混淆：** 把特征画成流程图，不会自动使流程图变成经过识别的因果图。

概念编辑与steering • concept editing / steering

直觉： 在模型运行时给内部表示施加改动，希望某个概念或行为向指定方向变化。

定义： 在固定激活空间中，若概念测量是A，希望目标改变d，则要求$A\eta = d$；最小欧氏范数解在可解条件下为$\eta = A^{+}d$。

例子： 激活差(1,1)和(1,−1)平均为(1,0)，第一坐标目标保留，第二坐标副作用抵消。

在论文中的用途： ITI使用head激活差方向；矩阵版根据句向量产生上下文相关方向。

> **别混淆：** 能改变输出不等于精确恢复了真实概念，也不保证所有非目标能力或语境保持不变。

KL散度 • KL divergence

直觉： 衡量用一个概率分布来代替另一个分布时的信息差异；不是普通几何距离。

定义： 离散时$D_{\mathrm{KL}}(P\|Q) = \sum_x P(x)\log[P(x)/Q(x)]$，通常不对称；在适当绝对连续条件下非负。

例子： 若编辑后的模型给下一token分配的概率与原模型大幅不同，KL通常会变大。

在论文中的用途： 表2将准确率与KL一起报告，用来提醒模型行为改变有收益也有扰动。

> **别混淆：** KL小不保证回答真实或安全；KL大也不能单独证明任务能力变差。P与Q的方向必须说明。

激活与注意力头 • activation / attention head

直觉： 激活是网络处理某个具体输入时在中间算出的数值；注意力头是Transformer中产生特定信息汇聚输出的模块。

定义： 一层或一个head的激活通常是向量。模型权重在推理时通常固定，激活则随问题、token位置和上下文变化。

例子： 同一模型回答两个不同问题，其参数可以不变，但末token的head激活会不同。

在论文中的用途： ITI给选中的head输出加方向；探针用这些激活来预测真假标签。

> **别混淆：** 权重不是激活。探针能读出信息，也不等于沿其方向编辑一定获得最好的因果控制。