先修｜基础概念补课：从看懂符号到读懂第一条公式

这部分专门写给“以前学过，但很久没用”的你。**不要求先恢复整本概率论和线性代数，也不要一开始就啃证明。** 先建立对象、例子和术语之间的联系，再回到原论文。

正文中带虚线下划线的术语可以点击；右上角“查术语”也能按中文、英文或别名搜索。每个词条都有：直觉、定义、手算例子、论文用途和容易混淆的地方。静态版的全部解释在术语词典。

先修0｜先知道自己在学什么，不急着背定义

假设你有一堆物体图片，想研究“颜色”和“大小”。要区分三个问题：

1. **表示问题：** 图片能否用少量有用数值来描述？
2. **识别问题：** 不同模型都能解释这些图片时，怎样知道哪个数真的对应颜色，而不是颜色与大小的混合？
3. **控制问题：** 改动某个内部数值，能否改变颜色或行为，同时少影响其他东西？

这篇论文的严格理论主要研究第二问；LLM编辑是第三问的一种启发式应用。你的因果结构学习背景主要关注“变量之间怎样连边”，而这里先问“变量本身怎样确定”。

学习时只反复问四句话：这个符号是什么？输入和输出是什么？我能算一个例子吗？论文此处为什么需要它？

先修1｜先分清数、向量、矩阵和函数

1. 一个数：标量

温度25、概率0.8、某个概念值3，都是标量。标量只有一个数。

2. 一组有顺序的数：向量

设

$$z = \begin{bmatrix} 3 \\ 4 \end{bmatrix} \in \mathbb{R}^2.$$

这表示z有两个实数分量。你可以暂时把它理解成“颜色强度3、大小4”，但**语义只是我们给这个教学例子的设定，不是看到两个数就自动知道它们的意义。**

$\mathbb{R}^2$中的2数的是坐标数量。列向量竖着写，行向量横着写。$z^\top = (3,4)$中的上标$\top$表示转置，不是乘方。

3. 内积：指定怎样从向量读出一个数

取$a = (1,2)^\top$，则

$$a^\top z = 1 \times 3 + 2 \times 4 = 11.$$

可以把a看成一组读取权重：第一个分量读1份，第二个分量读2份。**a是读取规则，z是被读取的数据，11才是读取结果。**

4. 矩阵：同时执行多条读取规则

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 2 \end{bmatrix}, \qquad Az = \begin{bmatrix} 1 \times 3 + 0 \times 4 \\ 1 \times 3 + 2 \times 4 \end{bmatrix} = \begin{bmatrix} 3 \\ 11 \end{bmatrix}.$$

A的每一行是一条测量。论文用A表示概念测量，不是因果邻接矩阵。

先检查维度：$k \times d$矩阵乘d维列向量，输出k维向量。你可以把它记成“中间维度对得上，外面留下输出维度”。

5. 函数：输入到输出的一条规则

$f(z) = 2z$是规则；$f(3) = 6$是把输入3代进去后的计算。写f^{-1}表示逆函数，而不是通常意义上的$1/f$。

先修2 | “线性”“仿射”“非线性”有什么区别?

线性映射保留输入的加法和缩放：

$$L(\alpha u + \beta v) = \alpha L(u) + \beta L(v).$$

用最简单的例子检查：

- $L(z) = 2z$线性，因为$2(u+v) = 2u + 2v$，而且$L(0) = 0$。
- $F(z) = 2z + 1$不是线性，但属于仿射映射：它多了一个偏移。
- $G(z) = z^2$通常非线性，因为$(u+v)^2 = u^2 + 2uv + v^2$，不等于$u^2 + v^2$。

“概念在潜空间线性”说的是Az的形式；它不要求图像生成器f也线性。

一个可以自己反算的生成模型

$$x = f(z) = (z_1,\ z_2 + z_1^2).$$

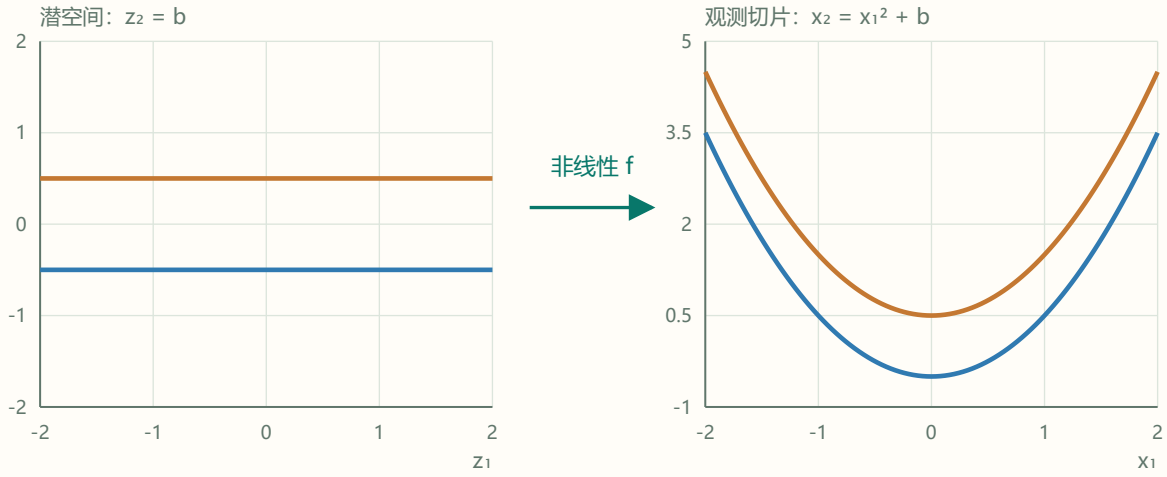
给$z = (2, 3)$，得到$x = (2, 7)$。反过来：

$$z_1 = x_1 = 2, \qquad z_2 = x_2 - x_1^2 = 7 - 4 = 3.$$

“读出第二个潜概念”的函数因此是$s_2(x) = x_2 - x_1^2$。它在z里线性，却在x里非线性。

概念在潜空间线性，不等于在像素或观测空间线性

教学补图 · 非论文原图



同一线性概念 z₂，在观测空间里对应弯曲的等值线。

这里只画 z₃ 固定的二维切片；第四维 sin(z₁) 未画出。

2402.09236v2 中文精读 · 示意或按讲义公式计算，不是新的训练实验

先修图解：先看“同一组对象换一种坐标后形状会变”，不必马上理解后面的可识别性证明。

先修3｜线性独立、正交、统计独立：三个完全不同的问题

线性独立问：向量能否互相拼出来？

$(1, 0)$和$(2, 0)$不独立，因为后者是前者的2倍。$(1, 0)$和$(1, 1)$独立，因为第二个方向带来了无法由第一个产生的竖向变化。

严格定义：$c_1 a_1 + c_2 a_2 = 0$只能在$c_1 = c_2 = 0$时成立，就叫线性独立。

正交问：指定内积下是否垂直?

$(1,0)^\top(0,1)=0$，所以这两个方向正交。$(1,0)$和$(1,1)$内积为1，不正交，但它们依然线性独立。

统计独立问：知道一个随机结果，会不会改变另一个的分布?

两枚独立硬币，知道第一枚的结果不会改变第二枚的正面概率。这说的是随机变量的联合规律，不是在检查固定向量能否相互表示。

论文要求原子向量线性独立，并没有要求它们正交，也没有要求概念数值统计独立。

先修4 | 秩、零空间、左零空间：把定义变成算式

秩：真正独立的信息方向数

$$M=\begin{bmatrix}1&0\\0&1\\1&1\end{bmatrix}.$$

第三行等于前两行之和，所以3行不等于3份独立信息。前两行独立，秩是2。两列独立，因此M满列秩。

零空间：输入变化了，但测量看不见

令$A=(1,0)$。它只读第一坐标，所以

$$A\begin{bmatrix}0\\t\end{bmatrix}=0.$$

所有$(0,t)$都在A的零空间中。若想改变第一概念而保持其他东西少变化，就要知道哪些成分会被A看见，哪些会被忽略。

左零空间：给行加权，把结果抵消

对上述M，取$v=(-1,-1,1)^\top$:

$$v^\top M=-(1,0)-(0,1)+(1,1)=(0,0).$$

它不是神秘的线性代数符号，只是“第三行减去前两行”。论文利用这样的权重抵消二次项。

右零空间检查$Mv = 0$，左零空间检查$v^\top M = 0$。两者向量长度通常不同；先看矩阵尺寸，就不容易写反。

先修5｜仿射空间、维度与余维：为什么论文一直在数平面？

在三维中：

- 不加限制，三个坐标都能变，有3个自由度。
- 要求$z_1 = 1$，还剩z_2, z_3自由，是一个平面，维度2、余维1。
- 再要求$z_2 = 2$，只剩z_3自由，是一条直线，维度1、余维2。

一般地，d维空间中的k条独立线性约束，在有解时留下$d - k$维自由度。

$Az = 0$的解集经过原点，是线性子空间；$Az = b$是它的平移，叫仿射空间。若$Az_0 = b$，所有解就是

$$z = z_0 + v, \qquad v \in \ker A.$$

论文“概念维度k”数的是测量数；满足测量的集合维度则是$d_z - k$。不要把这两个维度看反。

先修6｜概率分布不是一批数据，密度也不是概率

随机变量、样本与分布

还没抽图时，Z表示不确定的潜变量；抽到一张图后，可以得到某个具体值z。反复抽到的$z^{(1)}, \ldots, z^{(N)}$是一批样本。分布描述产生这些样本的概率规律。

一枚公平硬币的总体正面概率是1/2，但10次可能出现7次正面。样本比例0.7不代表总体规律已经变成0.7。

离散概率是点的比例，连续概率通常是区域的面积

连续变量可以落在无穷多个数上。密度$p(z)$告诉你概率在附近有多集中：

$$P(a \le Z \le b) = \int_a^b p(z)\, dz.$$

积分可以先理解为：把区间切成许多小段，将“曲线高度×小段宽度”相加，再让小段越来越细。

例如$Z \sim U[0, 0.2]$，密度在区间内为5。整个区间概率为$5 \times 0.2 = 1$。**密度5没有问题，概率5才有问题。**

对于有连续密度的分布，单点概率通常为0；这不表示该点附近不可能出现样本。

先修7｜期望、方差与高斯：先掌握位置和散布

期望是按出现概率加权的平均位置。若0和2各以一半概率出现，期望为1。方差检查围绕均值的平均平方偏离：

$$\mathrm{Var}(Z) = E[(Z - EZ)^2] = \frac{1}{2}(0-1)^2 + \frac{1}{2}(2-1)^2 = 1.$$

标准差是方差的平方根。期望不必是某次抽样能出现的值：骰子期望3.5，但没有一面写着3.5。

高斯分布$\mathcal{N}(\mu, \sigma^2)$有两个基本参数：中心μ与方差σ²。其密度是

$$p(z) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(z-\mu)^2}{2\sigma^2}\right].$$

先读指数部分：离中心越远，负的平方越大，密度越小；σ越小，远离中心下降得越快。前面的系数负责让整条曲线下面积为1。

本文假设高斯的是筛选噪声，不是任意基准分布。 基准可以相关、复杂、多峰。

先修8｜条件概率、似然与贝叶斯：从筛选物体开始

设有100个物体，50个红色、50个蓝色。一个不完美的筛选器：

- 红色物体有80%概率通过；
- 蓝色物体有20%概率误通过。

在这组整齐的教学数据里，通过者是40个红色、10个蓝色。通过后是红色的概率为

$$P(\text{红} \mid \text{通过}) = \frac{40}{40+10} = 0.8.$$

写成“先加权、再归一化”就是

$$\frac{0.5 \times 0.8}{0.5 \times 0.8 + 0.5 \times 0.2} = 0.8.$$

先验0.5表示筛选前的比例；似然0.8表示红色情况下证据有多容易出现；后验0.8表示看到证据后重新计算的比例。分母是所有情况的加权总量。

这就是贝叶斯更新。连续情形把求和换为积分，形式保持：

$$p(z \mid y) = \frac{p(z)p(y \mid z)}{\int p(u)p(y \mid u)\,du}.$$

注意：刚才红蓝数量算得整齐是教学设定；真实随机筛选次数只会在平均意义上接近这些数量。

先修9｜怎样把这篇论文的第一个公式读成人话?

假设z是真正被表示的潜向量，我们想知道某个概念数值$a^\top z$。现实测量有噪声：

$$\tilde{b} = a^\top z + \epsilon.$$

- a：决定读哪个方向；
- $a^\top z$：这一张样本的真实概念数值；
- ε：测量误差；
- $\tilde{b}$：我们看见的含噪测量。

若噪声密度是q，看见测量结果b时，这个潜状态的似然就是$q(b - a^\top z)$。误差越符合噪声规律，该状态越容易解释测量。

于是

$$\boxed{p_C(z) = \frac{p^0(z)q(b - a^\top z)}{N_C}}, \qquad N_C = \int p^0(u)q(b - a^\top u)\,du.$$

逐段翻译：筛选后的分布 = 筛选前分布 × 测量匹配程度 ÷ 所有状态的总权重。

符号∝表示“只差一个不随z变化的正常数”。所以$p_C(z) \propto p^0(z)q(b - a^\top z)$不表示作者忘了归一化，而是暂时省略了分母。

多个测量在给定z时噪声独立，似然才能写成乘积。这正是原文公式(2)的来源。

先修10｜一维高斯筛选，逐行算到最后

设基准是$\mathcal{N}(0,1)$，希望测量接近b=1，噪声也为标准高斯：

$$p^0(z)=\frac{1}{\sqrt{2\pi}}e^{-z^2/2},\qquad q(1-z)=\frac{1}{\sqrt{2\pi}}e^{-(z-1)^2/2}.$$

相乘时前面系数相乘、指数相加：

$$p^0(z)q(1-z)=\frac{1}{2\pi}\exp\left[-\frac{z^2+(z-1)^2}{2}\right].$$

逐步配方：

$$z^2+(z-1)^2=2z^2-2z+1=2(z-1/2)^2+1/2.$$

所以乘积为

$$\frac{e^{-1/4}}{2\pi}\exp[-(z-1/2)^2].$$

归一化后成为

$$\boxed{p_C=\mathcal{N}(1/2,1/2).}$$

因为指数中$(z-1/2)^2$前的系数是1，与高斯形式$1/(2\sigma_C^2)$比较，就得到$\sigma_C^2=1/2$。中心直接读为1/2。

如果想核对分母，利用$\int e^{-t^2}dt=\sqrt{\pi}$（积分范围为整个实数轴），得到

$$N_C=\frac{e^{-1/4}}{2\sqrt{\pi}}\approx 0.21970.$$

▼ 可选：为什么全实数积分e的负平方等于根号π?

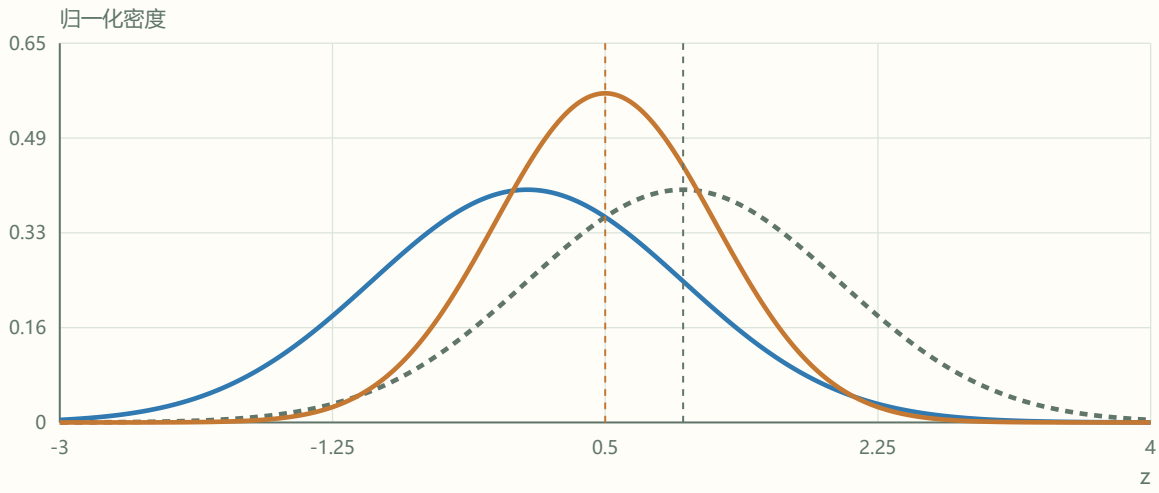
令$I=\int_{-\infty}^{\infty} e^{-x^2}dx>0$。平方后看作二维平面积分，按半径r的圆环相加；薄圆环面积约为$2\pi r\,dr$：

$$I^2=\int_0^{\infty} 2\pi r e^{-r^2}dr=\pi\int_0^{\infty} e^{-u}du=\pi.$$

这里使用换元$u=r^2$、$du=2r\,dr$，故$I=\sqrt{\pi}$。这一步是补充数学背景，不是本文可识别性证明的新结论。

含噪筛选不是直接把均值移到目标上

教学补图 · 非论文原图



蓝：基准 N(0,1)　　虚线：筛选 q(z−1)　　橙：后验 N(0.5,0.5)

目标 b = 1，但后验均值 = 0.5；先验与筛选权重相乘后必须重新归一化。

2402.09236v2 中文精读 · 示意或按讲义公式计算，不是新的训练实验

先修图解：对照橙色曲线再读刚才的配方。筛选目标b=1，不等于筛选后均值1/2。

先修11 | 密度比与对数：为什么复杂的东西可以消失?

把刚才的环境密度除以基准密度：

$$\frac{p_C(z)}{p^0(z)}=\frac{q(1-z)}{N_C}.$$

基准$p^0(z)$消掉了。这不需要先把复杂基准密度的全部形状学出来。

对数只要先记三条规则（所有输入为正）：

$$\log(ab) = \log a + \log b, \quad \log(a/b) = \log a - \log b, \quad \log(e^t) = t.$$

因此高斯的指数在取对数后变成二次式：

$$\log \frac{p_C(z)}{p^0(z)} = -\frac{1}{2}(z-1)^2 + c = -\frac{1}{2}z^2 + z + c',$$

c与c′不随z变化，但不是同一个数。证明中对z求导、找极小位置时可以把这些常数单独处理；写精确密度时不能把它们当成不存在。

观测变换的体积项为什么也会抵消?

先用一维$x = 2z$想象：区间被拉长2倍，为了保留概率面积，密度高度要变成一半：

$$p_X^e(x) = p_Z^e(x/2)/2, \qquad p_X^0(x) = p_Z^0(x/2)/2.$$

同一点作比，两个1/2又抵消。一般情形的Jacobian就是记录这种局部拉伸的工具。这里需要两个环境使用同一个变换，而且比值所在区域分母为正。

先修12 | 导数、梯度、Jacobian和链式法则各管什么?

一元函数：导数记录局部变化速度

从$F(z) = z^2$出发：

$$\frac{F(z+h) - F(z)}{h} = \frac{2zh + h^2}{h} = 2z + h.$$

让h趋于0，导数为2z。这也解释了$\frac{1}{2}z^2 - bz$的导数是$z - b$。

多个输入、一个输出：梯度

$$F(z_1, z_2) = z_1^2 + 2z_2^2, \qquad \nabla F = (2z_1, 4z_2)^\top.$$

每次只改一个输入求偏导，再把这些偏导排起来。梯度下降沿负梯度方向作小步更新，但小步变好不等于全局最优。

多个输入、多个输出：Jacobian

对$f(z_1, z_2) = (z_1, z_2 + z_1^2)$，每个输出都对每个输入求偏导：

$$Df(z) = \begin{bmatrix} 1 & 0 \\ 2z_1 & 1 \end{bmatrix}.$$

第一行描述第一个输出，第二行描述第二个输出。论文对向量环境函数求导，得到的也是这样的矩阵。

函数套函数：链式法则

$y = (2z+1)^2$先经过内层$u = 2z + 1$，再经过外层$y = u^2$：

$$\frac{dy}{dz} = \frac{dy}{du}\frac{du}{dz} = 2u \times 2 = 4(2z+1).$$

向量版本把两个数相乘换成矩阵相乘，顺序由输入输出维度决定。反向传播就是系统地利用这条法则计算网络梯度。

先修13｜最小值是数，argmin是位置或集合

考虑

$$F(z_1, z_2) = (z_1 - 1)^2.$$

它的最小值是0，但达到0的输入有无穷多个：$(1, -3), (1, 0), (1, 10)$都行。因此

$$\operatorname{argmin} F = \{(1, t) : t \in \mathbb{R}\}.$$

论文要看的是这个集合还剩几个自由度。只依赖一个概念的二次函数，常常只固定一个方向，其他方向仍自由。

还要区分：局部极小是在附近最低；全局最小是在整个指定定义域中最低；驻点只是梯度为0。例子$-z^2$在0处梯度为0，却是极大点。

先修14｜可识别性为什么不是“算法跑得出来”？

想象两位研究者给出两套模型，它们能产生完全相同的所有环境分布。若你就算拥有无限数据也无法区分它们，它们之间的差异就不是多训练几轮能解决的。

所以有三层问题：

层次	问题	典型困难
可识别性	总体信息是否足以区分解释?	不同概念混合产生同样分布
统计估计	有限数据能估得多准?	抽样波动、密度比估计误差
优化	选定目标能否高效求解?	局部极值、病态尺度、梯度不稳定

本文允许原子重排、换单位、换零点，例如$\tilde{s} = 2s + 3$；这叫识别到等价类。允许这些变化不代表允许任意把颜色和大小混成一个新概念。

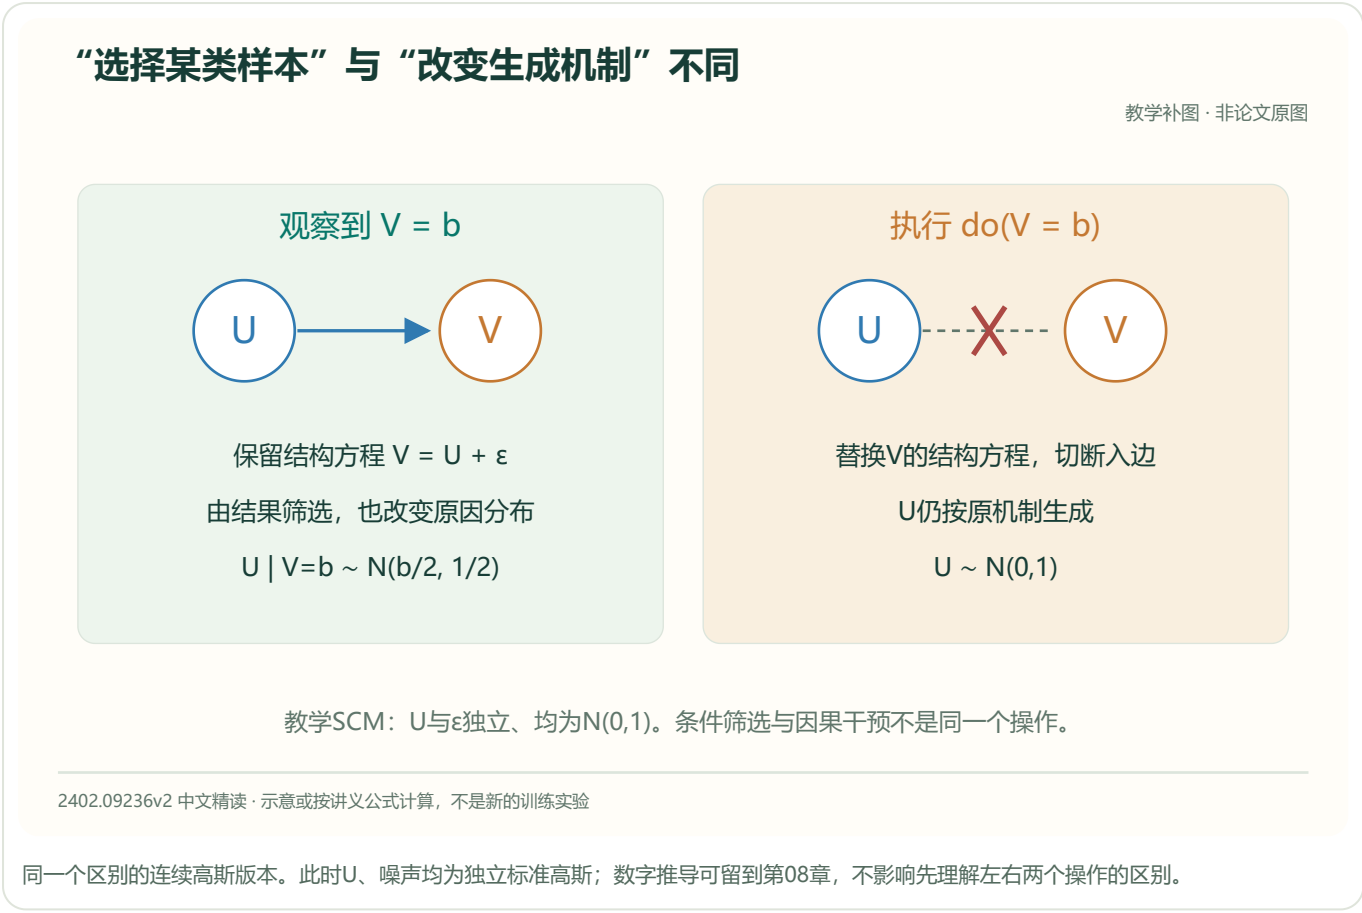
可识别定理不保证优化收敛；优化收敛不保证因果真值；好的分类准确率也不自动证明概念恢复。

先修15｜条件筛选与因果干预，先用“下雨—地湿”理解

设下雨R以一半概率发生，在这个极简教学世界里，地湿W完全由下雨决定：$W = R$。

- 观察到地湿，$P(R = 1 \mid W = 1) = 1$。
- 主动洒水把地面设为湿，即$\mathrm{do}(W = 1)$，不会让天空更容易下雨；雨仍以1/2概率发生。

第一种是用结果筛选世界，第二种是改变一个机制。**条件相关性不等于操作的因果效果。**



同一个区别的连续高斯版本。此时U、噪声均为独立标准高斯；数字推导可留到第08章，不影响先理解左右两个操作的区别。

LLM里的“激活干预”是对模型内部计算施加修改。它可以帮助研究模型行为，但不是自动证明现实世界中“真假、礼貌、帮助性”之间的因果机制。

先修16 | 分类损失怎样与密度比接上?

假设正类来自条件环境、负类来自基准环境，各占一半。固定输入x后，贝叶斯公式给出

$$P(Y=1 \mid x)=\frac{p_X^e(x)}{p_X^e(x)+p_X^0(x)}.$$

设这个概率为p，则

$$\frac{p}{1-p}=\frac{p_X^e(x)}{p_X^0(x)}, \qquad \log\frac{p}{1-p}=\log\frac{p_X^e(x)}{p_X^0(x)}.$$

左边叫logit（对数几率），不是log p。Sigmoid是它的反函数，把任意实数分数r变成概率$1/(1+e^{-r})$。

交叉熵鼓励模型给真实标签高概率。真实标签为1时，损失是$-\log p$：预测0.8约损失0.223，预测0.2约损失1.609。

在总体风险、足够模型容量等条件下，交叉熵最优预测等于真实条件标签概率。这就把分类、对数密度比和概念求值联系起来。有限网络训练是否达到这一理想状态，是另外的问题。

先修17｜公式阅读的简明字典

写法	读法	此处含义
$z \in \mathbb{R}^d$	z属于d维实数空间	z有d个实数坐标
$a^\top z$	a转置乘z	一个加权求和的标量
$Z \sim p$	Z服从分布p	不是Z约等于p
$p(z \mid b)$	给定b时z的条件密度	竖线不是除号
$p \propto w$	p正比于w	差一个与当前自变量无关的正常数
$\sum_i u_i$	对i求和	把各项相加
$\prod_i u_i$	对i求积	把各项相乘
$\int p(z)\,dz$	对z积分	在所有状态上累计密度面积
$E[Z]$	Z的期望	概率加权平均
$z^{\odot 2}$	z逐元素平方	不是矩阵乘方
$\|z\|_2$	z的欧氏范数	各分量平方和再开根号
$\ker A$	A的核或零空间	被A读成0的所有方向
$\mathrm{Diag}(z)$	以z为对角线的矩阵	对角外为0
$D\varphi$	φ的Jacobian	所有输出对所有输入的偏导表
argmin	达到最小值的输入集合	与最小的数值本身不同

上标e通常是环境编号，不是幂；上标0是基准环境；f^{-1}是逆映射；A^{+}是伪逆。读公式时先确认这些约定，可以少掉一半不必要的困惑。

先修18｜现在怎样回到原论文?

先不要按“把所有术语背完再看论文”的顺序。按以下三遍推进：

1. **直觉遍：** 读本章到先修11，能说清“潜变量、概念、筛选、密度比”。
2. **模型遍：** 回到00阅读地图、02模型。遇到词就点击查，只要求逐段翻译出公式在做什么。
3. **证明遍：** 补先修12–16与01预备知识，再读04定理2、05几何证明、06左零空间。

遇到“为什么满秩就可以左乘一个矩阵”时，回到秩与伪逆；遇到“为什么几乎处处能变成处处”时，回到连续与可微。**带着具体卡点补一个概念，比一次背完61个词更有效。**

先修19｜五个自测题：会这些就能开始读模型了

题1：a=(1,2)、z=(3,4)，哪个是方向，哪个是概念数值?

▼ 查看解释

a是读取方向或权重，z是潜表示，内积结果11才是概念数值。若筛选目标b=1，也不代表当前这个样本的概念值变成1。

题2：密度为5，违反概率不能超过1吗?

▼ 查看解释

不违反。宽度0.2的区间上密度为5，面积是1。密度高度与概率面积不同。

题3：筛选希望z接近1，为什么后验均值可能只有0.5?

▼ 查看解释

筛选是似然与先验相乘，不是强制把变量设成1。标准高斯先验更偏好0，单位方差的筛选偏好1，乘积在0.5处取得新的中心。

题4：M有3行，为什么左零空间里还有一个非零向量?

▼ 查看解释

上述M只有2个独立行方向，第三行是前两行之和，所以三行之间有一条非平凡抵消关系。左零空间维度为行数3减秩2，等于1。

题5：训练损失下降，能否据此证明找到了真正的因果变量？

▼ 查看解释

不能。损失下降说明当前优化目标改善了。还要分别检查模型设定、可识别性、有限样本误差，以及学到的特征是否满足相应解释或干预要求。

如果现在仍觉得“我知道词的意思，但读不动证明”，这是正常的下一阶段：先把一个具体例子算通，再逐行把数字换成符号，不必立刻把所有抽象结论一起记住。